


Muestreo de Gibbs



José Antonio Perusquía Cortés
Estadística Bayesiana, Semestre 2026-I



Algoritmo

- ▶ Inicializa el algoritmo con puntos iniciales $\left(x_1^{(0)}, \dots, x_p^{(0)}\right)$
- ▶ Al tiempo t :
 - Simular $X_1^{(t)} \sim f\left(\cdot \mid X_2^{(t-1)}, \dots, X_p^{(t-1)}\right)$
 - Simular $X_2^{(t)} \sim f\left(\cdot \mid X_1^{(t)}, X_3^{(t-1)}, \dots, X_p^{(t-1)}\right)$
 - \vdots
 - Simular $X_p^{(t)} \sim f\left(\cdot \mid X_1^{(t)}, \dots, X_{p-1}^{(t)}\right)$

Punto de cambio Poisson

- ▶ Considerar el siguiente modelo

$$X_i \sim \text{Po}(\lambda_1) \quad i = 1, \dots, M$$

$$X_i \sim \text{Po}(\lambda_2) \quad i = M + 1, \dots, n$$

- ▶ Se considera a priori

$$f(\lambda_1, \lambda_2, M) = f(\lambda_1)(\lambda_2)f(M)$$

- ▶ Donde $\lambda_1 \sim \text{Ga}(\alpha_1, \beta_1)$, $\lambda_2 \sim \text{Ga}(\alpha_2, \beta_2)$ y $M \sim \text{Unif}\{1, \dots, n - 1\}$

- ▶ La posterior es proporcional a

$$f(\lambda_1, \lambda_2, M \mid \mathbf{x}^{(n)}) \propto \lambda_1^{\alpha_1 - 1 + \sum_{i=1}^M x_i} \exp(-(\beta_1 + M)\lambda_1) \lambda_2^{\alpha_2 - 1 + \sum_{i=M+1}^n x_i} \exp(-(\beta_2 + n - M)\lambda_2)$$

Punto de cambio Poisson

- ▶ Las condicionales de λ_1, λ_2




$$\lambda_1 \mid \mathbf{x}^{(n)}, M \sim \text{Ga} \left(\alpha_1 + \sum_{i=1}^M x_i, \beta_1 + M \right)$$

$$\lambda_2 \mid \mathbf{x}^{(n)}, M \sim \text{Ga} \left(\alpha_2 + \sum_{i=M+1}^n x_i, \beta_2 + n - M \right)$$

- ▶ Para cualquier valor de k en el soporte de M

$$\mathbb{P} \left(M = k \mid \lambda_1, \lambda_2, \mathbf{x}^{(n)} \right) \propto \left(\frac{\lambda_1}{\lambda_2} \right)^{\sum_{i=1}^k x_i} \exp((\lambda_2 - \lambda_1) \cdot k)$$

Punto de cambio Poisson



Condición de positividad

Definición

Una distribución con densidad $f(x_1, \dots, x_n)$ y densidades marginales $f_i(x_i)$ satisface la condición de positividad si $f(x_1, \dots, x_n) > 0$ para todo x_1, \dots, x_n tal que $f_i(x_i) > 0$.

- La condición de positividad implica que el soporte de la densidad conjunta f es el producto cartesiano de los soportes marginales.

Teorema de Hammersley - Clifford

Teorema

Sea (X_1, \dots, X_p) un vector multivariado con densidad conjunta $f(x_1, \dots, x_p)$ que satisface la condición de positividad. Entonces para todo (ξ_1, \dots, ξ_p) en el soporte de f y cualquier permutación l en $\{1, 2, \dots, p\}$ se cumple que

$$f(x_1, \dots, x_p) \propto \prod_{j=1}^p \frac{f_{l_j}(x_{l_j} | x_{l_1}, \dots, x_{l_{j-1}}, \xi_{l_{j+1}}, \dots, \xi_{l_p})}{f_{l_j}(\xi_{l_j} | x_{l_1}, \dots, x_{l_{j-1}}, \xi_{l_{j+1}}, \dots, \xi_{l_p})}.$$

- Tareita: Ver el caso (X_1, X_2, X_3)

Kernel de transición

Lema

El kernel de transición del algoritmo de Gibbs está dado por

$$K(\mathbf{x}^{(t-1)}, \mathbf{x}^{(t)}) = f_{X_1|X_{-1}}(x_1^{(t)} \mid x_2^{(t-1)}, \dots, x_p^{(t-1)}) \cdots f_{X_p|X_{-p}}(x_p^{(t)} \mid x_1^{(t)}, \dots, x_{p-1}^{(t)}) .$$

- No es reversible pero existen versiones reversibles del muestro de Gibbs

Kernel de transición

Lema

La distribución conjunta $f(x_1, \dots, x_p)$ es la distribución invariante de la cadena de Markov generada por el algoritmo de Gibbs.

- Demostración (ver las notas)

Kernel de transición

Lema

Si la distribución conjunta $f(x_1, \dots, x_p)$ satisface la condición de positividad, el algoritmo Gibbs produce una cadena de Markov f -irreducible y recurrente.

- Demostración (ver las notas)
- Si el kernel es absolutamente continuo con respecto a la medida de Lebesgue entonces la cadena es Harris recurrente

Observaciones

- Las realizaciones no son independientes sino típicamente positivamente correlacionadas
- A mayor correlación la cadena se moverá lentamente por el espacio de estados (*slow mixing*)

Ejemplo normal bivariada

- ▶ Asumir que se desea simular de una distribución normal bivariada usando Gibbs
- ▶ La densidad conjunta es

$$f(x_1, x_2) \propto \exp \left(-\frac{(x_1 - (\mu_1 + \sigma_{12}/\sigma_{22}^2(x_2 - \mu_2)))^2}{2(\sigma_1^2 - (\sigma_{12})^2/\sigma_2^2)} \right)$$



- ▶ Las marginales son

$$X_1 | X_2 = x_2 \sim \mathcal{N} \left(\mu_1 + \frac{\sigma_{12}}{\sigma_2^2}(x_2 - \mu_2), \sigma_1^2 - \frac{\sigma_{12}^2}{\sigma_2^2} \right)$$

$$X_2 | X_1 = x_1 \sim \mathcal{N} \left(\mu_2 + \frac{\sigma_{12}}{\sigma_1^2}(x_1 - \mu_1), \sigma_2^2 - \frac{\sigma_{12}^2}{\sigma_1^2} \right)$$



Ejemplo normal bivariada

- ▶ Considerando $\mu_1 = \mu_2 = 0$, $\sigma_1 = \sigma_2 = 1$ y $\sigma_{12} = 0.3$





Ejemplo normal bivariada

- ▶ Considerando $\mu_1 = \mu_2 = 0, \sigma_1 = \sigma_2 = 1$ y $\sigma_{12} = 0.3$





Ejemplo normal bivariada

- ▶ Considerando $\mu_1 = \mu_2 = 0, \sigma_1 = \sigma_2 = 1$ y $\sigma_{12} = 0.3$





Ejemplo normal bivariada

- ▶ Considerando $\mu_1 = \mu_2 = 0$, $\sigma_1 = \sigma_2 = 1$ y $\sigma_{12} = 0.99$





Ejemplo normal bivariada

- ▶ Considerando $\mu_1 = \mu_2 = 0, \sigma_1 = \sigma_2 = 1$ y $\sigma_{12} = 0.99$



Ejemplo normal bivariada

- ▶ Considerando $\mu_1 = \mu_2 = 0$, $\sigma_1 = \sigma_2 = 1$ y $\sigma_{12} = 0.99$



Compleción

Definición

Dada una densidad de probabilidad f , una densidad g que satisfaga

$$\int g(x, z) dz = f(x)$$

se dice una **compleción** de f .

- Técnica de **aumentación**
- Elegir g tal que sus condicionales sean fáciles de simular
- Ejemplo conocido es el **slice sampler**

Slice sampler

Lema

Si $f(\theta) = \prod_{i=1}^k f_i(\theta)$ donde $f_i(\theta)$ son funciones positivas (no necesariamente densidades)

entonces f se puede completar como

$$\prod_{i=1}^k \mathbb{I}(0 \leq u_i \leq f_i(\theta))$$

Slice sampler

Algoritmo

Dados valores iniciales $u_1^{(0)}, \dots, u_k^{(0)}, \theta^{(0)}$ al tiempo t :

- Simular $u_1^{(t)} \sim \text{Unif}(0, f_1(\theta^{(t-1)}))$
- Simular $u_2^{(t)} \sim \text{Unif}(0, f_2(\theta^{(t-1)}))$
- \vdots
- Simular $u_k^{(t)} \sim \text{Unif}(0, f_k(\theta^{(t-1)}))$
- Simular $\theta^{(t)} \sim \text{Unif}(A^{(t)})$ donde $A^{(t)} = \{y : f_i(y) \geq u_i^{(t)}, i = 1, \dots, k\}$

Ejemplo normal truncada

- La densidad de la distribución normal truncada en $[\mu^*, \infty)$ es proporcional a

$$f(x) \propto \exp\left(\frac{-(x - \mu)^2}{2\sigma^2}\right) \mathbb{I}_{(\mu^*, \infty)}^{(x)} = f_1(x)f_2(x)$$

donde

$$f_1(x) = \exp\left(\frac{-(x - \mu)^2}{2\sigma^2}\right), \quad f_2(x) = \mathbb{I}_{(\mu^*, \infty)}^{(x)}$$

- Se puede completar como

$$g(x, z) \propto \mathbb{I}_{(\mu^*, \infty)}^{(x)} \mathbb{I}^{(z)}(0, \exp(-(x - \mu)^2/2\sigma^2))$$

Ejemplo normal truncada

- ▶ El algoritmo se traduce a simular variables uniformes en los soportes adecuados
- ▶ El soporte de Z está bien definido

$$\mathbb{I}^{(z)}_{\left(0, \exp\left(-(x - \mu)^2/2\sigma^2\right)\right)}$$

- ▶ Para X se tienen dos condiciones:

1. $x \geq \mu^*$

2. Como $0 \leq z \leq \exp\left(-(x - \mu)^2/2\sigma^2\right)$ entonces $x \leq \mu + \sqrt{-2\sigma^2 \log(z)}$

Ejemplo normal truncada

- El algoritmo queda definido mediante las siguientes iteraciones

1. $x^{(t)} \mid z^{(t-1)} \sim \text{Unif}(\mu^*, \mu + \sqrt{-2\sigma^2 \log(z^{(t-1)})})$



2. $z^{(t)} \mid x^{(t)} \sim \text{Unif}(0, \exp(-(x^{(t)} - \mu)^2 / 2\sigma^2))$

- Con $z^{(0)}$ elegido de tal forma que $\mu + \sqrt{-2\sigma^2 \log(z^{(0)})} > \mu^*$ lo que implica que

$$z^{(0)} < \exp\left(\frac{-(\mu^* - \mu)^2}{2\sigma^2}\right)$$


Ejemplo normal truncada

- Tomando $\mu = 0$, $\mu^* = 3$, $\sigma^2 = 1$ y puntos iniciales $x^{(0)} = 0$ y $z^{(0)} = 0.0055$ e iterando 1000 veces el algoritmo




Ejemplo normal truncada

- ▶ Tomando $\mu = 0$, $\mu^* = 3$, $\sigma^2 = 1$ y puntos iniciales $x^{(0)} = 0$ y $z^{(0)} = 0.0055$ e iterando 1000 veces el algoritmo



Ejemplo

- Se tienen 48 tiempos de supervivencia de pacientes con mieloma múltiple



- Tiene sesgo positivo y claramente no es normal

Ejemplo


- ¿Cómo se puede hacer para que los datos sean normales?
- Box y Cox propusieron la transformación

$$w_i = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0 \\ \log(y_i) & \text{si } \lambda = 0 \end{cases}$$

- Aplicaciones a modelos de regresión y a series de tiempo

Ejemplo


- ▶ En el enfoque clásico es otro parámetro a estimar mediante la maximización de la (log) verosimilitud perfilada, i.e., $\mathcal{L}(\lambda) = \mathcal{L}(\hat{\mu}, \hat{\sigma}^2, \lambda)$



- ▶ El estimador máximo verosímil es $\hat{\lambda} = 0.1414$

Ejemplo

- ▶ Con esta $\hat{\lambda}$



| Prueba | Estadístico | p-valor |
|------------------|-------------|---------|
| Anderson-Darling | 0.47426 | 0.2308 |
| Lilliefors | 0.12077 | 0.07713 |
| Shapiro-Wilk | 0.96828 | 0.2169 |

- ▶ Para esta transformación $\hat{\mu}_w = 3.2994$ y $\hat{\sigma}_w = 1.6129$

Ejemplo

- ▶ Bajo un enfoque bayesiano se puede hacer inferencia sobre λ, μ, σ^2 conjuntamente
- ▶ Utilizando la distribución no-informativa

$$f(\lambda, \mu, \sigma^2) \propto \frac{1}{\sigma}$$

- ▶ La verosimilitud está dada por

$$f(\mathbf{y} \mid \lambda, \mu, \sigma^2) = \prod_{i=1}^n \phi \left(\frac{y_i^\lambda - 1}{\lambda} \mid \mu, \sigma^2 \right) y_i^{\lambda-1}$$

Ejemplo

- ▶ La posterior es

$$f(\lambda, \mu, \sigma^2 \mid \mathbf{y}) \propto \left(\frac{1}{\sigma^2}\right)^{\left(\frac{n+1}{2}\right)} \prod_{i=1}^n y_i^\lambda \prod_{i=1}^n \exp\left(-\frac{(w_i(\lambda) - \mu)^2}{2\sigma^2}\right)$$

- ▶ Las condicionales de μ y σ^2 son conocidas

$$\mu \mid \sigma^2, \lambda, \mathbf{y} \sim \mathcal{N}\left(\bar{w}(\lambda), \frac{\sigma^2}{n}\right)$$

$$\sigma^2 \mid \mu, \lambda, \mathbf{y} \sim \text{InvGa}\left(\frac{n-1}{2}, \frac{\sum_i (w_i(\lambda) - \mu)^2}{2}\right)$$

Ejemplo

- ▶ El ‘problema’ es la condicional de λ

$$\begin{aligned} f(\lambda \mid \mu, \sigma^2 \mathbf{y}) &\propto \prod_{i=1}^n y_i^\lambda \prod_{i=1}^n \exp \left(-\frac{(w_i(\lambda) - \mu)^2}{2\sigma^2} \right) \\ &= \exp \left(\lambda \sum_i \log(y_i) \right) \prod_{i=1}^n \exp \left(-\frac{(w_i(\lambda) - \mu)^2}{2\sigma^2} \right) \end{aligned}$$

- ▶ No tiene una distribución cerrada
- ▶ Se puede usar un slice sampler o si es log-cóncava un ARS o
- ▶ Metropolis - Hastings

Ejemplo

- ▶ A grandes rasgos el algoritmo de Metropolis-Hastings genera una cadena de Markov de tal forma que al tiempo t
 1. Se genera un valor λ^* de una distribución instrumental
 2. Se acepta $\lambda^{(t)} = \lambda^*$ con probabilidad α
 3. En caso contrario $\lambda^{(t)} = \lambda^{(t-1)}$
- ▶ Los detalles se verán más adelante

Ejemplo

► El algoritmo queda definido como:

1. Definir valores iniciales $\mu^{(0)}, \sigma^{2(0)}, \lambda^{(0)}$ e hiperparámetros requeridos

2. Al tiempo t :

- Simular $\mu^{(t)} \sim \mathcal{N} \left(\bar{w}(\lambda^{(t)}), \frac{\sigma^{2(t-1)}}{n} \right)$


- Simular $\sigma^{2(t)} \sim \text{InvGa} \left(\frac{n-1}{2}, \frac{\sum_i (w_i(\lambda^{(t-1)}) - \mu^{(t)})^2}{2} \right)$

- Simular $\lambda^{(t)}$ utilizando un Metropolis-Hastings

3. Repetir N veces

Ejemplo


- Para λ



| Min. | Q1 | Mediana | Media | Q3 | Max. |
|----------|---------|---------|---------|---------|---------|
| -0.07959 | 0.16291 | 0.24326 | 0.24034 | 0.30959 | 0.57317 |

Ejemplo


- Para μ



| Min. | Q1 | Mediana | Media | Q3 | Max. |
|-------|-------|---------|-------|-------|-------|
| 2.121 | 3.392 | 3.908 | 4.051 | 4.530 | 9.372 |

Ejemplo

- Para σ^2



| Min. | Q1 | Mediana | Media | Q3 | Max. |
|--------|--------|---------|--------|--------|---------|
| 0.5983 | 3.0050 | 4.6209 | 5.9167 | 7.1654 | 48.8956 |