



Estadística descriptiva

Datos y variables



¿Qué es la estadística descriptiva?



Medidas numéricas

Tendencia
central

Localización

Dispersión

Forma

Correlación

Medidas de tendencia central

- Indican el valor donde se centran los datos e.g.:

- **Media:** El promedio de las observaciones

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Mediana:** El valor que separa las observaciones en dos partes iguales

$$\text{med}(\mathbf{x}) = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & \text{si } n \text{ es impar} \\ \frac{1}{2} \left(x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)} \right) & \text{si } n \text{ es par} \end{cases}$$

- **Moda:** El valor más repetido

Medidas de localización

- Indican los valores que dividen la muestra ordenada e.g. :
 - **Cuartiles** : Son los tres valores que dividen las observaciones en cuatro partes iguales y usualmente denotados por $q_{.25}$, $q_{.50}$ (mediana) y $q_{.75}$
 - **Deciles** : Son los nueve valores que dividen la muestra en 10 partes iguales
 - **Percentiles** : Son los 99 valores que dividen la muestra en 100 partes iguales

Medidas de dispersión

- Indican la variabilidad de los datos e.g.:

- **Desviación estándar**

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

- **Rango**: Definido como $r = x_{(n)} - x_{(1)}$




- **Rango intercuartílico**: Utilizado para identificar valores atípicos y definido como

$$\text{IQR} = q_{.75} - q_{.25}$$

- **Coeficiente de variación**: Utilizado para comparar las distribuciones y definido como $\sigma/\bar{x}$

Medidas de forma

- Nos indican la forma de la distribución:
 - **Curtosis** : Mide que tan achatada es una distribución en relación a una distribución gaussiana cuya curtosis es 3
 - **Mesocúrtica** : Si la curtosis es igual a 3
 - **Platicúrtica** : Si la curtosis es menor a 3
 - **Leptocúrtica** : Si la curtosis es mayor a 3






Medidas de forma

- Nos indican la forma de la distribución :

- Coeficiente de asimetría (o sesgo)

- **Simétrica** : si el coeficiente es cero.
- **Asimétrica negativa** (o a la izquierda) : si el coeficiente es menor a cero.
- **Asimétrica positiva** (o a la derecha) : si el coeficiente es mayor a cero.



Medidas de correlación

- Miden el grado de efecto de una variable en otra :
 - **Coeficiente de Pearson.**
 - **Coeficiente ρ de Spearman.**
 - **Coeficiente τ de Kendall.**
- Se estudian a fondo en el curso de Modelos No Paramétricos y de Regresión

Representaciones gráficas

Tabla de
frecuencias

Gráfica de
barras

Histograma

Box plot

Pie/dona

Diagrama de
dispersión

Diagrama de
correlación

Diagrama de
tallo y hojas

¡Muchas más!

Tabla de frecuencias

- Útiles para resumir la información de variables categóricas
- Para una muestra $x_1, \dots, x_n$
 - Se encuentran los valores únicos $x_1^*, \dots, x_k^*$
 - Se cuenta el número de veces que estos valores únicos ocurren (**frecuencias**) y se denotan por $f_1, \dots, f_k$ de tal forma que $f_1 + \dots + f_k = n$
 - Se calculan las **frecuencias relativas**, $f_i^* = f_i/n$, de tal forma que $f_1^* + \dots + f_k^* = 1$
 - Se obtienen las **frecuencias acumuladas** como $F_i = f_1^* + \dots + f_i^*$
- Las frecuencias (relativas) se utilizan para construir las gráficas de barras, de pie/dona

Gráficas de barras y pie/dona







Tabla de frecuencias

- Para una muestra $x_1, \dots, x_n$ de variables numéricas
 - Se genera una partición del soporte en m intervalos
 - Se cuenta el número de observaciones que caen en cada intervalo (**frecuencias**)
 - Se obtienen las **frecuencias relativas**
 - Se obtienen las **frecuencias acumuladas**
- Las frecuencias (relativas) se utilizan para construir histogramas

Histogramas

- Representación gráfica de la densidad empírica





Histogramas

- Requiere una tabla de frecuencias utilizando intervalos en lugar de valores únicos
 - Obtener el rango de los datos
 - Seleccionar el número de clases M (e.g. $M = \sqrt{n}$ o $M = \log(n) + 1$)
 - Crear los intervalos y obtener las **frecuencias**
 - Obtener la **marca de clase** (punto medio del intervalo)
 - Crear una gráfica de barras con cada barra centrada en la marca de clase y altura dada por las frecuencias (absolutas o relativas)

Box plot

- Representación gráfica de los datos a partir de los cuartiles




Box plot

- Muestra información del mínimo, máximo, mediana, de la simetría de la densidad así como de valores atípicos
 - Obtener los cuártiles y el rango intercuartílico
 - Dibujar una caja empezando por el primer cuartil y terminado en el tercer cuartil
 - Dibujar una recta horizontal (o vertical) dentro de la caja a la altura del segundo cuartil
 - Calcular el rango intercuartílico e identificar como valores atípicos aquellos valores que sean menores a $Q_1 = q_{.25} - 1.5 * \text{IQR}$ y mayores a $Q_2 = q_{.75} + 1.5 * \text{IQR}$
 - Dibujar una recta del primer cuartil a Q_1
 - Dibujar una recta del tercer cuartil a Q_2

Software

Lenguajes



IDE



Notebooks



En este curso

Paqueterías:

- ggplot2
- dplyr
- plyr
- tidyverse
- etc.



Ejemplo: Salarios

- Base que contiene la información de 1171 personas laborando en algo relacionado con la ciencia de datos
 - ***job_title***: Nombre de la posición
 - ***job_type***: Tiempo completo o becario
 - ***experience_level***: Nivel de experiencia
 - ***location***: Ubicación del trabajo
 - ***salary_currency***: Tipo de moneda
 - ***salary***: Salario

