Estadística descriptiva

José Antonio Perusquía Cortés

Inferencia Estadística Semestre 2026-I

Datos y variables

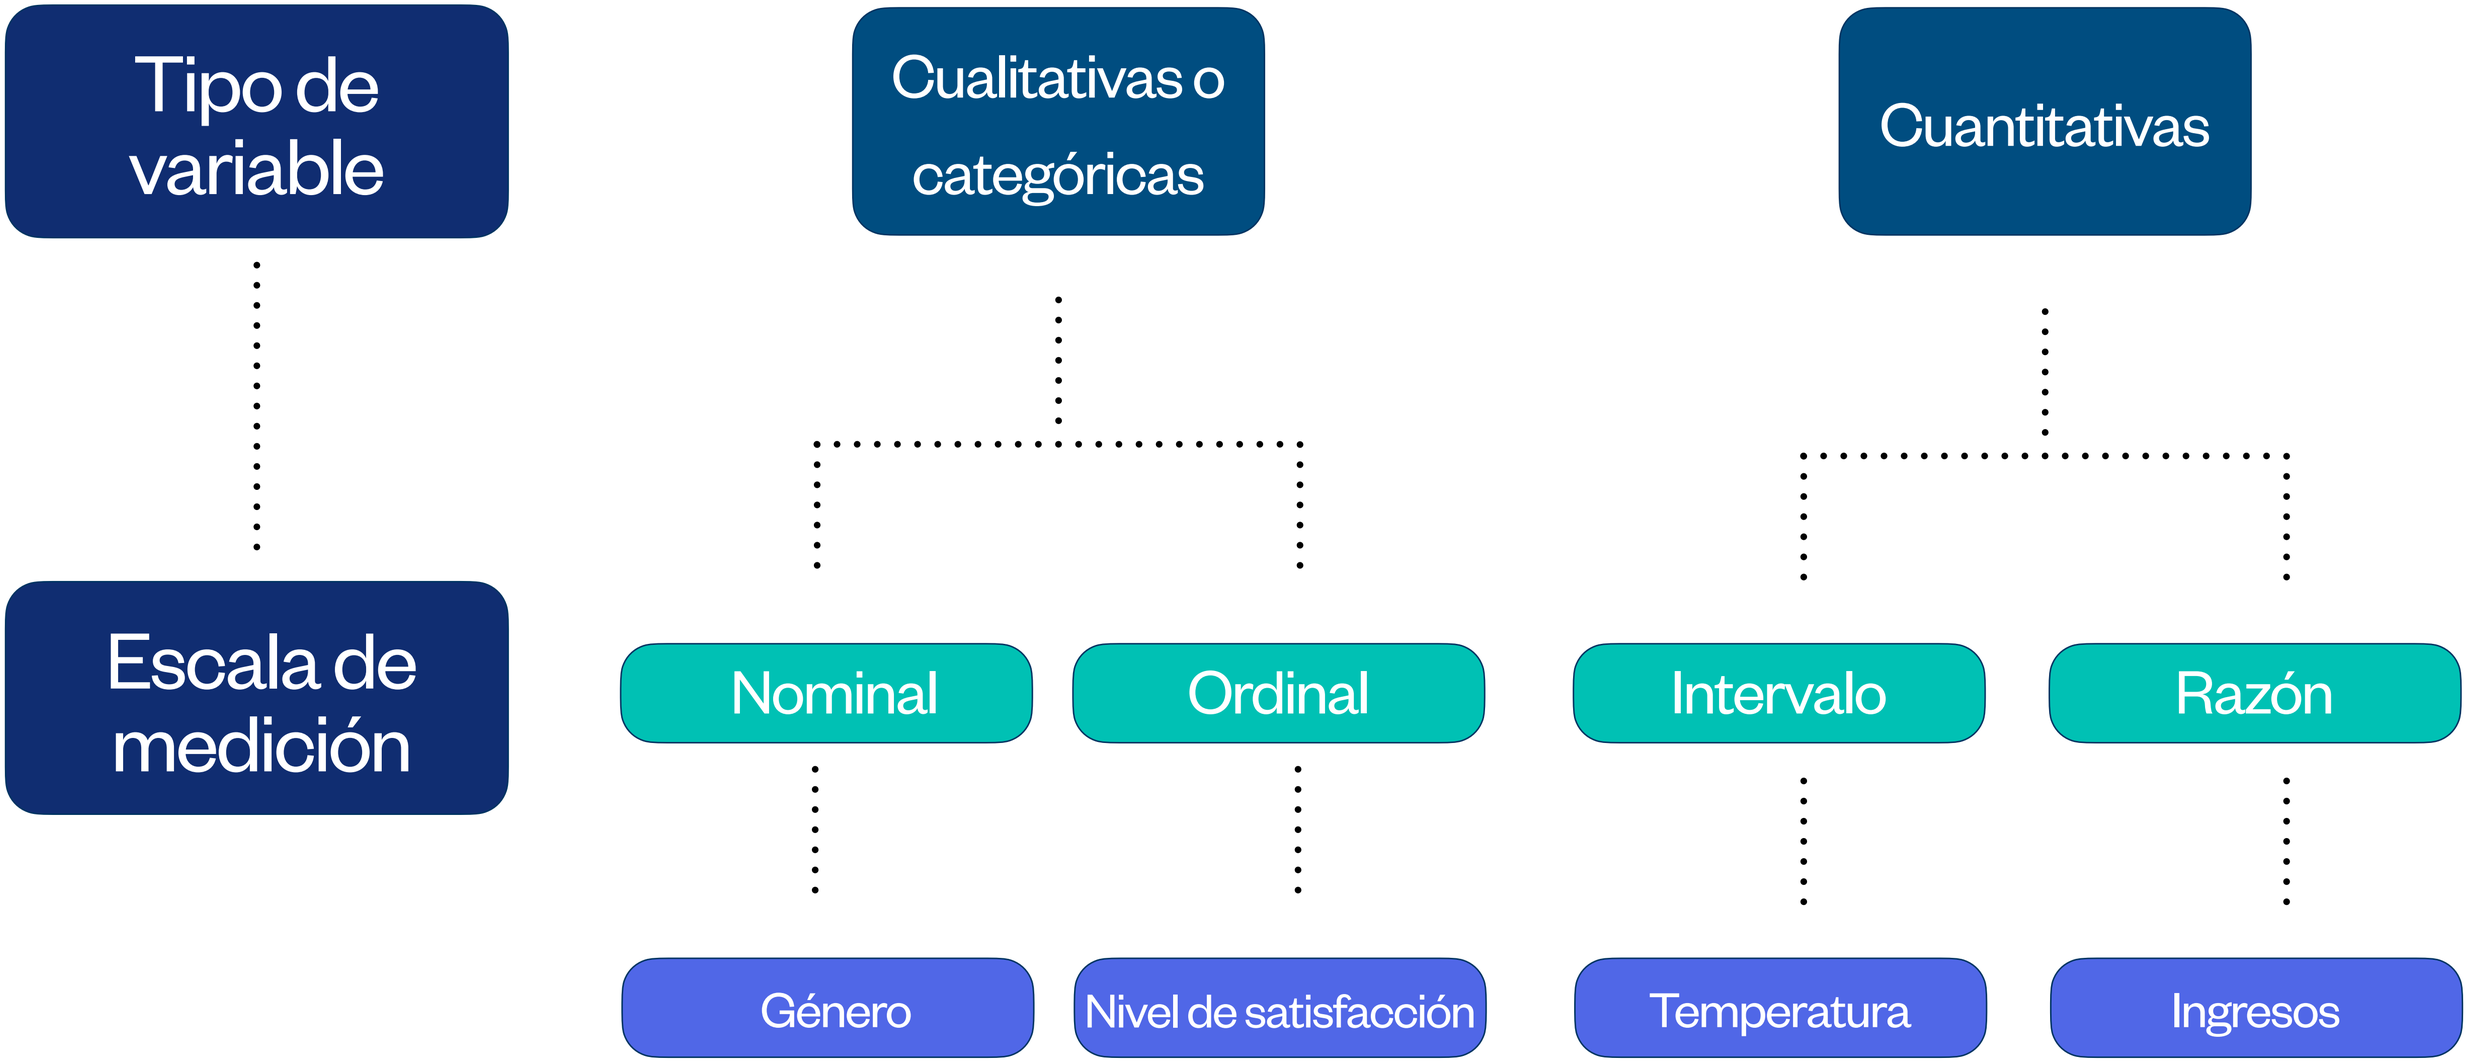

¿ Qué es la estadística descriptiva ?

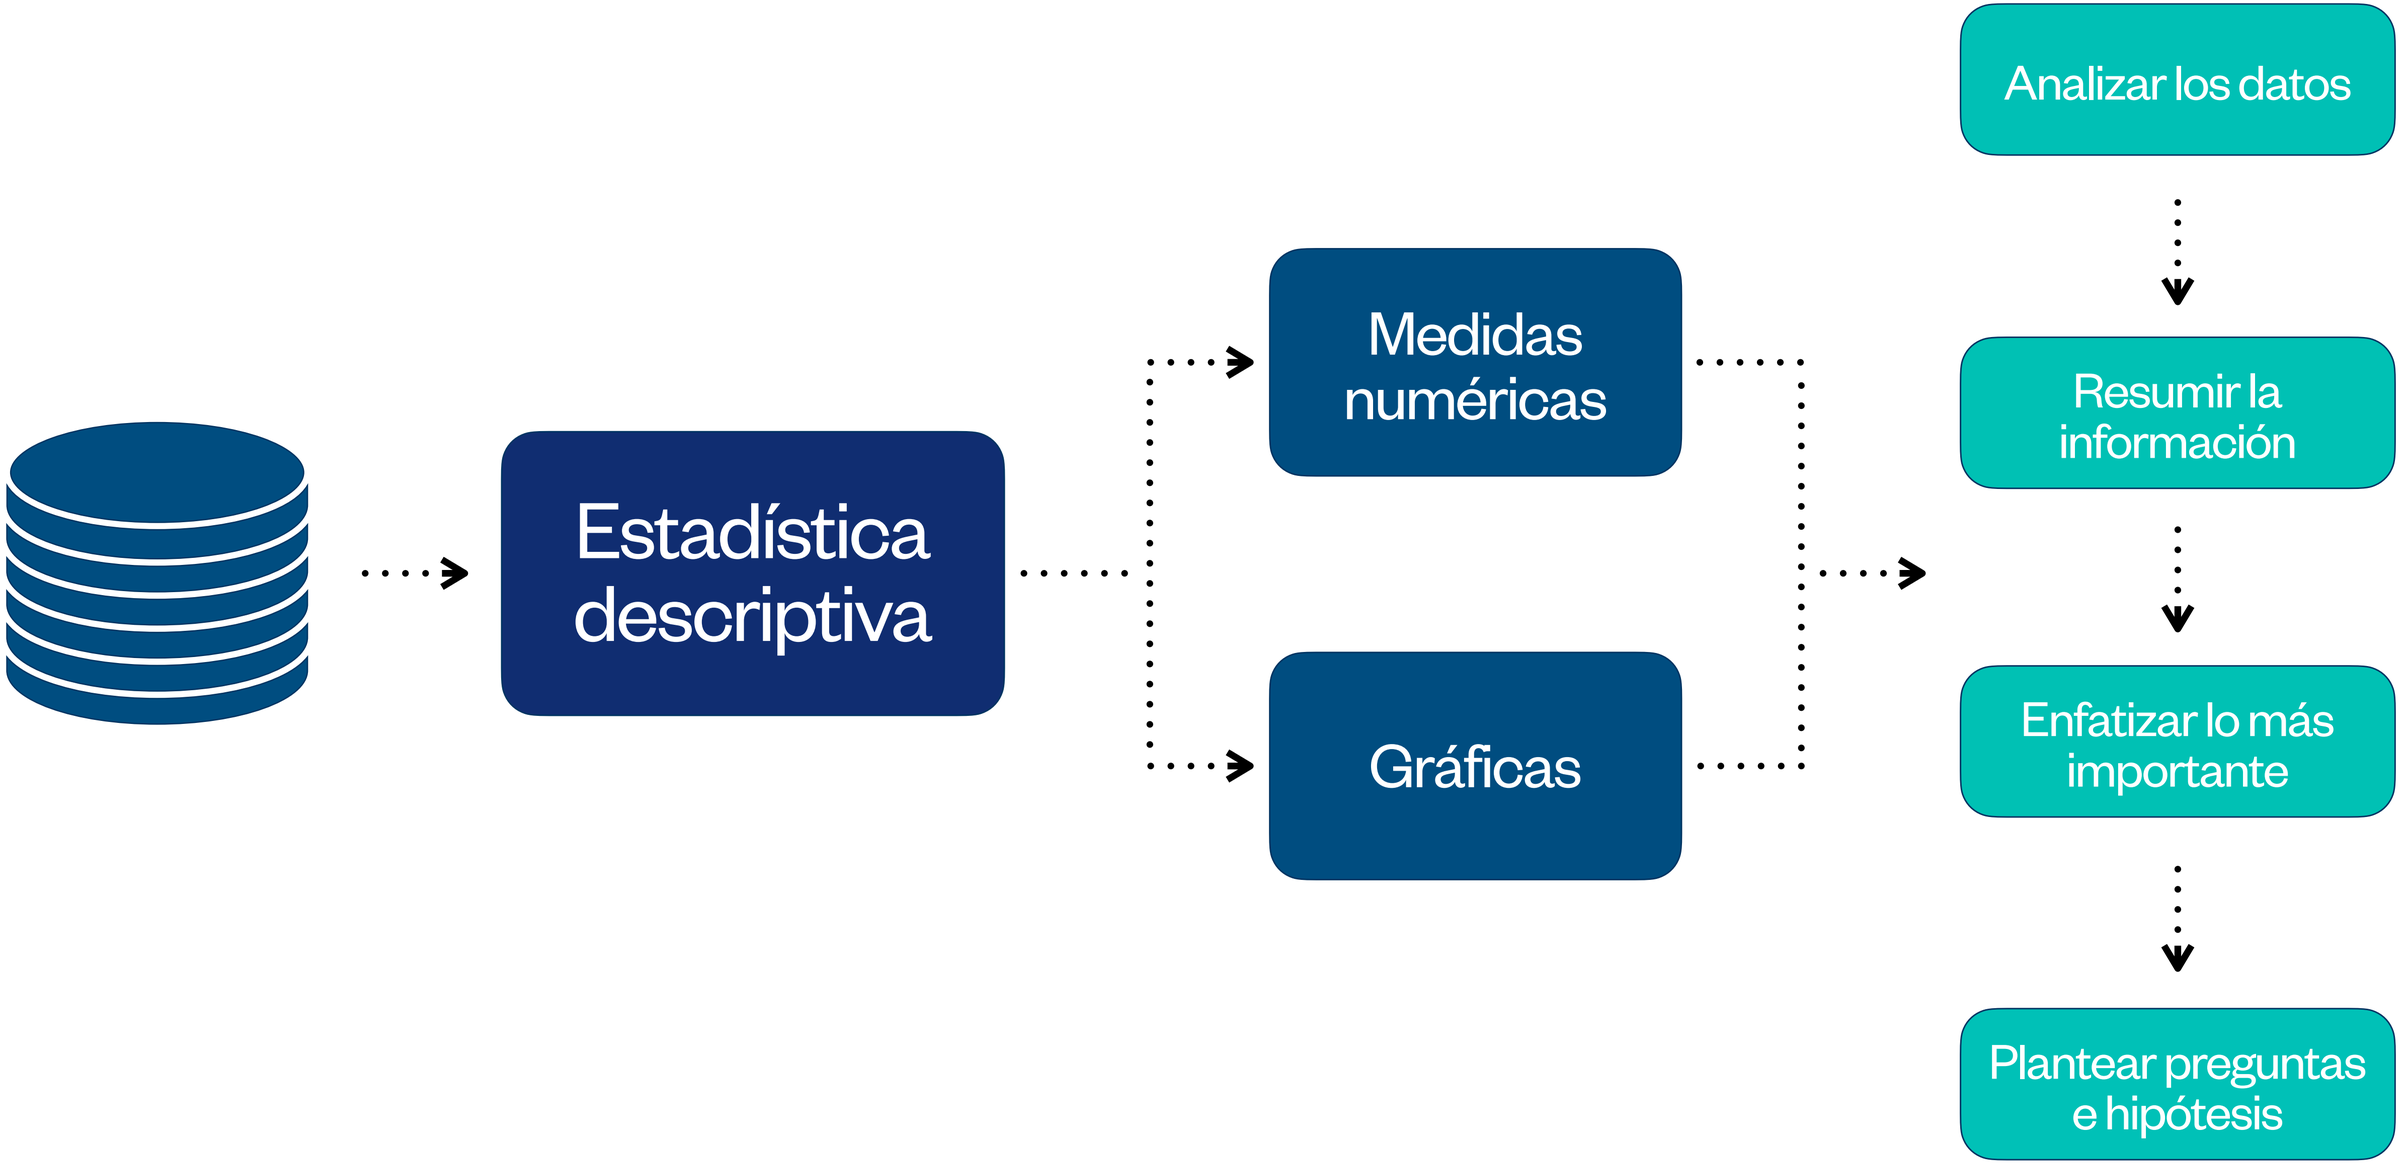

Medidas numéricas

- Tendencia central
- Localización
- Dispersión
- Forma
- Correlación

Medidas de tendencia central

- Indican el valor donde se centran los datos e.g.:

  - **Media**: El promedio de las observaciones

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

  - **Mediana**: El valor que separa las observaciones en dos partes iguales

$$\text{med}(\mathbf{x}) = \begin{cases} x_{\left(\frac{n+1}{2}\right)} & \text{si } n \text{ es impar} \\ \frac{1}{2}\left(x_{\left(\frac{n}{2}\right)} + x_{\left(\frac{n}{2}+1\right)}\right) & \text{si } n \text{ es par} \end{cases}$$

  - **Moda**: El valor más repetido

Medidas de localización

- Indican los valores que dividen la muestra ordenada e.g. :

  - **Cuartiles** : Son los tres valores que dividen las observaciones en cuatro partes iguales y usualmente denotados por $q_{.25}$, $q_{.50}$ (mediana) y $q_{.75}$

  - **Deciles** : Son los nueve valores que dividen la muestra en 10 partes iguales

  - **Percentiles** : Son los 99 valores que dividen la muestra en 100 partes iguales

Medidas de dispersión

- Indican la variabilidad de los datos e.g. :

  - **Desviación estándar**

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

  - **Rango** : Definido como $r = x_{(n)} - x_{(1)}$

  - **Rango intercuartílico** : Utilizado para identificar valores atípicos y definido como $\text{IQR} = q_{.75} - q_{.25}$

  - **Coeficiente de variación** : Utilizado para comparar las distribuciones y definido como $\sigma/\bar{x}$

Medidas de forma

- Nos indican la forma de la distribución :

  - **Curtosis** : Mide que tan achatada es una distribución en relación a una distribución guassiana cuya curtosis es 3

    - **Mesocúrtica** : Si la curtosis es igual a 3
    - **Platicúrtica** : Si la curtosis es menor a 3
    - **Leptocúrtica** : Si la curtosis es mayor a 3

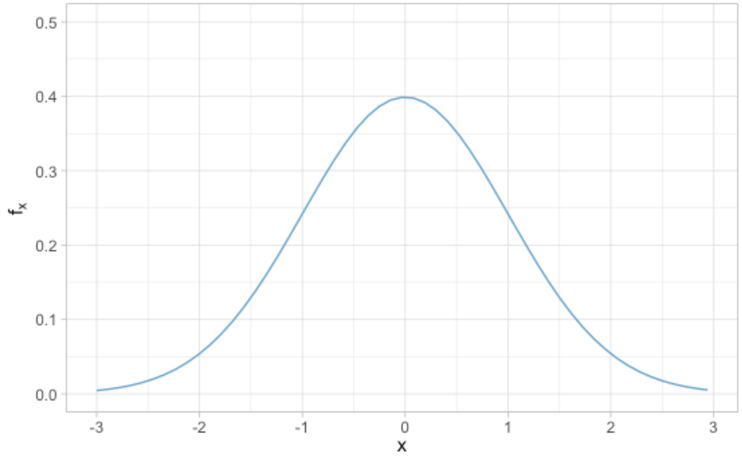

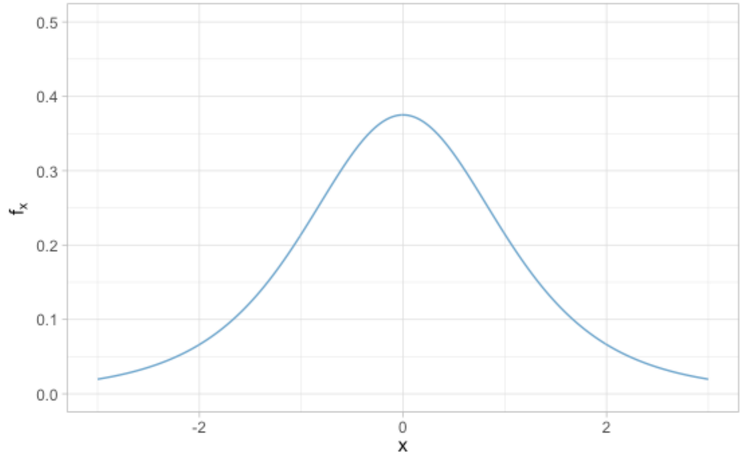

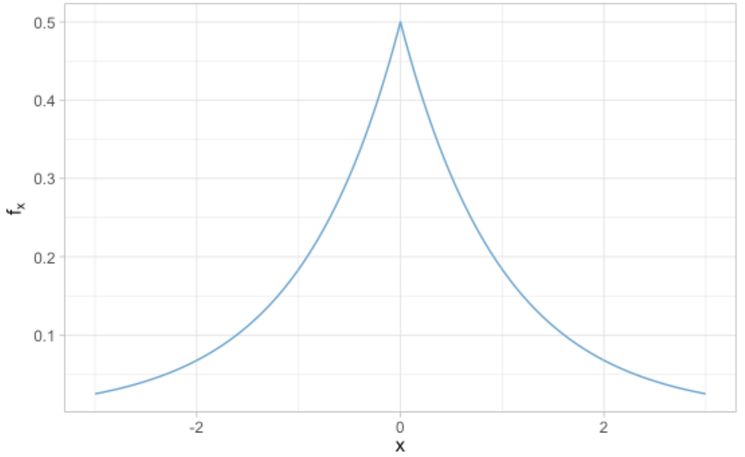

Medidas de forma

- Nos indican la forma de la distribución :

  - Coeficiente de asimetría (o sesgo)

    - **Simétrica** : si el coeficiente es cero.
    - **Asimétrica negativa** (o a la izquierda) : si el coeficiente es menor a cero.
    - **Asimétrica positiva** (o a la derecha) : si el coeficiente es mayor a cero.

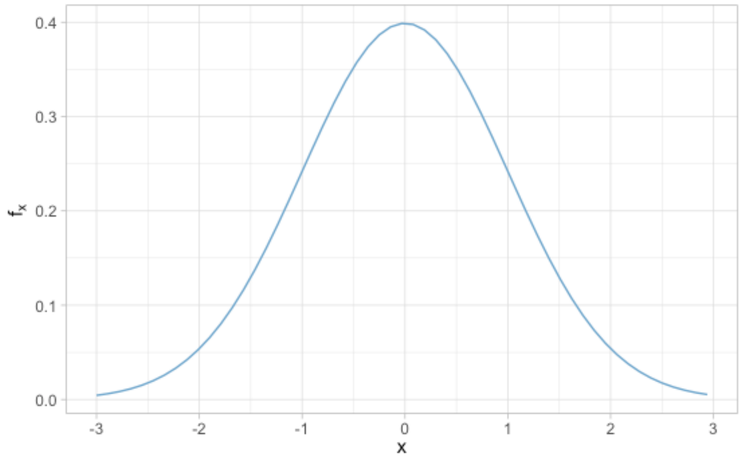

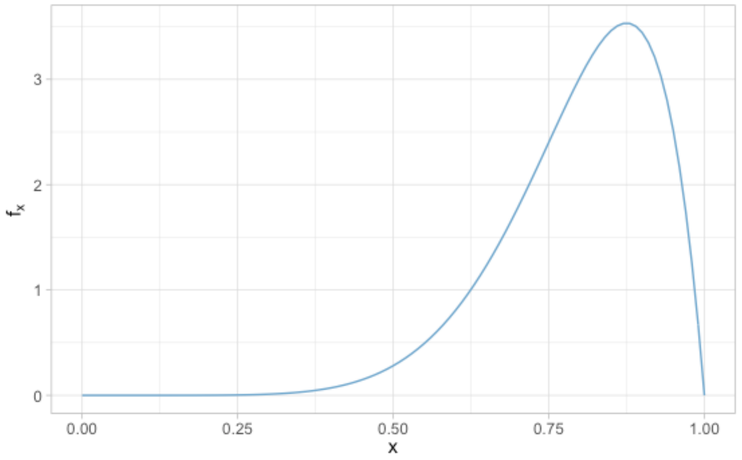

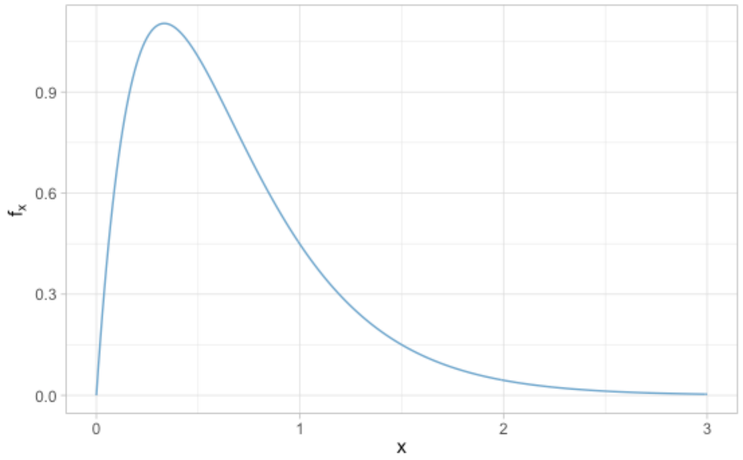

Medidas de correlación

- Miden el grado de efecto de una variable en otra :
  - **Coeficiente de Pearson**.
  - **Coeficiente ρ de Spearman**.
  - **Coeficiente τ de Kendall**.
- Se estudian a fondo en el curso de Modelos No Paramétricos y de Regresión

Representaciones gráficas

- Tabla de frecuencias
- Gráfica de barras
- Histograma
- Box plot
- Pie/dona
- Diagrama de dispersión
- Diagrama de correlación
- Diagrama de tallo y hojas
- ¡Muchas más!

Tabla de frecuencias

- Útiles para resumir la información de variables categóricas
- Para una muestra $x_1, \ldots, x_n$

  - Se encuentran los valores únicos $x_1^*, \ldots, x_k^*$
  - Se cuenta el número de veces que estos valores únicos ocurren (**frecuencias**) y se denotan por $f_1, \ldots, f_k$ de tal forma que $f_1 + \cdots + f_k = n$
  - Se calculan las **frecuencias relativas,** $f_i^* = f_i/n$, de tal forma que $f_1^* + \cdots + f_k^* = 1$
  - Se obtienen las **frecuencias acumuladas** como $F_i = f_1^* + \cdots + f_i^*$

- Las frecuencias (relativas) se utilizan para construir las gráficas de barras, de pie/dona

Gráficas de barras y pie/dona

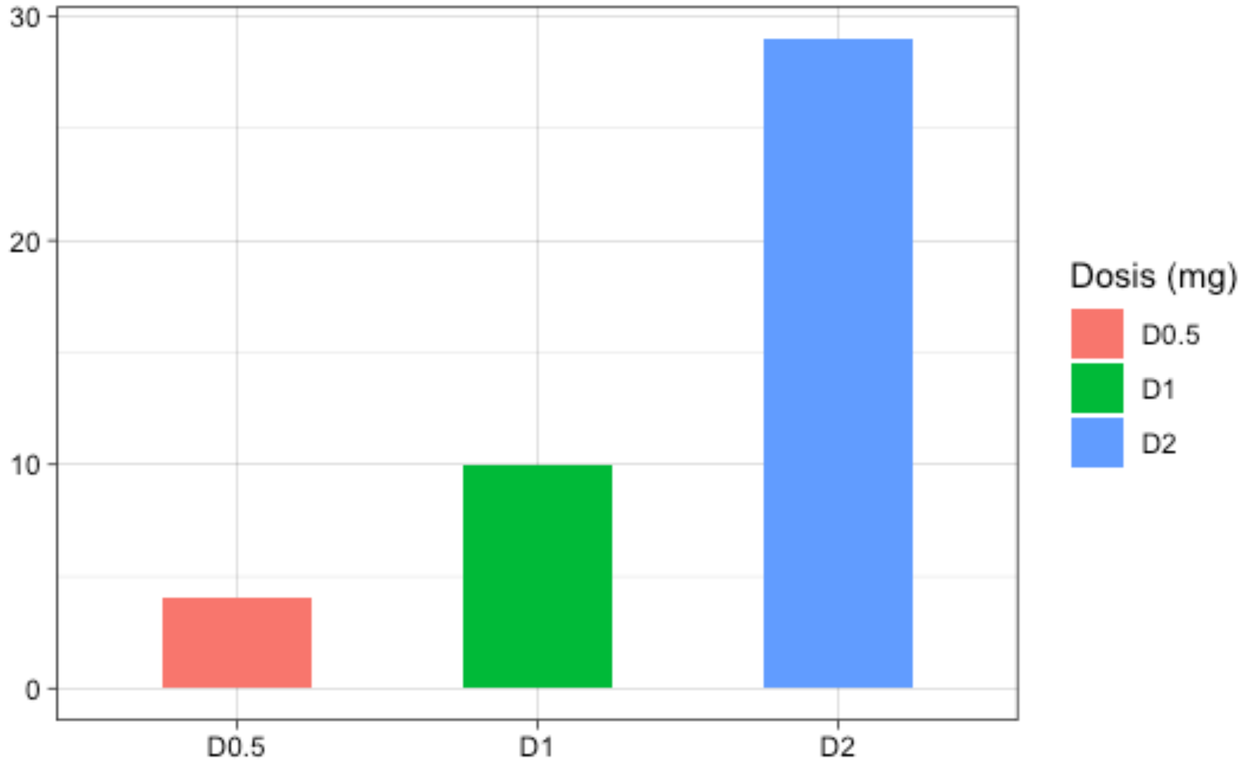

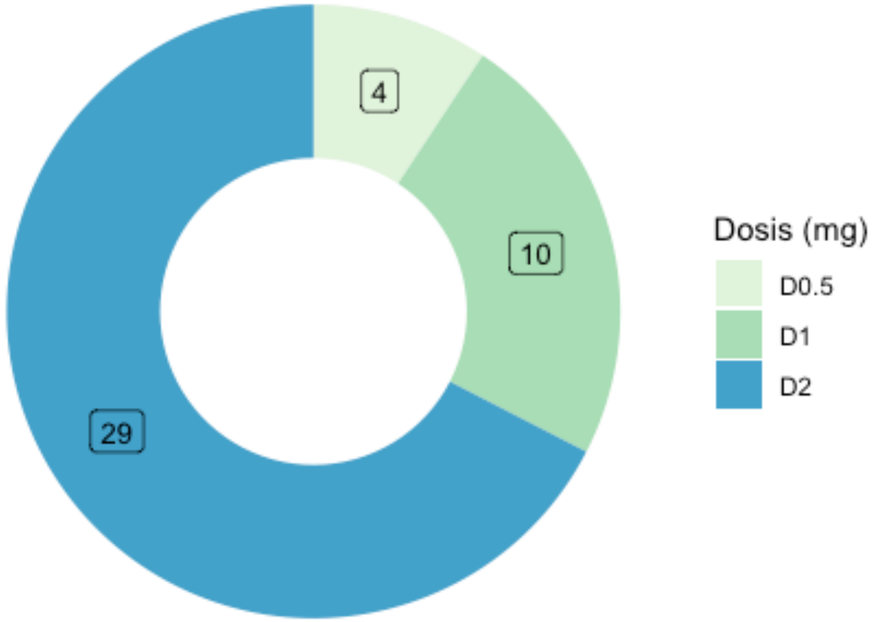

Tabla de frecuencias

- Para una muestra $x_1, \ldots, x_n$ de variables numéricas

  - Se genera una partición del soporte en m intervalos
  - Se cuenta el número de observaciones que caen en cada intervalo (**frecuencias**)
  - Se obtienen las **frecuencias relativas**
  - Se obtienen las **frecuencias acumuladas**

- Las frecuencias (relativas) se utilizan para construir histogramas

Histogramas

- Representación gráfica de la densidad empírica

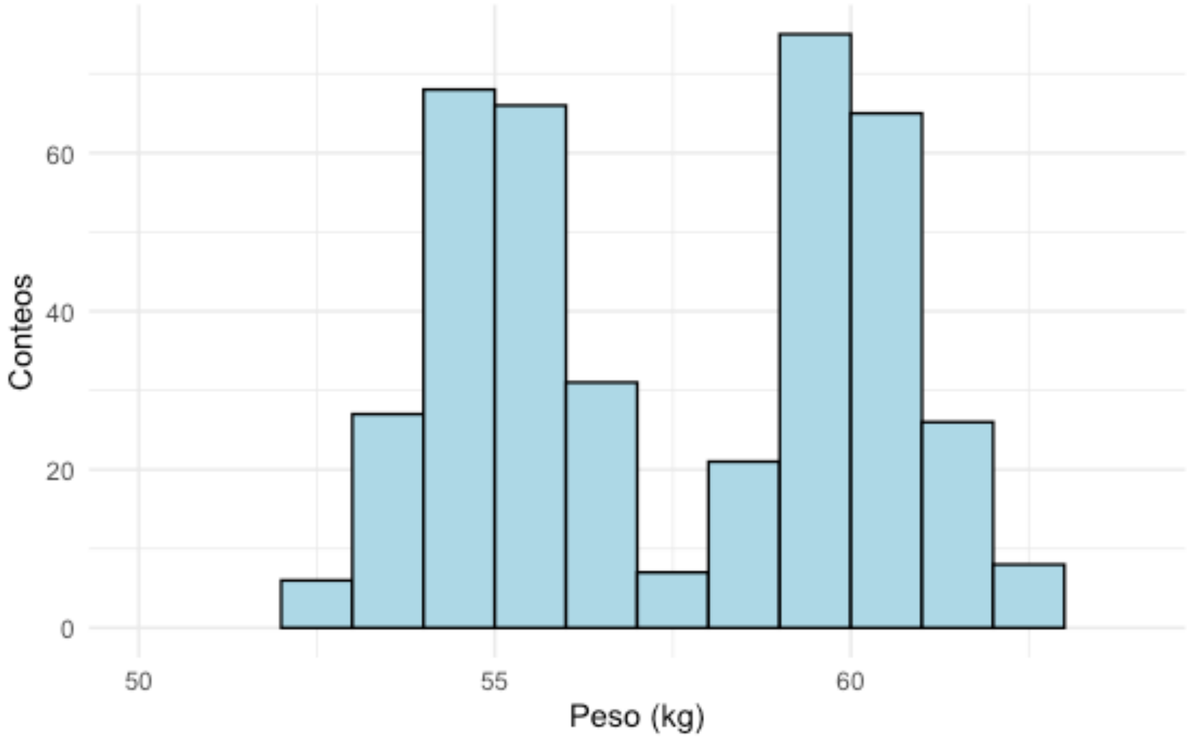

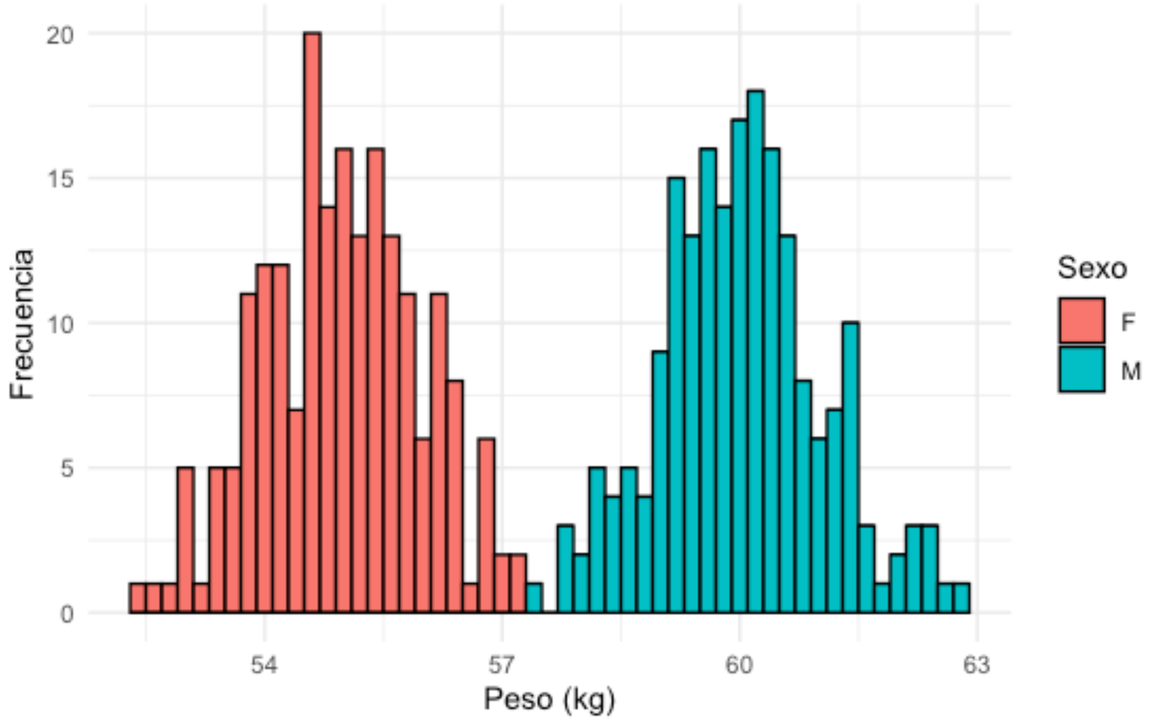

Histogramas

- Requiere una tabla de frecuencias utilizando intervalos en lugar de valores únicos

  - Obtener el rango de los datos
  - Seleccionar el número de clases M (e.g. $M = \sqrt{n}$ o $M = \log(n) + 1$)
  - Crear los intervalos y obtener las **frecuencias**
  - Obtener la **marca de clase** (punto medio del intervalo)
  - Crear una gráfica de barras con cada barra centrada en la marca de clase y altura dada por las frecuencias (absolutas o relativas)

Box plot

- Representación gráfica de los datos a partir de los cuartiles

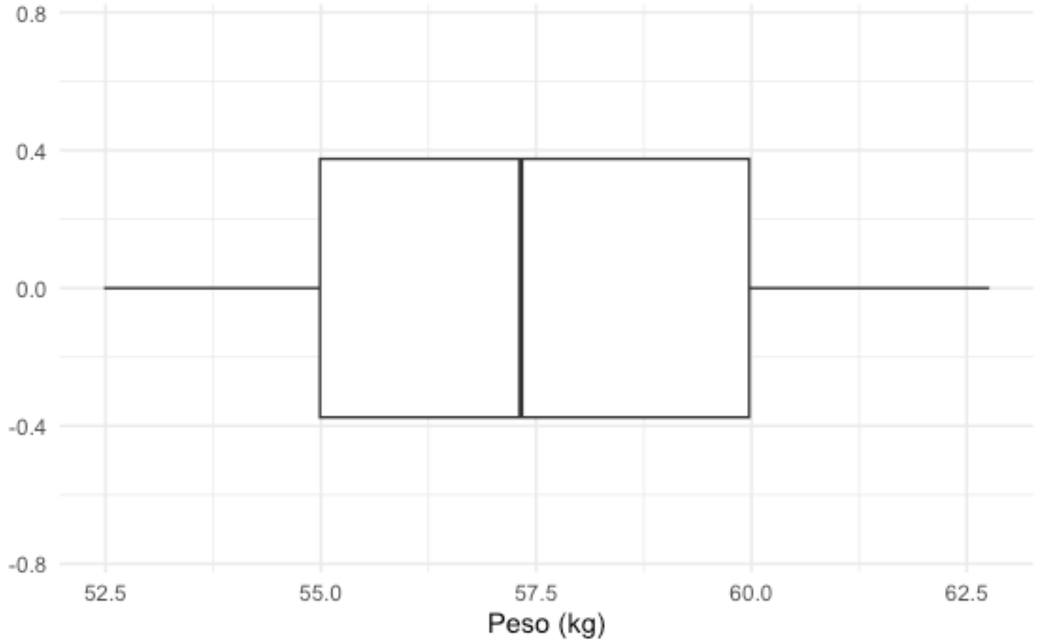

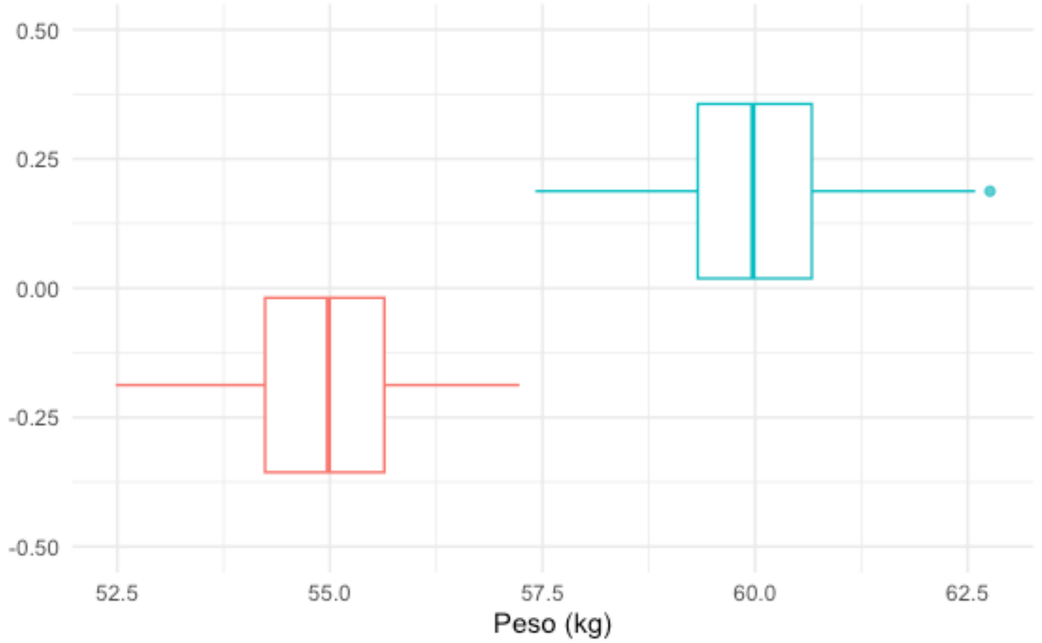

Box plot

- Muestra información del mínimo, máximo, mediana, de la simetría de la densidad así como de valores atípicos

  - Obtener los cuártiles y el rango intercuartílico
  - Dibujar una caja empezando por el primer cuartil y terminado en el tercer cuartil
  - Dibujar una recta horizontal (o vertical) dentro de la caja a la altura del segundo cuartil
  - Calcular el rango intercuartílico e identificar como valores atípicos aquellos valores que sean menores a $Q_1 = q_{.25} - 1.5 * \text{IQR}$ y mayores a $Q_2 = q_{.75} + 1.5 * \text{IQR}$
  - Dibujar una recta del primer cuartil a Q_1
  - Dibujar una recta del tercer cuartil a Q_2

Software

Lenguajes

IDE

Notebooks

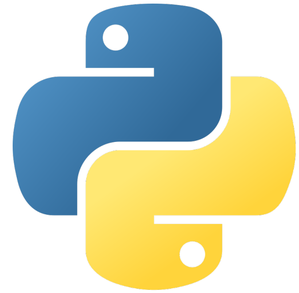

En este curso

Paqueterías:

- ggplot2
- dplyr
- plyr
- tidyverse
- etc.

Ejemplo: Salarios

- Base que contiene la información de 1171 personas laborando en algo relacionado con la ciencia de datos

  - *job_title* : Nombre de la posición
  - *job_type* : Tiempo completo o becario
  - *experience_level* : Nivel de experiencia
  - *location* : Ubicación del trabajo
  - *salary_currency* : Tipo de moneda
  - *salary* : Salario