

Modelos no paramétricos y de regresión

Tarea 3

Fecha de entrega: 22 de mayo

Instrucciones. La tarea se puede realizar en equipos de máximo 3 integrantes. Se entregará física (o digital) a la hora de la clase y no habrá prórroga. Las actividades de DataCamp son individuales y se podrán terminar hasta el final de la fecha de entrega y contarán como un punto extra sobre la tarea. En caso de no realizarlos habrá una penalización de un punto sobre la tarea. No se evaluará únicamente el resultado numérico, sino la calidad del razonamiento estadístico.

1. (1 punto) Considera el modelo de regresión simple dado por

$$y = \beta_0 + \beta_1 x + \epsilon,$$

donde $\mathbb{E}(\epsilon) = 0$ y $\text{Var}(\epsilon) = \sigma^2$. Realiza lo siguiente.

- (a) Obtén los estimadores de mínimos cuadrados $\hat{\beta}_0$ y $\hat{\beta}_1$.
- (b) Demuestra que $\hat{\beta}_0$ y $\hat{\beta}_1$ son insesgados y obtén sus varianzas.
- (c) Demuestra que $SS_{\text{Res}} = SS_{\text{T}} - \hat{\beta}_1 S_{xy}$, donde

$$S_{xy} = \sum_{i=1}^n y_i x_i - \frac{\sum_{i=1}^n x_i \sum_{i=1}^n y_i}{n}.$$

2. (0.8 puntos) Considera el modelo de regresión lineal múltiple dado por

$$\mathbf{y} = \mathbf{X}\beta + \epsilon,$$

donde $\mathbf{y}$ es un vector de tamaño n , β es el vector de coeficientes de la regresión (i.e. $\beta_0, \beta_1, \dots, \beta_p$), $\mathbf{X}$ es la matriz de diseño de dimensiones $n \times (p+1)$ y ϵ es el vector errores los cuales se suponen siguen una distribución $\mathcal{N}_n(\mathbf{0}, \sigma^2 \mathbf{I})$.

- (a) Encuentra el estimador máximo verosímil para β . ¿Cómo se distribuye $\hat{\beta}$?
3. (0.7 puntos) Considera la matriz sombrero definida como $\mathbf{H} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$.

- (a) Demuestra que $\mathbf{H}$ es simétrica e idempotente (i.e. $\mathbf{H}^2 = \mathbf{H}$).
- (b) Demuestra que $\mathbf{I} - \mathbf{H}$ también lo es.
4. (1 punto) El analista Michael Burry está interesado en entender la relación entre los años de experiencia y el salario percibido, con el objetivo de ajustar un modelo que permita predecir el salario que una persona debería percibir de acuerdo a sus años de experiencia. Para llevarlo a cabo se te proporciona la base de datos *salarios.txt*.
- (a) Ajusta un modelo de regresión simple e interprétalo.
- (b) Evalúa el ajuste del modelo y verifica los supuestos del modelo.
- (c) Construye un intervalo de confianza al 90, 95 y 99 % para la respuesta media.
5. (1 punto) La empresa Herederos del Marqués de Riscal quiere entender qué factores explican la calidad de algunos vinos Rioja. Para esto se han obtenido 38 mediciones acerca de la calidad, aroma, cuerpo, sabor y región de diferentes vinos, las cuales se pueden consultar en el archivo *calidadRioja.txt*.
- (a) Utilizando un procedimiento de selección de variables encuentra la variable (o variables) adecuadas para explicar la calidad de los vinos. Interpreta el modelo y verifica si los supuestos del modelo se cumplen.
- (b) Introduce ahora la variable de la región al modelo. ¿Cambian los coeficientes de la regresión? ¿Qué modelo elegirías y por qué?
6. (1.2 puntos) La automotriz VW quiere generar un modelo que permita predecir el rendimiento de la gasolina por kilómetro a partir de las siguientes 11 características de 32 automóviles (archivo *rendimientoGasolina.txt*) dadas por
- x_1 : cilindrada.
 - x_2 : caballos de fuerza.
 - x_3 : torsión.
 - x_4 : relación de compresión.
 - x_5 : relación de eje trasero.
 - x_6 : carburador.
 - x_7 : número de velocidades en la transmisión.
 - x_8 : longitud.
 - x_9 : ancho.
 - x_{10} : peso.

- x_{11} : tipo de transmisión (1 = automático, 0 = manual).

Realiza lo siguiente.

- Ajusta un modelo de regresión lineal simple que relacione el rendimiento de la gasolina y la cilindrada. Evalúa e interpreta el modelo. ¿Se cumplen los supuestos de la regresión?
 - Determina un intervalo de confianza al 95% para la predicción del rendimiento de la gasolina si se tiene una cilindrada de 275.
 - Ahora realiza un procedimiento de selección de variables para encontrar la variable (o variables) adecuadas. Ajuste el modelo y verifica si los supuestos se cumplen. ¿El modelo mejora los resultados vistos anteriormente?
7. (0.5 puntos) Una empresa de gas natural del gobierno está interesada en explicar el dióxido de carbono generado en los procesos de licuefacción. Para esto se te ha otorgado acceso a la base *licuefacción.txt*, la cual contiene 27 mediciones y las siguientes 8 variables:

- $y = CO_2$.
- x_1 = tiempo (en min).
- x_2 = temperatura (en grados Celsius).
- x_3 = porcentaje de solvatación.
- x_4 = aceite.
- x_5 = carbón.
- x_6 = solvente.
- x_7 = consumo de hidrógeno.

Ajusta un modelo de regresión múltiple con todas las variables y verifica si existen problemas de multicolinealidad utilizando la matriz de correlación y los factores de inflación de la varianza.

8. (0.8 puntos) Considere la base *regPol.txt*, la cual contiene mediciones de una variable respuesta y una única variable regresora. El objetivo es ajustar un modelo de regresión polinomial, para lo cual puedes realizar lo siguiente:
- Ajusta un modelo de regresión lineal simple y grafica la recta resultante, ¿consideras que es un buen modelo?
 - Ahora analiza el supuesto de varianza constante, ¿puedes observar algún patrón en la gráfica de residuales contra valores ajustados?
 - Ajusta un modelo de regresión polinomial de orden 2 y repite el análisis realizado en el inciso anterior. ¿Consideras que este es un mejor modelo? ¿Se puede mejorar?

- (d) Finalmente, ajusta un modelo de regresión polinomial de orden 3 y analízalo. ¿Con qué modelo te quedarías?
9. (1.5 puntos) La empresa encargada de los sensores de ácido láctico te ha encargado estudiar la base *mediciones.txt*.
- (a) Ajusta un modelo de regresión lineal simple y evalúalo.
 - (b) ¿Se cumplen todos los supuestos de la regresión? Si no es el caso, encuentra una transformación adecuada y ajusta un nuevo modelo de regresión.
 - (c) Construye los intervalos de confianza para la respuesta media y para la predicción al 95% de confianza.
10. (1.5 puntos) La CFE está interesada en estudiar el consumo de electricidad en un barrio de la Ciudad de México. Considere la base *ConsumoEnergia.csv*, la cual contiene información de 100 edificios diferentes en dicho barrio, así como la temperatura promedio registrada al momento de capturar el consumo de energía.
- (a) Ajusta un modelo de regresión simple para cada una de las variables continuas por separado. ¿Hay algún modelo significativo? ¿Qué puedes decir del ajuste en los modelos que son significativos? ¿Te quedarías con alguno en particular?
 - (b) Ahora construye un modelo de regresión múltiple con todas las variables continuas y ajústalo en el caso de encontrar variables que no sean significativas. ¿Qué puedes decir del ajuste de dicho modelo y cómo se compara con los del inciso anterior? ¿Se cumplen los supuestos de la regresión?
 - (c) Finalmente, al modelo de regresión múltiple que hayas construido en el inciso anterior añádele la información del tipo de edificio. ¿Qué puedes decir ahora del modelo? Interpretalo y obtén una conclusión para la CFE.

Actividades de DataCamp

1. Data Communication Concepts
2. Intermediate Regression