

# Análisis Descriptivo de Datos Multivariados



José Antonio Perusquía Cortés  
Análisis Multivariado Semestre 2025-II



¿Qué es el análisis multivariado?

&

¿Qué tipo de datos nos interesan?

# Introducción

- El estudio de “muchas” variables **correlacionadas**
- Se considera que se tiene un vector aleatorio  $\mathbf{x} = (x_1, \dots, x_p)$  y se registran  $n$  realizaciones

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{pmatrix}$$

- Otras notaciones

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1^T \\ \mathbf{x}_2^T \\ \vdots \\ \mathbf{x}_n^T \end{pmatrix}$$

$$\mathbf{X} = (\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \dots, \mathbf{x}^{(p)})$$

# Introducción

- (Algunos) problemas de interés
  - Graficar/describir la estructura de los datos
  - Selección de variables
  - Aprendizaje supervisado, semi-supervisado y no supervisado
  - Analizar correlación entre variables
- Retos
  - Muchas observaciones y muchas variables ( $n \gg 1, p \gg 1$ )
  - Más variables que observaciones ( $p > n$ )

# Ánalysis descriptivo multivariado

# Análisis descriptivo

- Medidas numéricas

- Media muestral
- Varianza/covarianza muestral
- Curtosis y coeficiente de asimetría

- Gráficas

- Diagramas de dispersión/correlación
- Gráfica de estrellas
- Caras de Chernoff
- Curvas de Andrews

# Estadísticas descriptivas

# Media muestral

- Para la matriz  $\mathbf{X}$  podemos obtener la media muestral para cada variable  $\mathbf{x}^{(j)}$

$$\bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_{ij}$$

- Así el vector de medias muestrales queda definido como

$$\bar{\mathbf{x}} = (\bar{x}_1, \dots, \bar{x}_p)$$

- Formalmente, se define al vector de medias como

$$\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}^{(i)}$$



# Media muestral

## Proposición

Sea  $\mathbf{X}$  una matriz de datos entonces la media muestral se puede calcular como

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^T \mathbf{1}_n,$$

donde  $\mathbf{1}_n \equiv (1, 1, \dots, 1)^T$ .

## Observaciones

- $\mathbf{1}_n^T \mathbf{1}_n = n$

- $\mathbf{1}_n \mathbf{1}_p^T = \mathbf{J}_{n \times p}$

# Media muestral

En **R** existen muchas formas de obtener el vector de medias como:

- `summary()`
- `apply()`
- `colMeans()`
- `by()`: para la media muestral por grupos

# Varianza y covarianza muestral

- Varianza muestral de cada variable  $\mathbf{x}^{(j)}$

$$s_j^2 = s_{jj} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2$$

- Covarianza muestral entre  $\mathbf{x}^{(j)}$  y  $\mathbf{x}^{(k)}$

$$s_{jk} = \frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k)$$

- Y así, la matriz de covarianzas muestral

$$\mathbf{S} = \begin{pmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{pmatrix}$$

# Varianza y covarianza muestral

- Formalmente, se define a la matriz **S** como

$$\mathbf{S} = \frac{1}{n - 1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T$$

- Considerando  $\mathbf{w}_i = \mathbf{x}_i - \bar{\mathbf{x}}$

$$\mathbf{S} = \frac{1}{n - 1} \sum_{i=1}^n \mathbf{w}_i \mathbf{w}_i^T$$

- Podemos pensar a  $\mathbf{w}_i$  como observaciones de una “nueva” matriz de datos **W**

# Varianza y covarianza muestral

## Observación

$$\begin{aligned}\mathbf{W} &= \mathbf{X} - \begin{pmatrix} \bar{\mathbf{x}}^T \\ \bar{\mathbf{x}}^T \\ \vdots \\ \bar{\mathbf{x}}^T \end{pmatrix} \\ &= \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^T \\ &= \mathbf{X} - \mathbf{1}_n \left[ \frac{1}{n} \mathbf{X}^T \mathbf{1}_n \right]^T \\ &= \mathbf{X} - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T \mathbf{X} \\ &= \left( \mathbf{I}_{n \times n} - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T \right) \mathbf{X} \\ &= \mathbf{H}_n \mathbf{X}\end{aligned}$$

# Varianza y covarianza muestral

## Definición

A la matriz  $\mathbf{H}_n$  se le conoce como **matriz de centrado**

## Proposición (tarea)

- i.  $\mathbf{H}_n$  es simétrica
- ii.  $\mathbf{H}_n$  es idempotente
- iii.  $\mathbf{W} = \mathbf{H}_n \mathbf{X}$  tiene como media muestral al vector de ceros
- iv.  $\mathbf{S} = \frac{1}{n-1} \mathbf{X}^T \mathbf{H}_n \mathbf{X}$

# Varianza y covarianza muestral

## Proposición (tarea)

Sea  $\mathbf{B}$  una matriz cuadrada tal que  $\mathbf{B} = \mathbf{A}^T \mathbf{A}$ , donde  $\mathbf{A}_{n \times p}$  entonces

- i.  $\mathbf{B}$  es simétrica
- ii.  $\mathbf{B}$  es semidefinida positiva, i.e.,  $\forall \alpha \in \mathbb{R}^p$  se cumple  $\alpha^T \mathbf{B} \alpha \geq 0$

## Proposición (tarea)

La matriz de covarianza muestral  $\mathbf{S}$  es semidefinida positiva

# Varianza y covarianza muestral

En **R** existen varias formas de encontrar la matriz de covarianzas muestral

- `var()`
- `cov()`
- `sweep()`: para construir la matriz **W**
- `by()`: para la matriz de covarianza muestral por grupos



# Correlación muestral

- La correlación entre  $\mathbf{x}^{(j)}$  y  $\mathbf{x}^{(k)}$

$$r_{jk} = \frac{s_{jk}}{s_j s_k}, \quad s_j = \sqrt{s_{jj}}$$

- La matriz de correlación dada por

$$\mathbf{R} = \begin{pmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{pmatrix}$$

# Correlación muestral

- Otra representación útil está dada por  $\mathbf{R} = \mathbf{D}^{-1}\mathbf{S}\mathbf{D}^{-1}$ , donde

$$\mathbf{D} = \begin{pmatrix} s_1 & 0 & \cdots & 0 \\ 0 & s_2 & \cdots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \cdots & s_p \end{pmatrix}$$

## Proposición (tarea)

Sea  $\mathbf{R}$  la matriz de correlación muestral entonces

- i.  $\mathbf{R}$  es simétrica.
- ii.  $\mathbf{R}$  es semidefinida positiva.

# Correlación muestral

En **R** se puede calcular como

- `cor()`
- `by()` - para la correlación muestral por grupos

# Propiedades de los estimadores

## Proposición

Suponer que se tienen  $n$  observaciones independientes de un vector aleatorio  $\mathbf{x}$  tal que

$\mathbb{E}(\mathbf{x}) = \mu$  y  $\text{Var}(\mathbf{x}) = \Sigma$  entonces

i.  $\mathbb{E}(\bar{\mathbf{x}}) = \mu$

ii.  $\text{Var}(\bar{\mathbf{x}}) = \frac{1}{n}\Sigma$

iii.  $\bar{\mathbf{x}}$  es consistente, esto es,  $\mathbb{P}(\|\bar{\mathbf{x}} - \mu\| < \epsilon) \rightarrow 1$  para todo  $\epsilon > 0$

iv.  $\mathbb{E}(\mathbf{S}) = \Sigma$

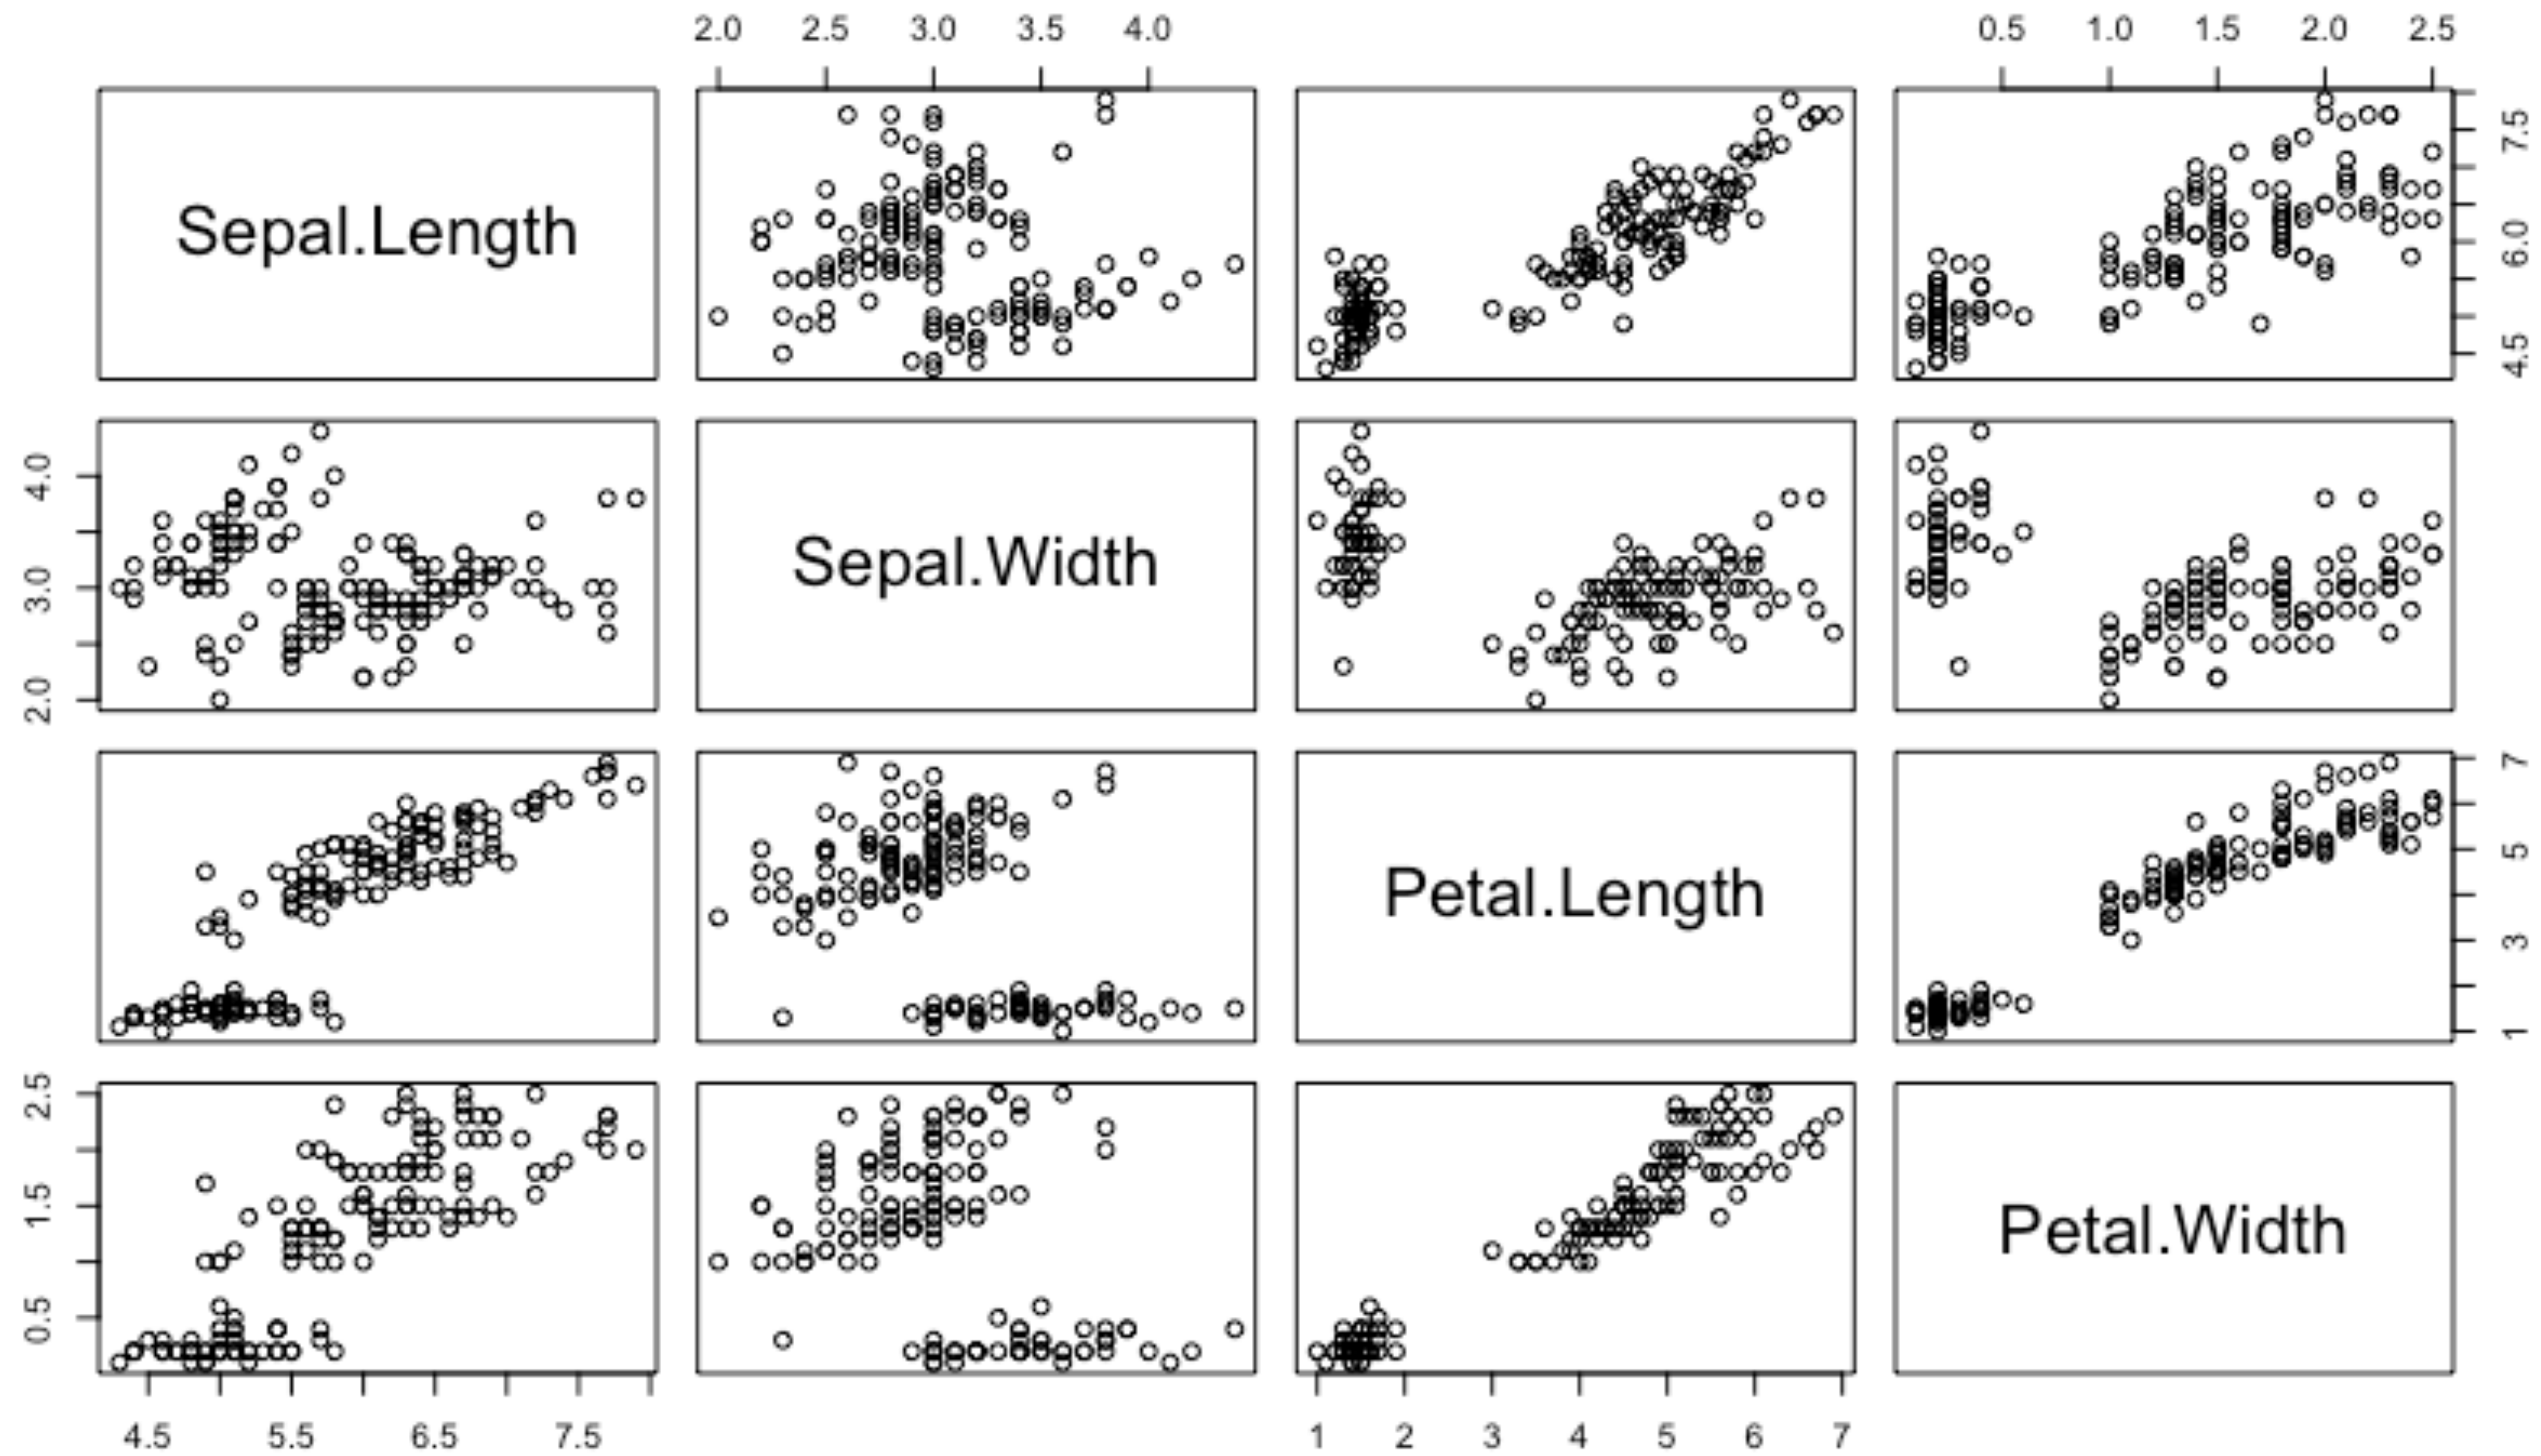
Gráficas

# Gráficas de dispersión y correlación

# Diagrama de dispersión

- Graficar todas las variables contra todas las variables
- Útil para:
  - Observar la relación por pares entre las variables
  - Identificar el tipo de correlación por pares entre ellas
- Desventajas:
  - Solo se puede analizar a las variables por pares
  - Muy difícil de graficar/analizar si se tienen muchas variables

# Diagrama de dispersión







# Diagrama de correlación

- Graficar la correlación por pares de las variables
- Útil para:
  - Identificar el tipo y el grado de correlación por pares entre ellas
- Desventajas:
  - Solo se puede analizar a las variables por pares
  - Muy difícil de graficar/analizar si se tienen muchas variables
- En R:
  - Librería: **corrplot**


# Diagrama de correlación




# Diagrama de dispersión con datos agrupados




# Diagrama de correlación con datos agrupados



Setosa



Versicolor

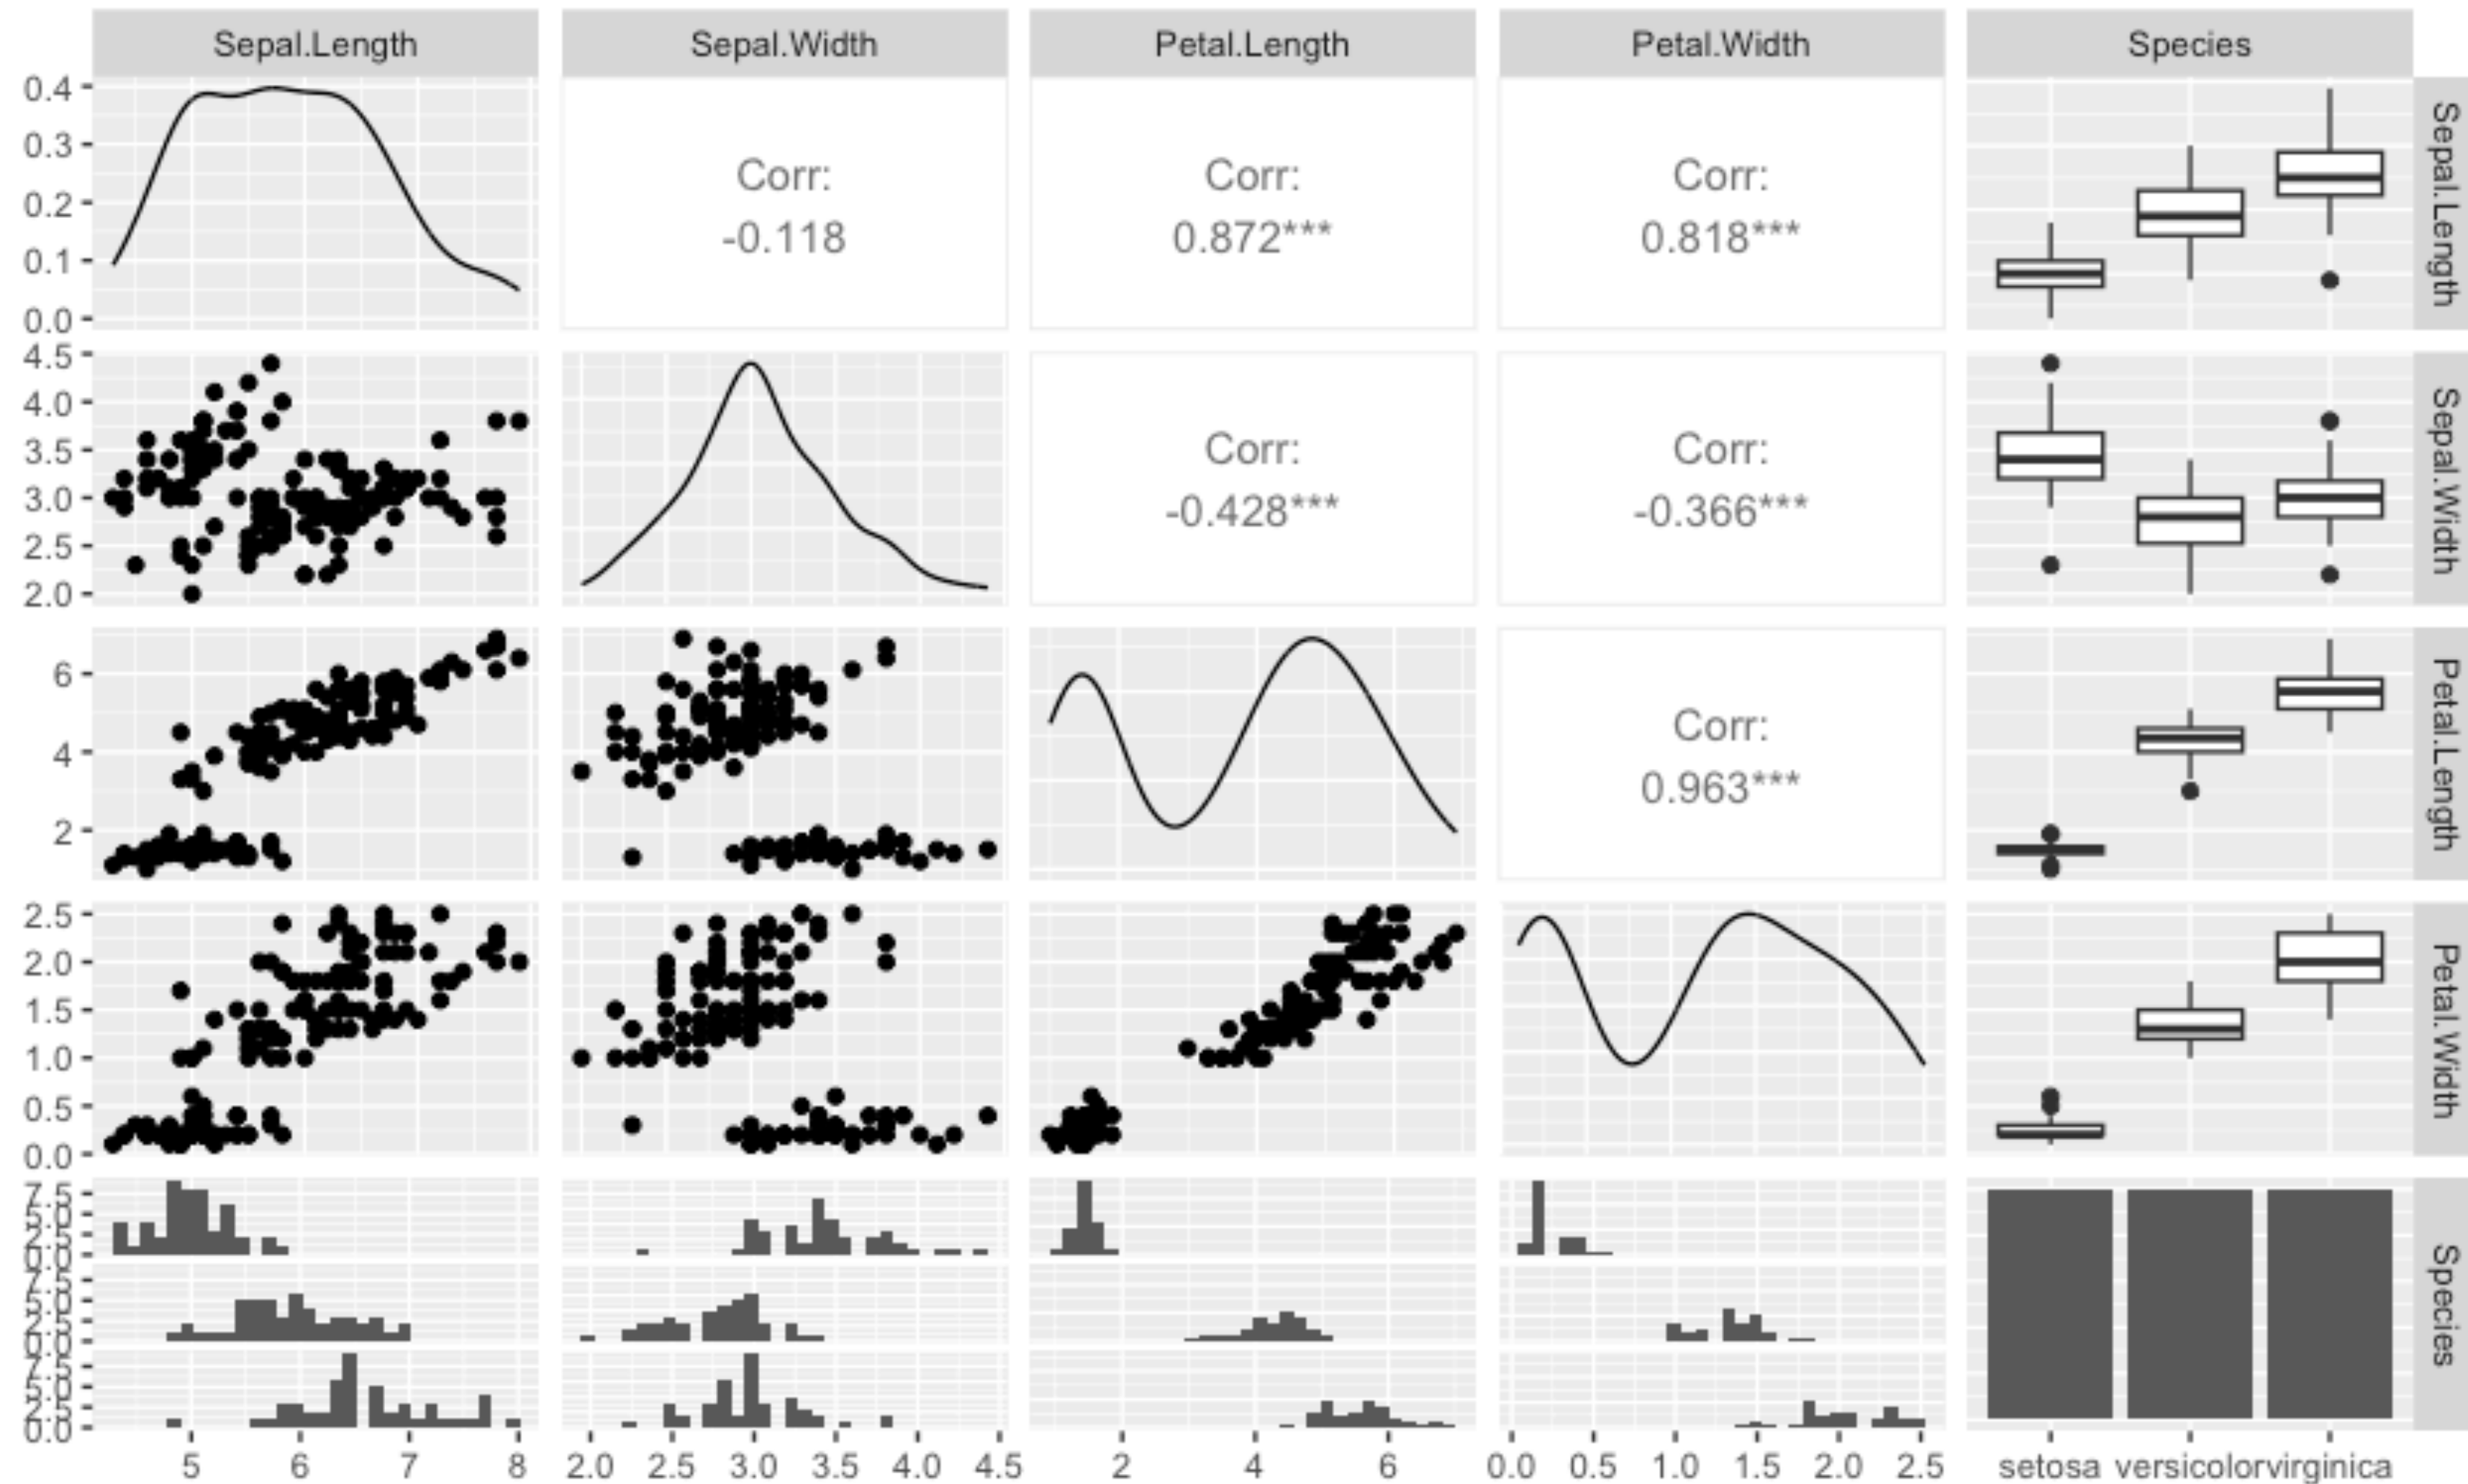


Virginica

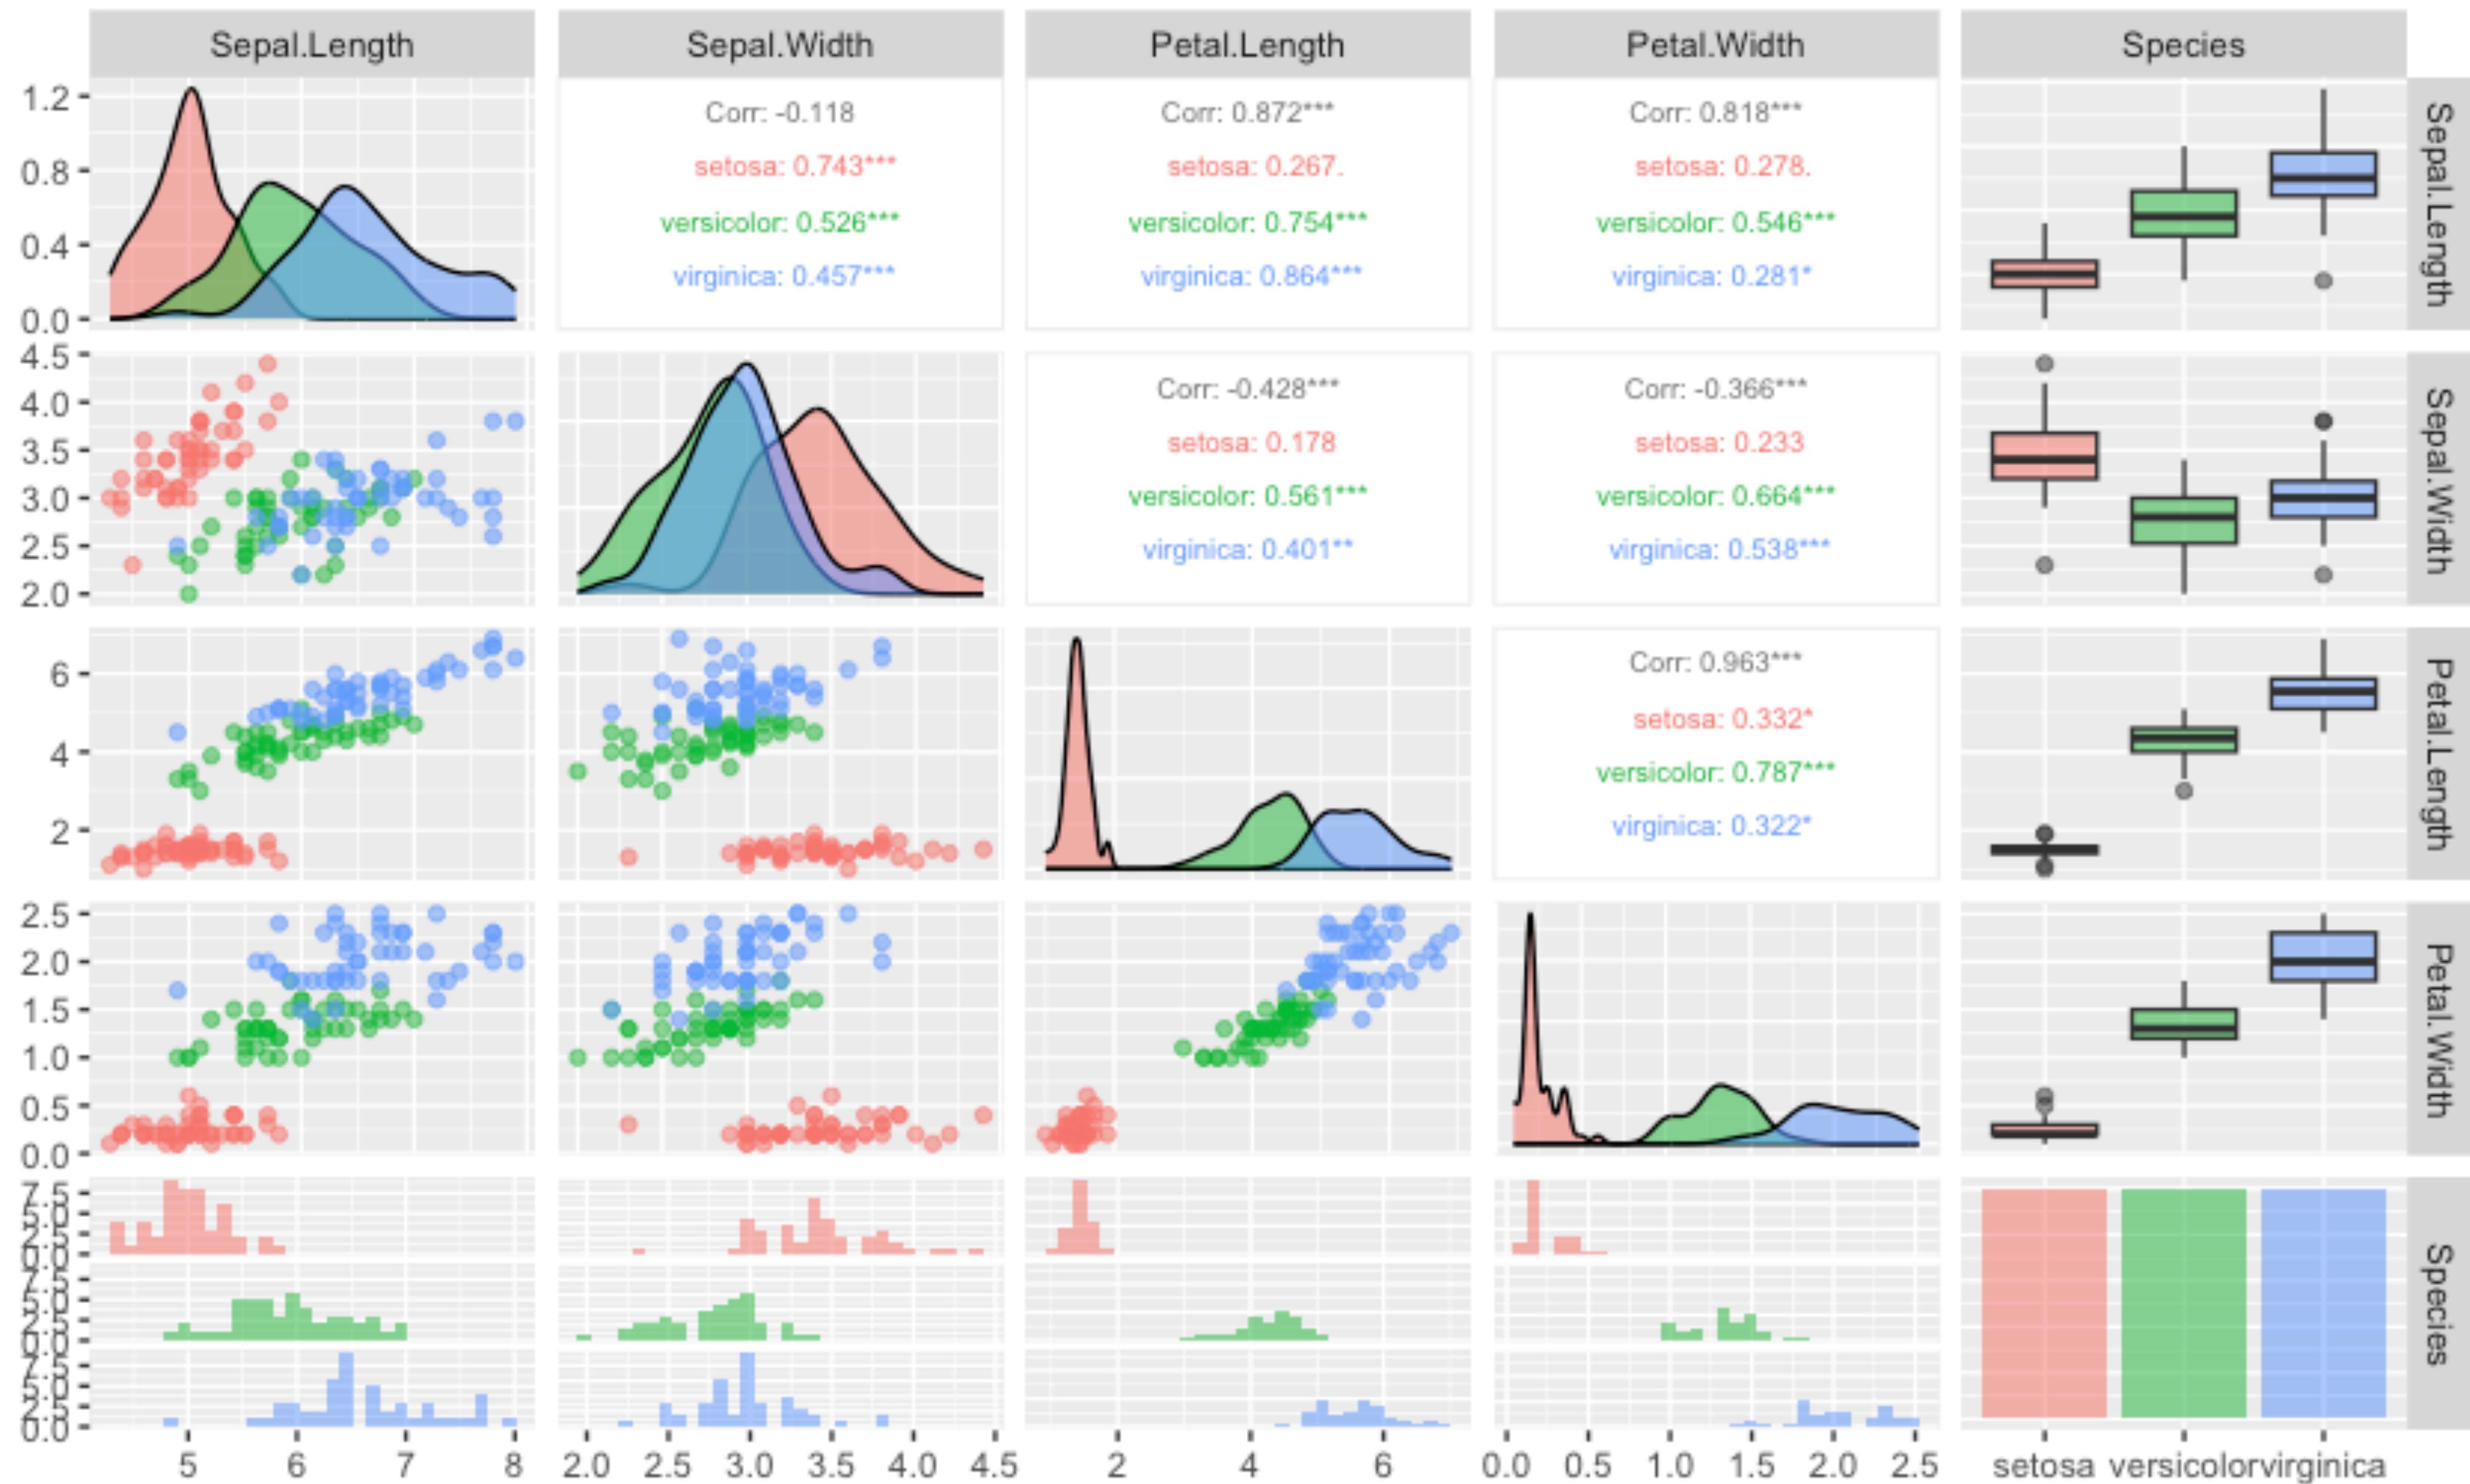


# Diagrama de dispersión II

- Librería GGally (ggplot2)



# Diagrama de dispersión para datos agrupados II




Estrellas

# Estrellas


- Técnica para graficar datos multivariados en 2D (escalados a  $[0,1]$ )
- Se forma una “estrella” con  $p$  picos por cada una de las  $n$  observaciones
- Útil para:
  - Identificar clusters, outliers y variables “importantes”
- Desventajas:
  - Complicado de analizar si hay muchas observaciones y/o muchas variables



# Estrellas



# Estrellas



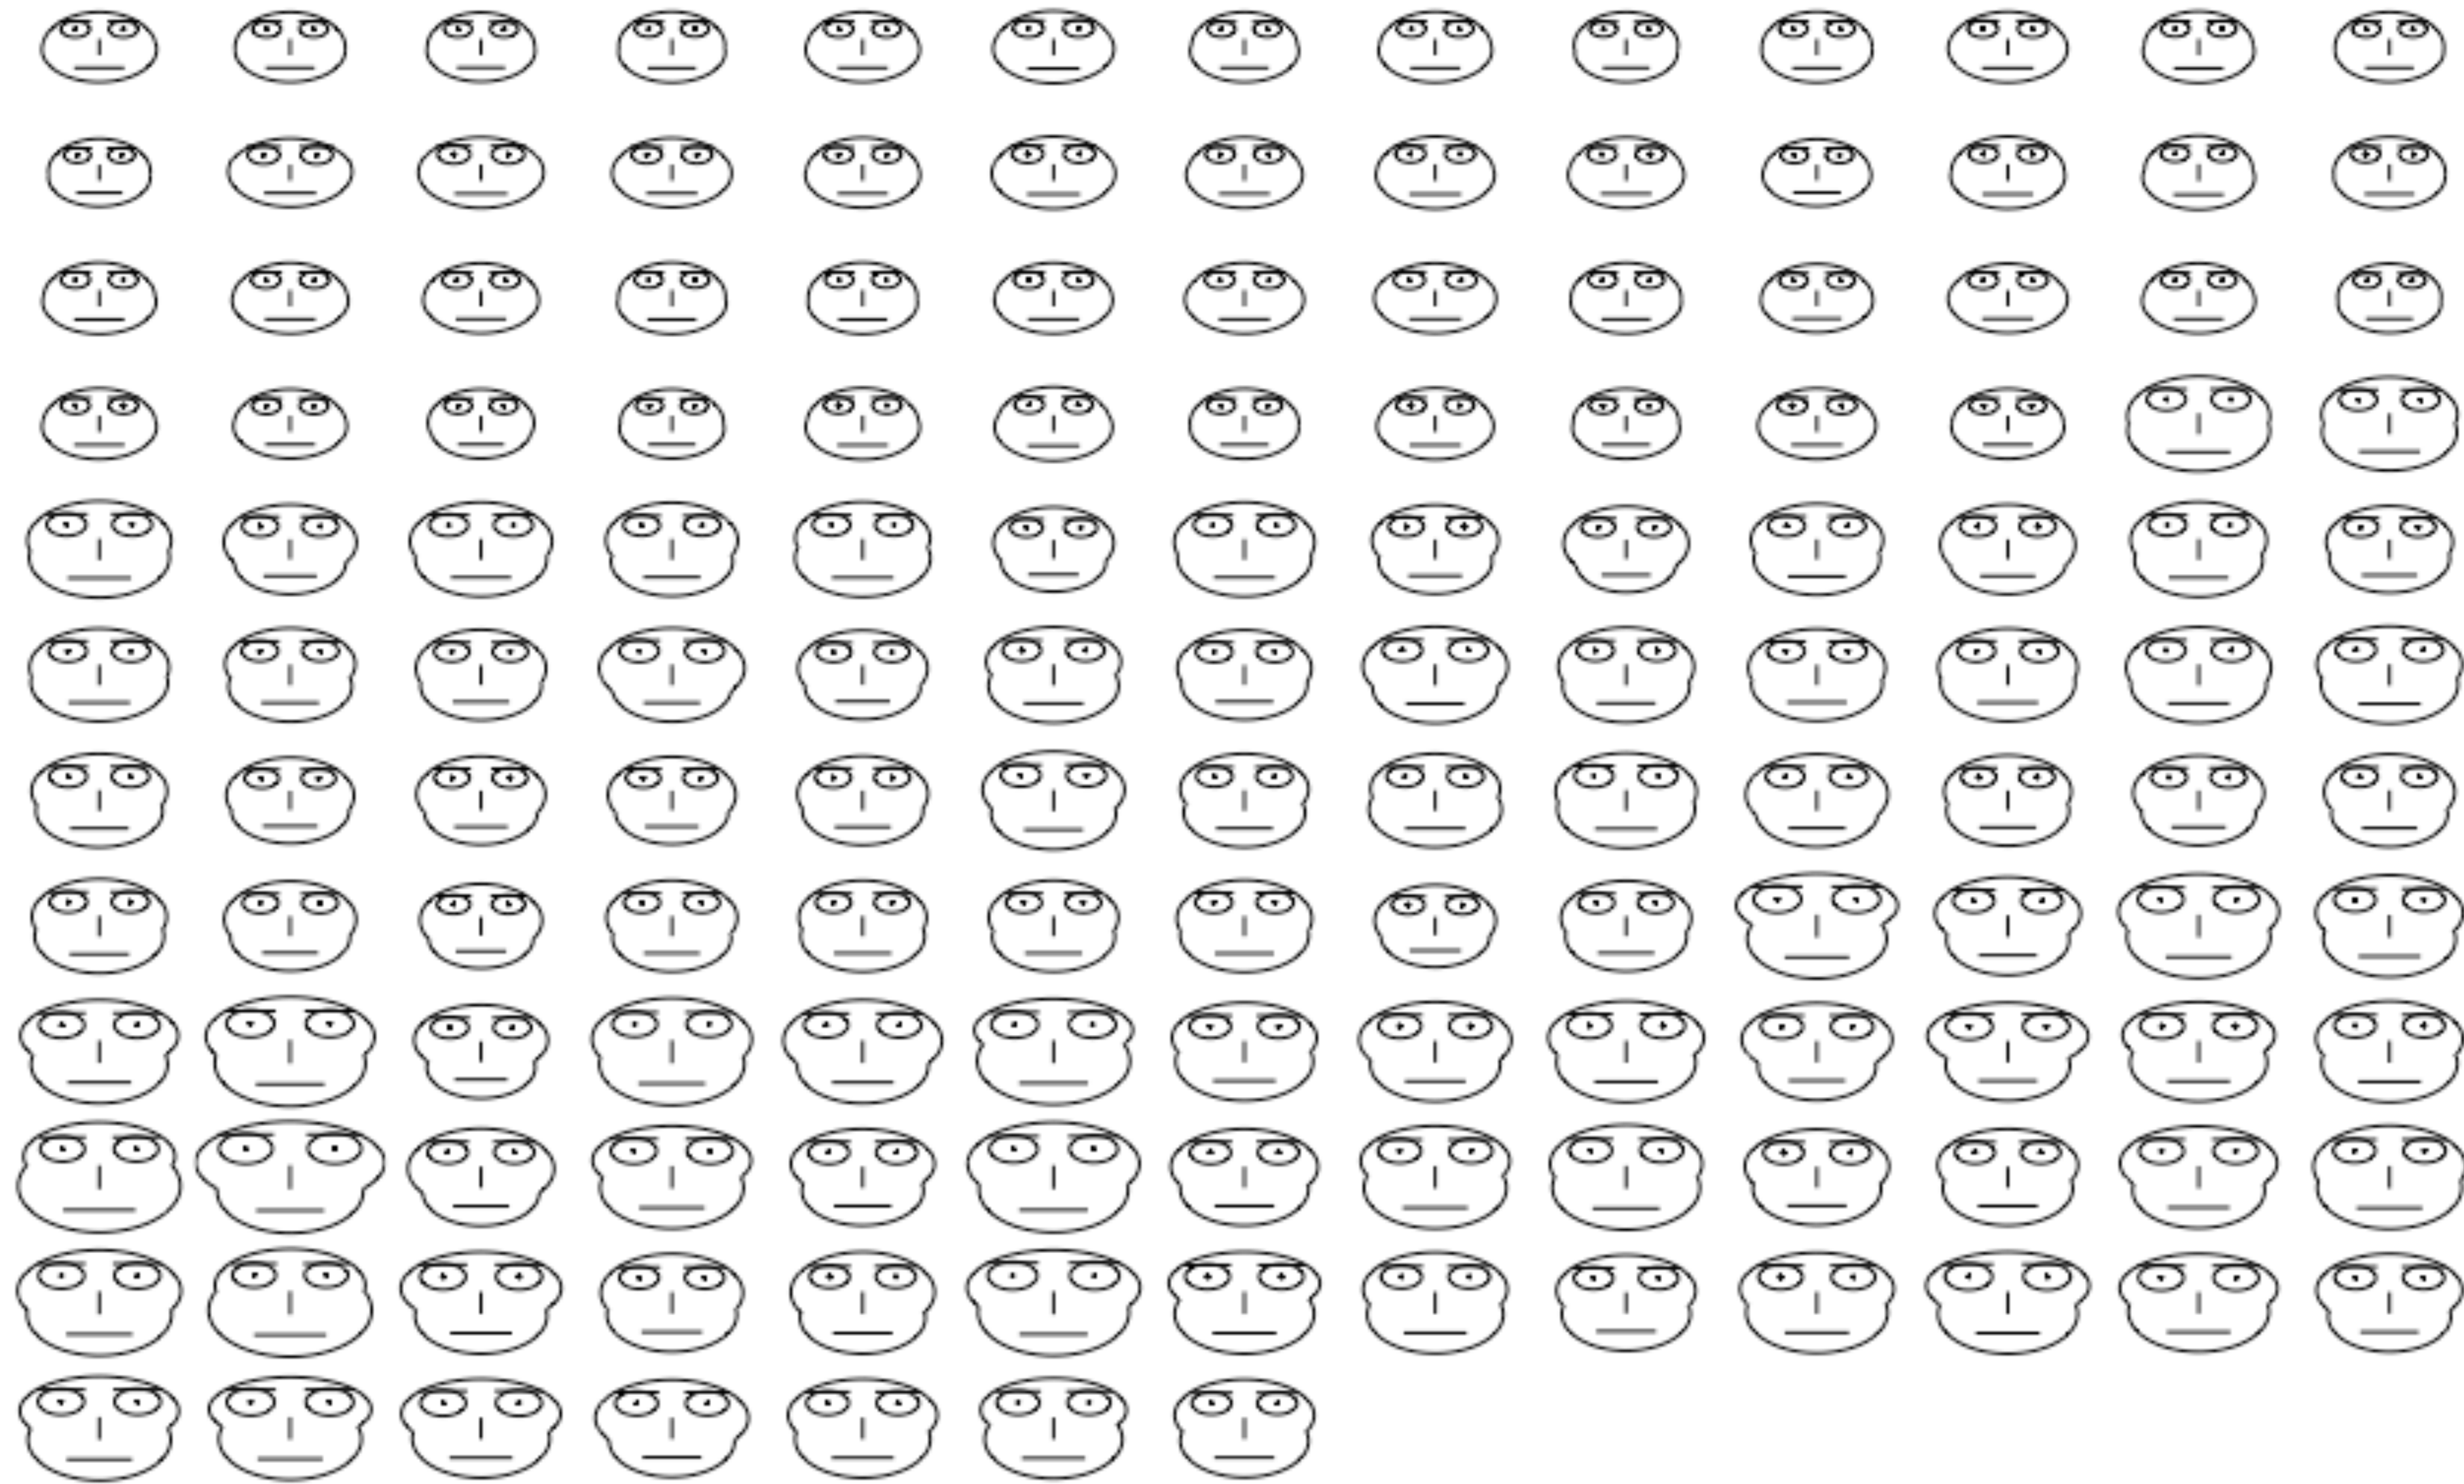
# Caras de Chernoff

# Caras de Chernoff

- Técnica similar a las estrellas para graficar datos multivariados (escalados a  $[0,1]$ )
- Desarrollado por Chernoff, Herman (1973). **The use of Faces to Represent Points in K-Dimensional Space Graphically**
- Útil para:
  - Identificar rápidamente clusters, outliers y variables importantes
- Desventajas:
  - Limitado a  $p \leq 18$
  - El orden de las variables importa
- En R: Librería TeachingDemos




# Caras de Chernoff






# Caras de Chernoff





# Caras de Chernoff

- Si se cambia el orden de las variables las caras cambian



# Curvas de Andrews



# Curvas de Andrews

- Transformación para graficar datos multivariados en el plano cartesiano (o coordenadas polares)
- Desarrollado por Andrews, D.F. (1972). **Plots of High-Dimensional Data.**
- Cada punto  $\mathbf{x} = (x_1, \dots, x_p)$  es mapeado a

$$f_{\mathbf{x}}(t) = \frac{x_1}{\sqrt{2}} + x_2 \sin(t) + x_3 \cos(t) + x_4 \sin(2t) + x_5 \cos(2t) + \dots, \quad -\pi < t < \pi$$

- (Algunas) Propiedades útiles:

Preserva medias, i.e.,

$$f_{\bar{\mathbf{x}}}(t) = \frac{1}{n} \sum_{i=1}^n f_{x_i}(t)$$

Preserva distancias, i.e.,

$$||f_{\mathbf{x}}(t) - f_{\mathbf{y}}(t)||_{L_2} = \int_{-\pi}^{\pi} [f_{\mathbf{x}}(t) - f_{\mathbf{y}}(t)]^2 dt = \pi ||\mathbf{x} - \mathbf{y}||^2$$

# Curvas de Andrews


## -Ventajas

- No hay restricciones en el número de variables ni de observaciones.
- Detección de outliers y clusters
- No requiere datos escalados

## -Desventajas

- El orden de las variables importa
- Mayor peso a las primeras variables.


# Curvas de Andrews





# Curvas de Andrews

- Las curvas cambian si el orden de las variables cambia



# Curvas de Andrews

-Otros posibles mapeos

▸ Andrews, 1972

$$f_{\mathbf{x}}(t) = x_1 \sin(n_1 t) + x_2 \cos(n_1 t) + x_3 \sin(n_2 t) + x_4 \cos(n_2 t) + \cdots, \quad n_i \in \mathbb{N}, \quad -\pi \leq t \leq \pi$$

$$f_{\mathbf{x}}(t) = x_1 \sin(2t) + x_2 \cos(2t) + x_3 \sin(4t) + x_4 \cos(4t) + \cdots, \quad 0 \leq t \leq \pi$$


▸ Khattree, R. & Naik, D. (2002). **Andrews plots for multivariate data: some new suggestions and applications.** Para  $-\pi \leq t \leq \pi$

$$f_{\mathbf{x}}(t) = \frac{1}{\sqrt{2}} \left[ x_1 + x_2(\sin(t) + \cos(t)) + x_3(\sin(t) - \cos(t)) + x_4(\sin(2t) + \cos(2t)) + \dots \right]$$

-En R: Librería **pracma** implementa la función definida por Khattree pero con  $0 \leq t \leq 2\pi$

# Curvas de Andrews (librería pracma)

Andrews' Curves



Andrews' Curves

