

Análisis de Factores (FA)



José A. Perusquía Cortés
Análisis Multivariado, Semestre 2025-II



Motivación

- El análisis de factores es un modelo matemático que busca:

Explicar la correlación de un conjunto de p variables a través de k factores latentes.

- Orígenes en psicología:

Spearman (1904). “*General-Intelligence,” Objectively Determined and Measured.* *American Journal of Psychology*. **15** (2): 201–293.

Thurstone (1931). Multiple factor analysis. *Psychological Review*. **38** (5): 406–427.

Thurstone (1934). The Vectors of Mind. *The Psychological Review*. **41**: 1–32.

Formulación

- Sea $\mathbf{x}_{p \times 1}$ un vector aleatorio con $\mathbb{E}(\mathbf{x}) = \boldsymbol{\mu}$ y $\text{Var}(\mathbf{x}) = \boldsymbol{\Sigma}$ entonces,

$$\mathbf{x} = \boldsymbol{\Lambda} \mathbf{f} + \mathbf{u} + \boldsymbol{\mu}$$

Donde

1. $\boldsymbol{\Lambda}_{p \times k}$ es una matriz de constantes
 2. $\mathbf{f}_{k \times 1}$ es un vector aleatorio de factores comunes
 3. $\mathbf{u}_{p \times 1}$ es un vector aleatorio de factores únicos
- Así, para cada variable se tiene la representación

$$x_i = \sum_{j=1}^k \lambda_{ij} f_j + u_i + \mu_i$$

Formulación

► Supuestos

1. $\mathbb{E}(\mathbf{f}) = \mathbf{0}$

2. $\text{Var}(\mathbf{f}) = \mathbf{I}$

3. $\mathbb{E}(\mathbf{u}) = \mathbf{0}$

4. $\text{Var}(\mathbf{u}) = \Psi = \text{diag} \left(\Psi_{11}, \dots, \Psi_{pp} \right)$

5. $\text{Cov}(\mathbf{f}, \mathbf{u}) = \mathbf{0}$

Propiedades

Proposición 1

Dado el modelo de análisis de factores, se tiene que la varianza de cada x_i es

$$\text{Var} (x_i) = \sum_{j=1}^k \lambda_{ij}^2 + \Psi_{ii} = h_i^2 + \Psi_{ii},$$

y la covarianza de x_i y x_l es

$$\text{Cov} (x_i, x_l) = \sum_{j=1}^k \lambda_{ij} \lambda_{jl}.$$

Por lo que, $\Sigma = \Lambda \Lambda^T + \Psi$

Propiedades

- **Invariante ante cambios de escala**, i.e. para $\mathbf{y} = \mathbf{C}\mathbf{x}$ con, $\mathbf{C} = \text{diag}(c_1, \dots, c_p)$, se cumple

$$\text{Var}(\mathbf{y}) = \mathbf{C}\Lambda\Lambda^T\mathbf{C} + \mathbf{C}\Psi\mathbf{C} = \mathbf{C}\Sigma\mathbf{C}$$

- Λ **no es única**, ya que si $\mathbf{G} \in \mathcal{O}(k)$ entonces $\mathbf{x} = (\Lambda\mathbf{G})(\mathbf{G}^T\mathbf{f}) + \mathbf{u} + \mu$ y así

$$\Sigma = (\Lambda\mathbf{G})(\mathbf{G}^T\Lambda^T) + \Psi = \Lambda\Lambda^T + \Psi$$

- Se necesita una restricción en términos de una rotación, $\Lambda^T\Psi^{-1}\Lambda$ sea diagonal con los elementos de Ψ^{-1} ordenados de mayor a menor

Estimación

Dada una matriz de datos \mathbf{X} ¿Cómo se puede estimar a Λ y a Ψ a partir de \mathbf{S} ?

► Buscar $\hat{\Lambda}$, $\hat{\Psi}$ tales que $\mathbf{S} = \hat{\Lambda} \hat{\Lambda}^T + \hat{\Psi}$ y $\hat{\Psi}_{ii} \geq 0$

► Dado un estimador $\hat{\Lambda}$ podemos hacer

$$\hat{\Psi}_{ii} = \mathbf{S}_{ii} - \sum_{j=1}^k \hat{\lambda}_{ij}^2$$

Estimación

- La solución dependerá de la diferencia entre los grados de libertad de Σ y de Λ, Ψ

$$s = \frac{p(p+1)}{2} - \left[p + pk - \frac{k(k-1)}{2} \right] = \frac{1}{2}[(p-k)^2 - (p+k)]$$

Observación 1

- Si $s < 0$: Hay una infinidad de soluciones (no es interesante)
- Si $s = 0$: existe una única solución (no siempre es viable)
- Si $s > 0$: no hay solución exacta y debe aproximarse (caso interesante)

Estimación

Proposición 2

Si $\mathbf{Y} = \mathbf{H}\mathbf{X}\mathbf{D}^{-\frac{1}{2}}$ entonces considerando el modelo de análisis de factores se cumple

$$\mathbf{R} = \widehat{\Lambda}_y \widehat{\Lambda}_y^T + \widehat{\Psi}_y$$

donde

$$\text{- } \widehat{\Lambda}_y = \mathbf{D}^{-\frac{1}{2}} \widehat{\Lambda}_x$$

$$\text{- } \widehat{\Psi}_y = \mathbf{D}^{-1} \widehat{\Psi}_x$$

Observación 2

Con la matriz de correlaciones se tiene que, $\widehat{\Psi}_{ii} = 1 - \sum_{j=1}^k \widehat{\lambda}_{ij}^2$

Estimación por factores principales

- ▶ Aplicar una descomposición de valores propios para la matriz de correlación reducida

$$\mathbf{R} - \hat{\Psi} \quad \text{diag} \left(\mathbf{R} - \hat{\Psi} \right) = \left(\hat{h}_1^2, \dots, \hat{h}_p^2 \right)$$

- ▶ Primero hay que estimar \hat{h}_i^2
 - El cuadrado del coeficiente de correlación múltiple de la i-ésima variable con el resto de las variables.
 - El coeficiente de correlación más grande entre la i-ésima variable y alguna de las otras, i.e., $\max_{j \neq i} |r_{ij}|$.

Estimación por factores principales

- ▶ Por el teorema de descomposición espectral se tiene que

$$\mathbf{R} - \widehat{\Psi} = \sum_{i=1}^p \alpha_i \gamma_i \gamma_i^T$$

donde, $\alpha_1 \geq \alpha_2 \geq \dots \geq \alpha_p$ son los eigenvalores y $\gamma_1, \dots, \gamma_p$ los eigenvectores

- ▶ Así $\widehat{\Lambda} = \Gamma_k \mathbf{A}_k^{\frac{1}{2}}$, donde $\mathbf{A}_k = \text{diag}(\alpha_1, \dots, \alpha_k)$

- ▶ Finalmente, volver a estimar a $\widehat{\Psi}_{ii}$ como

$$\widehat{\Psi}_{ii} = 1 - \sum_{j=1}^k \hat{\lambda}_{ij}^2$$

- ▶ En R: la función `fa()` de la librería `psych`

Ejemplo 1 (Spearman)

- Correlaciones entre el aprovechamiento académico de:
 - Estudios clásicos
 - Francés
 - Inglés

$$R = \begin{pmatrix} 1 & 0.83 & 0.78 \\ & 1 & 0.67 \\ & & 1 \end{pmatrix}$$

- Considerando un solo factor se tiene una solución exacta

Ejemplo 1 (Spearman)

- El modelo queda definido como:

$$x_1 = 0.983 \cdot f + u_1$$

$$x_2 = 0.844 \cdot f + u_2$$

$$x_3 = 0.794 \cdot f + u_3$$

- ¿Quién es f ?

- f es un factor común llamado “general intelligence ability” y donde

$$\Psi_{11} = \text{Var}(u_1) = 0.034$$

$$\Psi_{22} = \text{Var}(u_2) = 0.288$$

$$\Psi_{33} = \text{Var}(u_3) = 0.370$$

Ejemplo 2

- ▶ Considerar la matriz de correlaciones

$$R = \begin{pmatrix} 1 & 0.84 & 0.6 \\ & 1 & 0.35 \\ & & 1 \end{pmatrix}$$

- ▶ La solución al sistema es

$$\begin{array}{lll} \lambda_1 = 1.2 & & \Psi_{11} = \text{Var}(u_1) = -0.44 \\ \lambda_2 = 0.7 & \Rightarrow & \Psi_{22} = \text{Var}(u_2) = 0.51 \\ \lambda_3 = 0.5 & & \Psi_{33} = \text{Var}(u_3) = 0.75 \end{array}$$

- ▶ No es admisible y una posible solución es fijar $\lambda_1 = 1$ (caso de Heywood)

Estimación por máxima verosimilitud

- Suponiendo que $\mathbf{x}_1, \dots, \mathbf{x}_{n+1} \sim N(\mu, \Sigma)$ (iid) donde $\Sigma = \Lambda\Lambda^T + \Psi$ y $\hat{\mu} = \bar{\mathbf{x}}$ podemos pensar en maximizar la log-verosimilitud

$$L = -\frac{n}{2}(\log |\Sigma|) - \frac{n}{2}\text{tr}(\Sigma^{-1}\mathbf{S})$$

- O equivalentemente minimizar (Jörekog, 1967)

$$F = \log(|\Sigma|) + \text{tr}(\mathbf{S}\Sigma^{-1}) - \log(|\mathbf{S}|) - p$$

1. Minimizar F analíticamente con respecto a Λ para una Ψ fija
2. Minimizar numéricamente F con respecto a Ψ

Prueba de hipótesis para el número de factores

- ▶ Bajo el supuesto de normalidad se pueden hacer pruebas de hipótesis para el número de factores

- ▶ El estadístico de prueba estará dado por (Bartlett, 1954)

$$U = n' \min(F) \qquad n' = n - 1 - \frac{1}{6}(2p + 5) - \frac{2}{3}k$$

- ▶ Si k factores son suficientes entonces,

$$U \sim \chi^2_\nu \qquad \nu = \frac{1}{2}(p - k)^2 - \frac{1}{2}(p + k)$$

- ▶ Se puede probar de forma secuencial para $k = 1, 2, \dots$ para encontrar el número de factores a considerar

Ejemplo 3

- 88 calificaciones de 5 exámenes a libro abierto o cerrado.

Alumno	Lineal (C)	Estadística (C)	Probabilidad (A)	Finanzas (A)	Cálculo (A)
1	97	92	77	72	96
2	83	88	90	75	96
3	95	83	81	71	96
.
.
87	25	36	25	25	35
88	20	50	31	14	29

- La matriz de correlación es

$$R = \begin{pmatrix} 1 & .546 & .545 & .410 & .390 \\ & 1 & .613 & .489 & .449 \\ & & 1 & .712 & .666 \\ & & & 1 & .666 \\ & & & & 1 \end{pmatrix}$$

Ejemplo 3

- Para $k = 1$

Variable	λ_i	h_i^2	Ψ_{ii}
Lineal	0.61	0.37	0.63
Estadística	0.69	0.48	0.52
Probabilidad	0.91	0.83	0.17
Finanzas	0.76	0.58	0.42
Cálculo	0.72	0.51	0.49

- ¿Cómo se puede interpretar el factor común?
- El factor común se puede interpretar como un factor de habilidad general en matemáticas

Ejemplo 3

- Para $k = 2$

Variable	λ_{1i}	λ_{2i}	h_i^2	Ψ_{ii}
Lineal	0.64	0.33	0.51	0.49
Estadística	0.71	0.28	0.59	0.41
Probabilidad	0.90	-0.08	0.81	0.19
Finanzas	0.77	-0.23	0.65	0.35
Cálculo	0.72	-0.22	0.57	0.43

- El primer factor se puede interpretar como un factor de habilidad general en matemáticas
- El segundo factor se puede interpretar como un factor de habilidad en exámenes cerrados y abiertos

Ejemplo 3

▸ Para $k = 1$

Estimación por factores principales

Variable	λ_i	h_i^2	Ψ_{ii}
Lineal	0.61	0.37	0.63
Estadística	0.69	0.48	0.52
Probabilidad	0.91	0.83	0.17
Finanzas	0.76	0.58	0.42
Cálculo	0.72	0.51	0.49

Estimación por MLE

Variable	λ_i	h_i^2	Ψ_{ii}
Lineal	0.60	0.36	0.64
Estadística	0.67	0.45	0.55
Probabilidad	0.92	0.84	0.16
Finanzas	0.77	0.60	0.40
Cálculo	0.73	0.53	0.47

Ejemplo 3

▸ Para $k = 2$

Estimación por factores principales

Variable	λ_{1i}	λ_{2i}	h_i^2	Ψ_{ii}
Lineal	0.64	0.33	0.51	0.49
Estadística	0.71	0.28	0.59	0.41
Probabilidad	0.90	-0.08	0.81	0.19
Finanzas	0.77	-0.23	0.65	0.35
Cálculo	0.72	-0.22	0.57	0.43

Estimación por MLE

Variable	λ_{1i}	λ_{2i}	h_i^2	Ψ_{ii}
Lineal	0.62	0.38	0.53	0.47
Estadística	0.70	0.29	0.57	0.43
Probabilidad	0.90	-0.05	0.81	0.19
Finanzas	0.78	-0.20	0.65	0.35
Cálculo	0.73	-0.19	0.57	0.43

Ejemplo 3

- ▶ Hacemos la prueba de hipótesis para $k = 1$, obteniendo

$$U = n' \min(F) = 7.749803 < 11.0705 = \chi_{5,.95}^2$$

- ▶ Por lo que no rechazamos la hipótesis nula de que un factor sea suficiente

- ▶ Hacemos la prueba de hipótesis para $k = 2$, obteniendo

$$U = n' \min(F) = 0.02823699 < 3.841459 = \chi_{1,.95}^2$$

- ▶ Por lo que no rechazamos la hipótesis nula de que un factor sea suficiente

Rotaciones ortogonales

- ▶ Para tener unicidad en el modelo se consideró la restricción $\Lambda^T \Psi^{-1} \Lambda$ sea diagonal
- ▶ Para la interpretación de los factores es preferible que:
 1. Cada variable esté asociada fuertemente a lo más a un factor
 2. Las cargas sean muy grandes y positivas o cercanas al cero con algunos valores intermedios
- ▶ Ejemplo de rotaciones ortogonales: varimax, quartimax, orthomax, etc.

Rotación varimax

- ▶ Rotación ortogonal propuesta por Kaiser (1958)
- ▶ Sea Λ la matriz de cargas y \mathbf{G} matriz ortogonal entonces la matriz de cargas rotadas es:

$$\Delta = \Lambda \mathbf{G}$$

- ▶ Objetivo: maximizar ϕ

$$\phi = \sum_{j=1}^k \sum_{i=1}^p (d_{ij}^2 - \bar{d}_j)^2$$

$$d_{ij} = \frac{\delta_{ij}}{h_i} \quad \bar{d}_j = p^{-1} \sum_{i=1}^p d_{ij}^2$$

Ejemplo 3 (continuación)

▸ Para $k = 2$



Factores principales sin rotación

Variable	λ_{1i}	λ_{2i}	h_i^2	Ψ_{ii}
Lineal	0.64	0.33	0.51	0.49
Estadística	0.71	0.28	0.59	0.41
Probabilidad	0.90	-0.08	0.81	0.19
Finanzas	0.77	-0.23	0.65	0.35
Cálculo	0.72	-0.22	0.57	0.43


Factores principales con varimax

Variable	λ_{1i}	λ_{2i}	h_i^2	Ψ_{ii}
Lineal	0.27	0.66	0.51	0.49
Estadística	0.36	0.68	0.59	0.41
Probabilidad	0.74	0.52	0.81	0.19
Finanzas	0.74	0.32	0.65	0.35
Cálculo	0.69	0.30	0.57	0.43

Ejemplo 3 (continuación)



Ejemplo 3 (continuación)



Rotaciones oblicuas

- ▶ Permiten que los factores estén correlacionados
- ▶ Pueden proporcionar soluciones más simples
- ▶ Para factores latentes puede ser complicado tener que explicar la correlación entre ellos
- ▶ Ejemplos: quartimin, covarimin, biquartimin, oblimin (por default en R), etc.

Ejemplo 3 (continuación)

▸ Para $k = 2$

Factores principales con varimax

Variable	λ_{1i}	λ_{2i}	h_i^2	Ψ_{ii}
Lineal	0.27	0.66	0.51	0.49
Estadística	0.36	0.68	0.59	0.41
Probabilidad	0.74	0.52	0.81	0.19
Finanzas	0.74	0.32	0.65	0.35
Cálculo	0.69	0.30	0.57	0.43


Factores principales con oblimin

Variable	λ_{1i}	λ_{2i}	h_i^2	Ψ_{ii}
Lineal	-0.03	0.74	0.51	0.49
Estadística	0.09	0.70	0.59	0.41
Probabilidad	0.72	0.22	0.81	0.19
Finanzas	0.85	-0.05	0.65	0.35
Cálculo	0.79	-0.05	0.57	0.43

▸ La correlación de los factores es 0.76

Ejemplo 3 (continuación)

Factores principales con varimax



Factores principales con oblimin

