Análisis de factores (FA)

Introducción

- El análisis de factores es un modelo matemático que busca:

  Explicar la correlación de un conjunto de p variables a través de k factores latentes

- Orígenes en psicología:

  Spearman (1904). *"General-Intelligence," Objectively Determined and Measured. American Journal of Psychology*. **15** (2): 201–293.

  Thurstone (1931). Multiple factor analysis. Psychological Review. **38** (5): 406–427.

  Thurstone (1934). The Vectors of Mind. The Psychological Review. **41**: 1–32.

Formulación

Formulación

- Sea $\mathbf{x}_{p\times 1}$ un vector aleatorio con $\mathbb{E}(\mathbf{x}) = \mu$ y $\text{Var}(\mathbf{x}) = \Sigma$ entonces,

$$\mathbf{x} = \Lambda\mathbf{f} + \mathbf{u} + \mu$$

Donde

1. $\Lambda_{p\times k}$ es una matriz de constantes
2. $\mathbf{f}_{k\times 1}$ es un vector aleatorio de factores comunes
3. $\mathbf{u}_{p\times 1}$ es un vector aleatorio de factores únicos

- Así, para cada variable se tiene la representación

$$x_i = \sum_{j=1}^{k} \lambda_{ij} f_j + u_i + \mu_i$$

Formulación

- **Supuestos**

1. $\mathbb{E}(\mathbf{f}) = \mathbf{0}$
2. $\text{Var}(\mathbf{f}) = \mathbf{I}$
3. $\mathbb{E}(\mathbf{u}) = \mathbf{0}$
4. $\text{Var}(\mathbf{u}) = \Psi = \text{diag}\left(\Psi_{11}, \ldots, \Psi_{pp}\right)$
5. $\text{Cov}(\mathbf{f}, \mathbf{u}) = \mathbf{O}$

Propiedades

Propiedades

Proposición 1

Dado el modelo de análisis de factores, se tiene que la varianza de cada x_i es

$$\text{Var}\left(x_i\right) = \sum_{j=1}^{k} \lambda_{ij}^2 + \Psi_{ii} = h_i^2 + \Psi_{ii},$$

y la covarianza de x_i y x_l es

$$\text{Cov}\left(x_i, x_l\right) = \sum_{j=1}^{k} \lambda_{ij}\lambda_{jl}\,.$$

Por lo que, $\Sigma = \Lambda\Lambda^T + \Psi$

Propiedades

- **Invariante ante cambios de escala**, i.e. para $\mathbf{y} = \mathbf{C}\mathbf{x}$ con, $\mathbf{C} = \text{diag}(c_1, \ldots, c_p)$, se cumple

$$\text{Var}(\mathbf{y}) = \mathbf{C}\Lambda\Lambda^T\mathbf{C} + \mathbf{C}\Psi\mathbf{C} = \mathbf{C}\Sigma\mathbf{C}$$

- Λ **no es única**, ya que si $\mathbf{G} \in \mathcal{O}(k)$ entonces $\mathbf{x} = (\Lambda\mathbf{G})(\mathbf{G}^T\mathbf{f}) + \mathbf{u} + \mu$ y así

$$\Sigma = (\Lambda\mathbf{G})(\mathbf{G}^T\Lambda^T) + \Psi = \Lambda\Lambda^T + \Psi$$

- Se necesita una restricción en términos de una rotación, $\Lambda^T\Psi^{-1}\Lambda$ sea diagonal con los elementos de Ψ^{-1} ordenados de mayor a menor

Estimación por factores principales

Estimación

Dada una matriz de datos $\mathbf{X}$ ¿Cómo se puede estimar a Λ y a Ψ a partir de $\mathbf{S}$?

- Buscar $\widehat{\Lambda}$, $\widehat{\Psi}$ tales que $\mathbf{S} = \widehat{\Lambda}\,\widehat{\Lambda}^T + \widehat{\Psi}$ y $\widehat{\Psi}_{ii} \geq 0$

- Dado un estimador $\widehat{\Lambda}$ podemos hacer

$$\widehat{\Psi}_{ii} = \mathbf{S}_{ii} - \sum_{j=1}^{k} \widehat{\lambda}_{ij}^2$$

Estimación

- La solución dependerá de la diferencia entre los grados de libertad de Σ y de Λ, Ψ

$$s = \frac{p(p+1)}{2} - \left[p + pk - \frac{k(k-1)}{2}\right] = \frac{1}{2}[(p-k)^2 - (p+k)]$$

Observación 1

- Si $s < 0$: Hay una infinidad de soluciones (no es interesante)
- Si $s = 0$: existe una única solución (no siempre es viable)
- Si $s > 0$: no hay solución exacta y debe aproximarse (caso interesante)

Estimación

Proposición 2

Si $\mathbf{Y} = \mathbf{HXD}^{-\frac{1}{2}}$ entonces considerando el modelo de análisis de factores se cumple

$$\mathbf{R} = \widehat{\Lambda}_y \widehat{\Lambda}_y^T + \widehat{\Psi}_y$$

donde

- $\widehat{\Lambda}_y = \mathbf{D}^{-\frac{1}{2}} \widehat{\Lambda}_x$
- $\widehat{\Psi}_y = \mathbf{D}^{-1} \widehat{\Psi}_x$

Observación 2

Con la matriz de correlaciones se tiene que, $\widehat{\Psi}_{ii} = 1 - \sum_{j=1}^{k} \widehat{\lambda}_{ij}^2$

Estimación por factores principales

- Aplicar una descomposición de valores propios para la matriz de correlación reducida

$$\mathbf{R} - \widehat{\Psi} \qquad\qquad \text{diag}\left(\mathbf{R} - \widehat{\Psi}\right) = \left(\hat{h}_1^2, \ldots, \hat{h}_p^2\right)$$

- Primero hay que estimar $\hat{h}_i^2$
  - El cuadrado del coeficiente de correlación múltiple de la i-ésima variable con el resto de las variables.
  - El coeficiente de correlación más grande entre la i-ésima variable y alguna de las otras, i.e., $\max_{j \neq i} |r_{ij}|$.

Estimación por factores principales

- Por el teorema de descomposición espectral se tiene que

$$\mathbf{R} - \widehat{\Psi} = \sum_{i=1}^{p} \alpha_i \gamma_i \gamma_i^T$$

donde, $\alpha_1 \geq \alpha_2 \geq \cdots \geq \alpha_p$ son los eigenvalores y $\gamma_1, \ldots, \gamma_p$ los eigenvectores

- Así $\widehat{\Lambda} = \Gamma_k \mathbf{A}_k^{\frac{1}{2}}$, donde $A_k = \text{diag}(\alpha_1, \ldots, \alpha_k)$

- Finalmente, volver a estimar a $\widehat{\Psi}_{ii}$ como

$$\widehat{\Psi}_{ii} = 1 - \sum_{j=1}^{k} \widehat{\lambda}_{ij}^2$$

- En R: la función fa() de la librería psych

Ejemplo 1 (Spearman)

- Correlaciones entre el aprovechamiento académico de:

  - Estudios clásicos

  - Francés

  - Inglés

$$R = \begin{pmatrix} 1 & 0.83 & 0.78 \\ & 1 & 0.67 \\ & & 1 \end{pmatrix}$$

- Considerando un solo factor se tiene una solución exacta

Ejemplo 1 (Spearman)

- El modelo queda definido como:

$$x_1 = 0.983 \cdot f + u_1$$
$$x_2 = 0.844 \cdot f + u_2$$
$$x_3 = 0.794 \cdot f + u_3$$

- ¿Quién es f?

- f es un factor común llamado "general intelligence ability" y donde

$$\Psi_{11} = \text{Var}(u_1) = 0.034$$
$$\Psi_{22} = \text{Var}(u_2) = 0.288$$
$$\Psi_{33} = \text{Var}(u_3) = 0.370$$

Ejemplo 2

- Considerar la matriz de correlaciones

$$R = \begin{pmatrix} 1 & 0.84 & 0.6 \\ & 1 & 0.35 \\ & & 1 \end{pmatrix}$$

- La solución al sistema es

$$\begin{aligned} \lambda_1 &= 1.2 & & \Psi_{11} = \text{Var}(u_1) = -0.44 \\ \lambda_2 &= 0.7 & \Rightarrow \quad & \Psi_{22} = \text{Var}(u_2) = 0.51 \\ \lambda_3 &= 0.5 & & \Psi_{33} = \text{Var}(u_3) = 0.75 \end{aligned}$$

- No es admisible y una posible solución es fijar $\lambda_1 = 1$ (caso de Heywood)