

Escalamiento Multidimensional



José A. Perusquía Cortés
Análisis Multivariado, Semestre 2025-II



Motivación

- Un conjunto de métodos enfocados en reducir la dimensión usando como criterio preservar la “distancia” entre observaciones

- **Tipos**

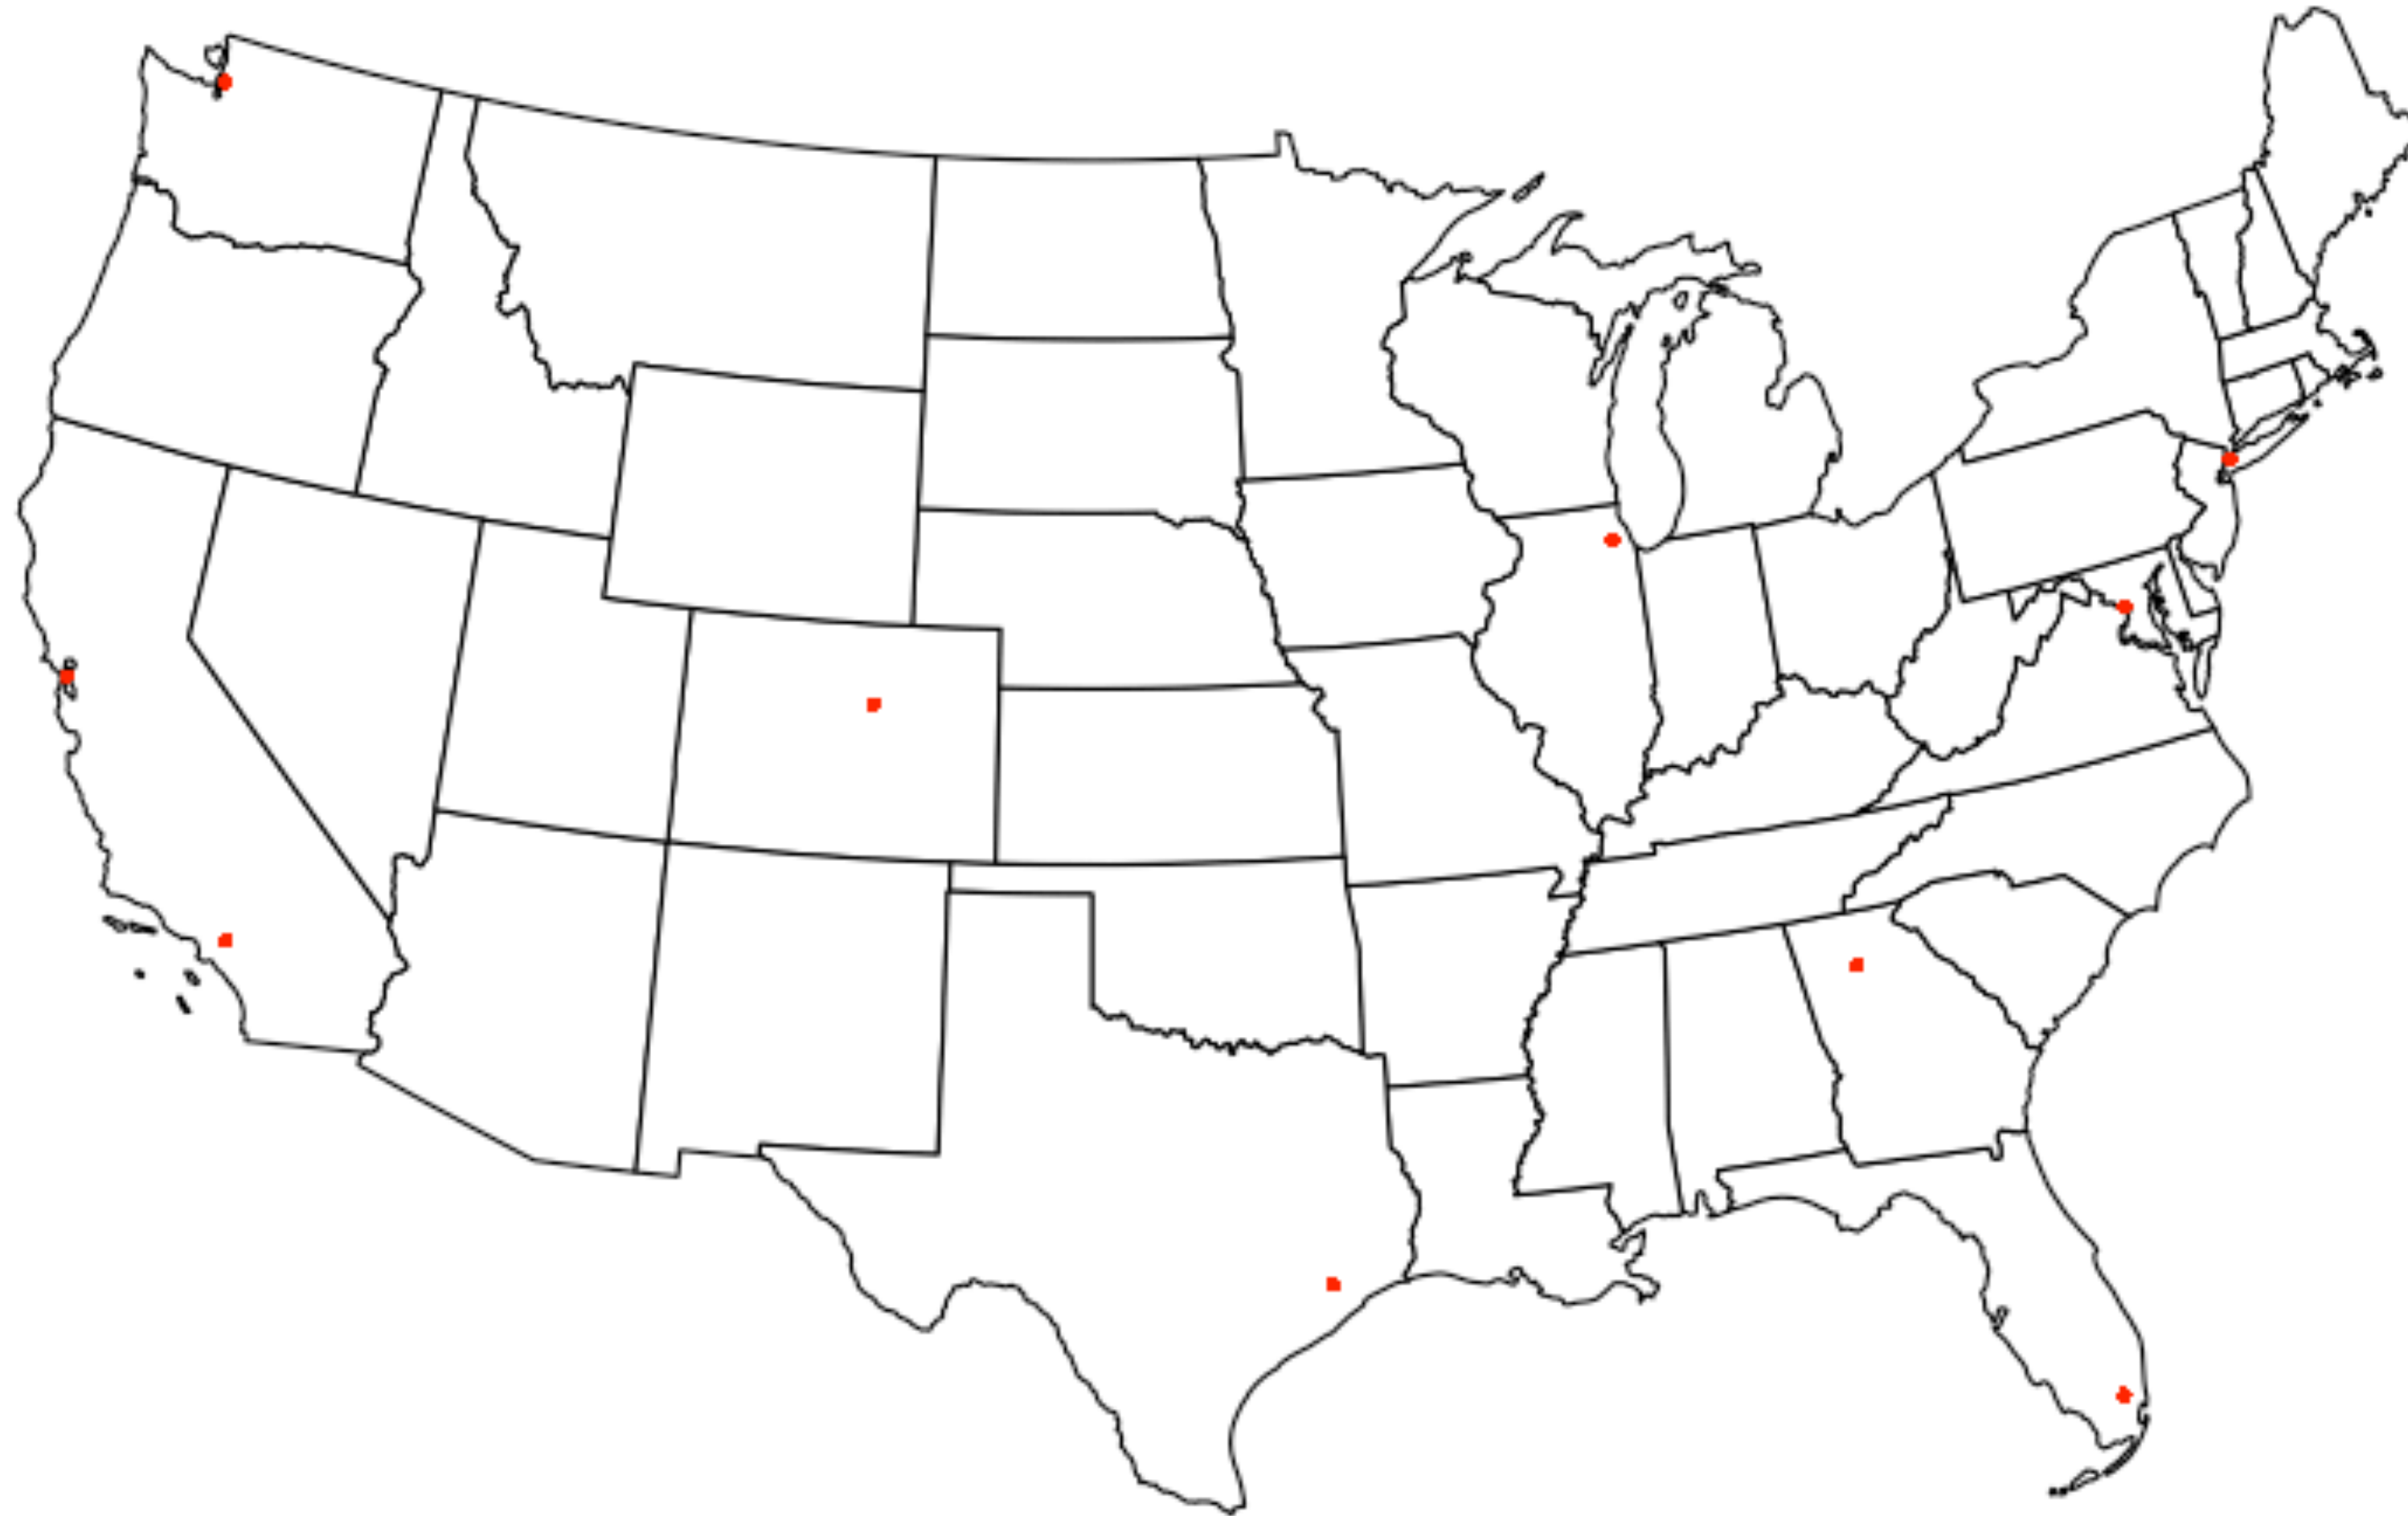
Escalamiento multidimensional clásico (lineal)

Escalamiento multidimensional métrico (no lineal)

Escalamiento multidimensional no métrico (no lineal)

Ejemplo ciudades EE.UU.

- Reconstrucción de un mapa a través de las distancias entre ciudades




Ejemplo ciudades EE.UU.

▸ Distancia en avión

	Atl.	Chic.	Denv.	Houston	LA	Miami	NY	SF	Seat.	Wash.
Atlanta	-									
Chicago	587	-								
Denver	1212	920	-							
Houston	701	940	879	-						
LA	1936	1745	831	1374	-					
Miami	604	1188	1726	968	2339	-				
NY	748	713	1631	1420	2451	1092	-			
SF	2139	1858	949	1645	347	2594	2571	-		
Seattle	2182	1737	1021	1891	959	2734	2408	678	-	
Wash.	543	597	1494	1220	2300	923	205	2442	2329	-


Ejemplo ciudades EE.UU.

- ▶ Utilizando el escalamiento multidimensional clásico



Ejemplo ciudades EE.UU.

- Rotando la solución




Ejemplo ciudades EE.UU.

- Problema similar: identificar las ciudades


-										
587	-									
1212	920	-								
701	940	879	-							
1936	1745	831	1374	-						
604	1188	1726	968	2339	-					
748	713	1631	1420	2451	1092	-				
2139	1858	949	1645	347	2594	2571	-			
2182	1737	1021	1891	959	2734	2408	678	-		
543	597	1494	1220	2300	923	205	2442	2329	-	

Ejemplo ciudades EE.UU.



Ejemplo capitales Europa

- ¡No siempre es fácil!



Escalamiento Multidimensional Métrico (Clásico)

Procedimiento

- ▶ Construir una matriz de distancias/disimilitudes **D**
 1. $d_{i,j} \geq 0$ para toda $i, j = 1, \dots, n$
 2. $d_{i,i} = 0$
 3. **D** = **D**^T
- ▶ Encontrar un conjunto de vectores $\mathbf{y}_1, \dots, \mathbf{y}_n \in \mathbb{R}^k$ tales que $d_{\mathbf{x}}(i, j) \approx d_{\mathbf{y}}(i, j)$

Observación 1

1. **D** es euclidiana si existe una configuración tal que $d_{\mathbf{x}}(i, j) = d_{\mathbf{y}}(i, j)$
2. En ocasiones **D** es una medición con error.

Construcción

Definición 1 (matriz doblemente centrada)

Sea **D** una matriz de “distancias” entonces la matriz doblemente centrada está definida como

$$\mathbf{B} = \mathbf{H}\mathbf{A}\mathbf{H}$$

donde,

$$\mathbf{A} = -\frac{1}{2}\mathbf{D} \odot \mathbf{D} \qquad a_{ij} = -\frac{d_{ij}^2}{2}$$

Construcción

Teorema 1

Sea $\mathbf{D}_{n \times n}$ una matriz de distancias con matriz doblemente centrada

$$\mathbf{B} = -\frac{1}{2}\mathbf{H}(\mathbf{D} \odot \mathbf{D})\mathbf{H} \text{ entonces}$$

1. Si $\mathbf{D}_{n \times n}$ es euclidiana entonces $\mathbf{B} = (\mathbf{H}\mathbf{X})(\mathbf{H}\mathbf{X})^T$ y así \mathbf{B} es semi-definida positiva.

2. Si \mathbf{B} es semi-definida positiva con eigenvalores $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k > 0$ y

descomposición espectral $\mathbf{B} = \mathbf{U}\mathbf{\Lambda}\mathbf{U}^T$ entonces

$$\mathbf{X} = \mathbf{U}\mathbf{\Lambda}^{\frac{1}{2}}$$

es una matriz de datos de dimensión $n \times k$ con matriz euclidiana de distancias \mathbf{D} .

Propiedades

1. La solución no es única (invariante ante cambios de origen, rotaciones y reflexiones)

2. $\bar{\mathbf{y}} = \mathbf{0}$

3. Robusto ante perturbaciones [e.g. Sibson (1978, 1979, 1981) y Mardia (1978)]

4. Si λ_1 y λ_2 son mucho más grandes que $\lambda_3, \dots, \lambda_n$ y los elementos de $\mathbf{y}^{(1)}$ y $\mathbf{y}^{(2)}$ son

diferentes entonces si $\sum_{k=1}^2 (y_{ik} - y_{jk})^2 \approx d_{ij}^2$ se tiene una buena representación en \mathbb{R}^2

5. Si la matriz es no euclidiana podemos hacer uso de los primeros l eigenvalores positivos y así, se tiene una configuración razonable con $(\mathbf{y}^{(1)}, \dots, \mathbf{y}^{(l)})$

Algoritmo

1. Construir la matriz **A**
2. Obtener la matriz doblemente centrada **B**
3. Obtener los k valores propios positivos y los vectores propios asociados
4. Si $k = 2$ o $k = 3$ se tiene una configuración que se puede graficar

► **En R:** `cmdscale()`

Ejemplo ciudades EE.UU.

- Distancia en avión de 10 ciudades de Estados Unidos

	Atl.	Chic.	Denv.	Houston	LA	Miami	NY	SF	Seat.	Wash.
Atlanta	-									
Chicago	587	-								
Denver	1212	920	-							
Houston	701	940	879	-						
LA	1936	1745	831	1374	-					
Miami	604	1188	1726	968	2339	-				
NY	748	713	1631	1420	2451	1092	-			
SF	2139	1858	949	1645	347	2594	2571	-		
Seattle	2182	1737	1021	1891	959	2734	2408	678	-	
Wash.	543	597	1494	1220	2300	923	205	2442	2329	-

Ejemplo ciudades EE.UU.

- Los eigenvalores de **B** están dados por

$$\lambda_1 = 9582144$$

$$\lambda_2 = 1686820$$

$$\lambda_3 = 8157.298$$

$$\lambda_4 = 1432.87$$

$$\lambda_5 = 508.6687$$

$$\lambda_6 = 25.14349$$

$$\lambda_7 = -6.218108e - 10$$

$$\lambda_8 = -897.7013$$

$$\lambda_9 = -5467.577$$

$$\lambda_{10} = -35478.89$$

- D** no es Euclidiana

Ejemplo ciudades EE.UU.

- ▶ Nos quedamos con los 6 valores propios positivos y construimos Y

$y^{(1)}$	$y^{(2)}$	$y^{(3)}$	$y^{(4)}$	$y^{(5)}$	$y^{(6)}$
-718.7594	142.99427	35.102499	-1.224963	-7.4094776	1.5046461
-382.0558	-340.83962	29.602228	-8.237885	-12.0242975	-2.3383016
481.6023	-25.28504	53.393802	1.339279	15.6658897	-0.9526963
-161.4663	572.76991	1.452571	-1.762318	-0.6718656	2.7007621
1203.7380	390.10029	-18.635065	14.974864	-3.1692006	-1.6561488
-1133.5271	581.90731	-32.268842	-2.375685	2.9718537	-2.0471878
-1072.2357	-519.02423	-34.341878	-14.253857	6.4473289	0.2709088
1420.6033	112.58920	-7.754755	-18.120276	-0.8054123	0.8695197
1341.7225	-579.73928	-23.650787	5.961453	-1.4286322	0.6143794
-979.6220	-335.47281	-2.899773	23.699388	0.4238136	1.0341183

- ▶ Podemos quedarnos con las primeras dos columnas

Otras consideraciones

1. Si se tienen similitudes con las siguientes condiciones:

▸ $s_{ij} \leq s_{ii}$

▸ $s_{ij} = s_{ji}$

Se puede crear una matriz de disimilitudes

$$d_{ij} = (s_{ii} - 2s_{ij} + s_{jj})^{\frac{1}{2}}$$

2. Relación cercana entre el escalamiento multidimensional clásico y los componentes principales

3. Se puede considerar la formulación: $d_{\mathbf{x}}(i, j) \approx d_{\mathbf{y}}(i, j) + a$ (additive constant problem)

MDS vs PCA

1. Si **D** es euclidiana entonces el MDS clásico (o análisis de coordenadas principales) da los mismos resultados que PCA.
2. MDS es más flexible ya que acepta a las observaciones **X** o a una matriz de distancias/disimilitudes **D**.
3. MDS es computacionalmente más demandante.

Ejemplo calificaciones

- ▶ Los eigenvalores de **S** son

$$\lambda_1 = 60000.28$$

$$\lambda_2 = 17478.45$$

$$\lambda_3 = 9006.942$$

$$\lambda_4 = 7511.62$$

$$\lambda_5 = 2805.543$$

- ▶ Iguales a los 5 eigenvalores de **B** distintos de cero

Ejemplo calificaciones

- ▶ Aplicando las transformaciones a los alumnos 1, 2, 3, 4, 86, 87 y 88

Alumno	PCA1	PCA2	MDS1	MDS2
1	-66.28	-6.48	-66.28	6.48
2	-63.60	6.79	-63.60	-6.79
3	-62.86	-3.26	-62.86	3.26
4	-44.51	5.65	-44.51	-5.65
86	44.35	7.86	44.35	-7.86
87	62.54	7.58	62.54	-7.58
88	65.93	2.66	65.93	-2.66

Constante aditiva

- ▶ Se busca encontrar la constante c más pequeña tal que un conjunto de disimilitudes tengan una representación euclidiana mediante,

$$d_{i,j}^c = d_{i,j} + c \quad i \neq j$$

- ▶ Problema estudiado por muchos autores (e.g. Messick & Abelson, 1956; Saito, 1978; Cailliez, 1983)
- ▶ La solución de Cailliez se utiliza en **R**: `cmdscale(...,add=T)`
- ▶ Por cuestiones numéricas no se puede garantizar que todos los valores propios sean no negativos

Ejemplo ciudades de EE.UU.

- Los valores propios de **B** al sumarle la constante aditiva $c = 39.12509$

$$\lambda_1 = 9851759$$

$$\lambda_2 = 1760672$$

$$\lambda_3 = 49961.61$$

$$\lambda_4 = 23925.69$$

$$\lambda_5 = 22217.78$$

$$\lambda_6 = 15077.03$$

$$\lambda_7 = 11721.03$$


$$\lambda_8 = 7807.841$$

$$\lambda_9 = 1.55739e - 10$$

$$\lambda_{10} = -5.297162e - 10$$


Ejemplo ciudades de EE.UU.

- El mapa reconstruido con la constante aditiva $c = 39.12509$




Escalamiento Multidimensional Métrico


Ejemplo rollo suizo (chocorol)



Ejemplo rollo suizo (chocorol)



MDS Clásico



Motivación

- Una generalización no lineal del escalamiento clásico en donde se busca preservar las distancias y no solo los productos interiores

Motivación

- Una generalización no lineal del escalamiento clásico en donde se busca preservar las distancias y no solo los productos interiores

- **Objetivo**

Minimizar una función objetivo conocida coloquialmente como “Stress”

$$\text{Stress} = \frac{1}{2} \sum_{i,j} w_{ij} \left[d_{\mathbf{x}}(i,j) - d_{\mathbf{y}}(i,j) \right]^2$$

Motivación

- ▶ Una generalización no lineal del escalamiento clásico en donde se busca preservar las distancias y no solo los productos interiores

- ▶ **Objetivo**

Minimizar una función objetivo conocida coloquialmente como “Stress”

$$\text{Stress} = \frac{1}{2} \sum_{i,j} w_{ij} \left[d_{\mathbf{x}}(i,j) - d_{\mathbf{y}}(i,j) \right]^2$$

- ▶ En la práctica, $w_{ij} = 1$ y $w_{ij} = 0$ (valores faltantes)

Sammon

- NLM: Mapeo no-lineal de Sammon (1969)

$$\text{Stress} = \frac{1}{c} \sum_{i,j} \frac{\left[d_{\mathbf{x}}(i,j) - d_{\mathbf{y}}(i,j) \right]^2}{d_{\mathbf{x}}(i,j)}$$

$$c = \sum_{i < j} d_{\mathbf{x}}(i,j)$$

Sammon

- NLM: Mapeo no-lineal de Sammon (1969)

$$\text{Stress} = \frac{1}{c} \sum_{i,j} \frac{\left[d_{\mathbf{x}}(i,j) - d_{\mathbf{y}}(i,j) \right]^2}{d_{\mathbf{x}}(i,j)} \qquad c = \sum_{i < j} d_{\mathbf{x}}(i,j)$$

- Por lo general, $d_{\mathbf{x}}(i,j)$ es la distancia Euclidiana (no necesariamente)

Sammon

- NLM: Mapeo no-lineal de Sammon (1969)

$$\text{Stress} = \frac{1}{c} \sum_{i,j} \frac{\left[d_{\mathbf{x}}(i,j) - d_{\mathbf{y}}(i,j) \right]^2}{d_{\mathbf{x}}(i,j)} \qquad c = \sum_{i < j} d_{\mathbf{x}}(i,j)$$

- Por lo general, $d_{\mathbf{x}}(i,j)$ es la distancia Euclidiana (no necesariamente)
- Da más importancia a distancias cortas

Sammon

- NLM: Mapeo no-lineal de Sammon (1969)

$$\text{Stress} = \frac{1}{c} \sum_{i,j} \frac{\left[d_{\mathbf{x}}(i,j) - d_{\mathbf{y}}(i,j) \right]^2}{d_{\mathbf{x}}(i,j)} \qquad c = \sum_{i < j} d_{\mathbf{x}}(i,j)$$

- Por lo general, $d_{\mathbf{x}}(i,j)$ es la distancia Euclidiana (no necesariamente)
- Da más importancia a distancias cortas
- Requiere una rutina numérica (quasi-Newton) y de un parámetro “magic” (recomendado entre .3 y .4)


Sammon

- NLM: Mapeo no-lineal de Sammon (1969)


$$\text{Stress} = \frac{1}{c} \sum_{i,j} \frac{\left[d_{\mathbf{x}}(i,j) - d_{\mathbf{y}}(i,j) \right]^2}{d_{\mathbf{x}}(i,j)} \qquad c = \sum_{i < j} d_{\mathbf{x}}(i,j)$$

- Por lo general, $d_{\mathbf{x}}(i,j)$ es la distancia Euclidiana (no necesariamente)
- Da más importancia a distancias cortas
- Requiere una rutina numérica (quasi-Newton) y de un parámetro “magic” (recomendado entre .3 y .4)
- En **R**: función **sammon** en librería **MASS**

Ejemplo rollo suizo (chocorol)



Sammon NLM



Escalamiento Multidimensional

No Métrico

Motivación

- Alternativa menos rígida al MDS utilizando una función monótona desconocida de las distancias/proximidades, i.e.

$$d_x(i, j) = f(d_y(i, j))$$

Motivación

- ▶ Alternativa menos rígida al MDS utilizando una función monótona desconocida de las distancias/proximidades, i.e.

$$d_x(i, j) = f(d_y(i, j))$$

- ▶ Para el MDS no métrico, construimos $d_y(i, j)$ utilizando solo los rangos de $d_x(i, j)$, e.g.

para las ciudades de Estados Unidos usamos:

- El viaje más corto es entre NY y Washington D.C.
- El segundo viaje más corto es entre Seattle y Atlanta.

...

- El viaje más largo es entre Seattle y Miami

MDS no métrico

- **Objetivo**

Optimizar la función “stress”

$$\text{Stress} = \sqrt{\frac{\sum_{ij} w_{ij} \left[f(\delta_{\mathbf{x}}(i, j)) - d_{\mathbf{y}}(i, j) \right]^2}{c}}$$

MDS no métrico

► **Objetivo**

Optimizar la función “stress”

$$\text{Stress} = \sqrt{\frac{\sum_{ij} w_{ij} \left[f(\delta_{\mathbf{x}}(i, j)) - d_{\mathbf{y}}(i, j) \right]^2}{c}}$$

donde

- $\delta_{\mathbf{x}}(i, j)$ son proximidades
- f es una función monótona tal que $f(\delta_{\mathbf{x}}(i, j)) \approx d_{\mathbf{x}}(i, j)$ (distancia Euclidiana)
- c es un factor de escala
- w_{ij} son pesos no negativos como en el escalamiento multidimensional métrico

- Algoritmo dado por Shepard (1962) y Kruskal (1964)

1. Dada una matriz de disimilitudes **D** ordenar las entradas fuera de la diagonal.

2. Para una configuración k -dimensional, minimizar la función Stress dada por

$$\text{Stress} = \sqrt{\frac{\sum_{i < j} [d_{ij}^* - d_y(i, j)]^2}{\sum_{i < j} d_y(i, j)^2}}$$

con respecto a valores d_{ij}^* tal que d_{ij}^* esté relacionada de forma monótona con $d_x(i, j)$,

i.e., $d_x(i, j) < d_x(k, l) \Rightarrow d_{ij}^* \leq d_{kl}^*$.

Consideraciones

- ▶ Los d_{ij}^* se encuentran a través de una regresión monótona (isotonic regression).

Consideraciones

- ▶ Los d_{ij}^* se encuentran a través de una regresión monótona (isotonic regression).
- ▶ Requiere de rutinas numéricas.

Consideraciones

- ▶ Los d_{ij}^* se encuentran a través de una regresión monótona (isotonic regression).
- ▶ Requiere de rutinas numéricas.
- ▶ Para encontrar la dimensión adecuada calcular para cada k

$$S_k = \min \text{Stress}^2$$

detenerse hasta que S_k sea pequeño para $k = k_0$ o una regla de dedo de Kruskal donde

$S_k \geq 20 \%$ es pobre, $S_k = 10 \%$ es justo, $S_k \leq 5 \%$ es bueno y $S_k = 0$ es perfecto.

Consideraciones

- ▶ Los d_{ij}^* se encuentran a través de una regresión monótona (isotonic regression).
- ▶ Requiere de rutinas numéricas.
- ▶ Para encontrar la dimensión adecuada calcular para cada k

$$S_k = \min \text{Stress}^2$$


detenerse hasta que S_k sea pequeño para $k = k_0$ o una regla de dedo de Kruskal donde

$S_k \geq 20\%$ es pobre, $S_k = 10\%$ es justo, $S_k \leq 5\%$ es bueno y $S_k = 0$ es perfecto.


- ▶ En **R**: `isoMDS/Shepard` de la librería **MASS** utilizando una configuración inicial (e.g. solución clásica).

Ejemplo rollo suizo (chocorol)

MDS Clásico



isoMDS



Variantes

- Hacer uso de otras distancias, e.g. distancia geodésica en la variedad

Variantes


- Hacer uso de otras distancias, e.g. distancia geodésica en la variedad
- Si la distancia geodésica es difícil de calcular (común) hacer uso de aproximaciones discretas usando grafos.

Variantes


- ▶ Hacer uso de otras distancias, e.g. distancia geodésica en la variedad
- ▶ Si la distancia geodésica es difícil de calcular (común) hacer uso de aproximaciones discretas usando grafos.
- ▶ Por ejemplo, Isomap (en **R** `isomap` en librería `MASS`):
 1. Conectamos cada punto con sus K vecinos más cercanos (o los que caigan en una bola de radio ϵ).
 2. Aproximamos la matriz de distancias geodésicas a través del camino más corto en la red (algoritmo de Dijkstra o Floyd-Warshall)
 3. Usamos escalamiento multidimensional clásico en la matriz de distancias.

Ejemplo rollo suizo (chocorol)

Isomap $K = 7$




Isomap $K = 9$



Ejemplo rollo suizo (chocorol)

Isomap $K = 5$



Isomap $K = 10$

