Análisis de Componentes Principales (PCA)

Introducción

- Motivación

  Visualizar y/o interpretar datos multivariados es complicado

- A grandes rasgos PCA es un método estadístico que busca

  1. “Reducir” la dimensionalidad de los datos
  2. Retener la mayor cantidad de la variación original

- ¿Cómo?

  Crear un nuevo conjunto de variables no correlacionadas y ordenadas por varianza

Intuición

¿Cómo debe girar la cabeza la ballena para comer la mayo cantidad de kril?

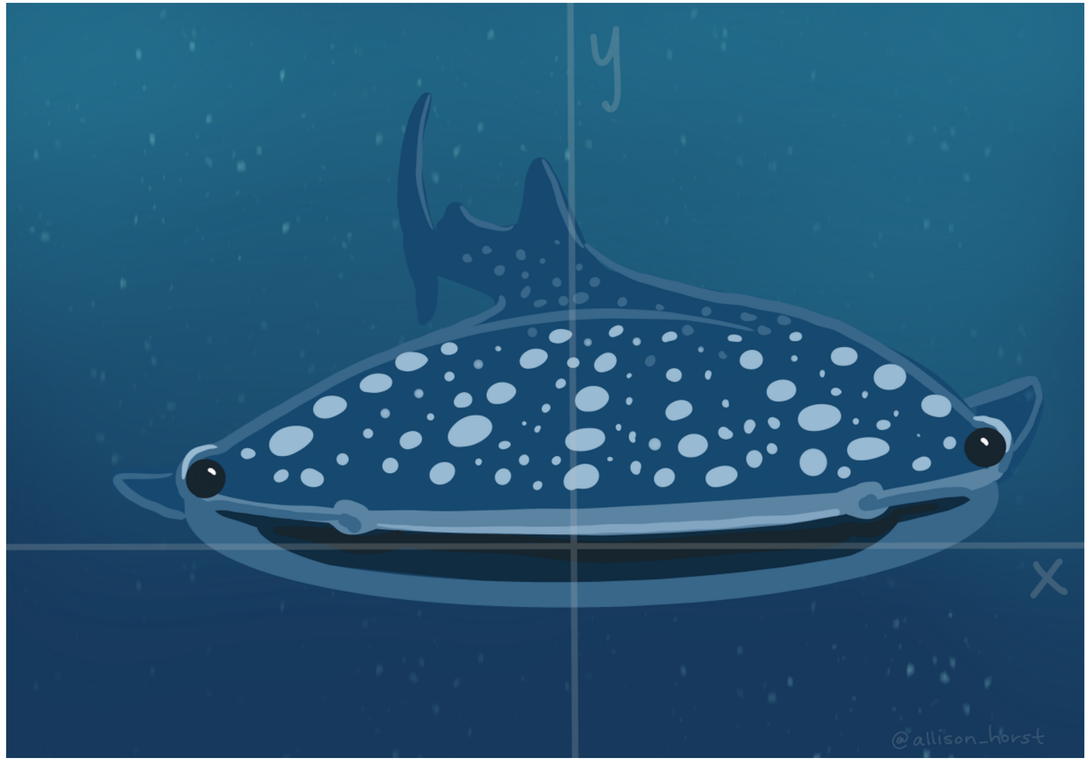

Fuente: Allison Horst (twitter)

Construcción (idea)

- Sea $\mathbf{x}_{p\times 1}$ un vector aleatorio real valuado
- El primer componente principal estará dado por:

$$\alpha_1^T \mathbf{x} = \alpha_{11}x_1 + \alpha_{12}x_2 + \cdots + \alpha_{1p}x_p = \sum_{j=1}^{p} \alpha_{1j}x_j$$

tal que sea la combinación lineal de **mayor varianza.**

- El segundo componente principal estará dado por:

$$\alpha_2^T \mathbf{x} = \alpha_{21}x_1 + \alpha 22x_2 + \cdots + \alpha_{2p}x_p = \sum_{j=1}^{p} \alpha_{2j}x_j$$

tal que sea la combinación lineal de **mayor varianza** y **no esté correlacionado** con el primero.

- Y así sucesivamente hasta llegar a p componentes

Ejemplo

Datos

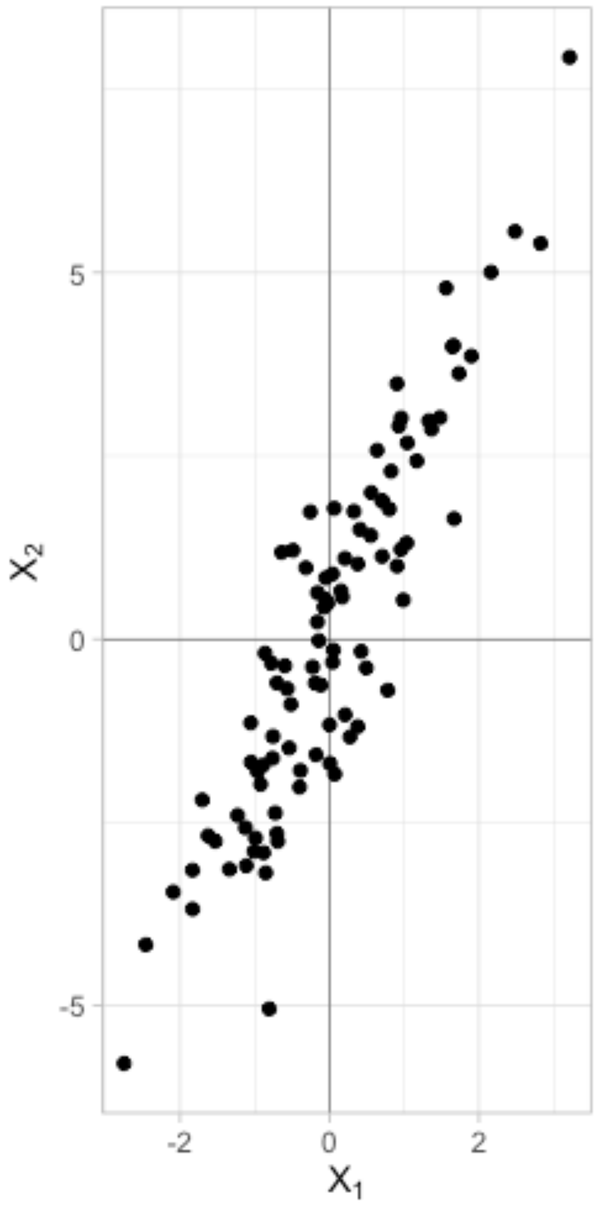

Primer Componente

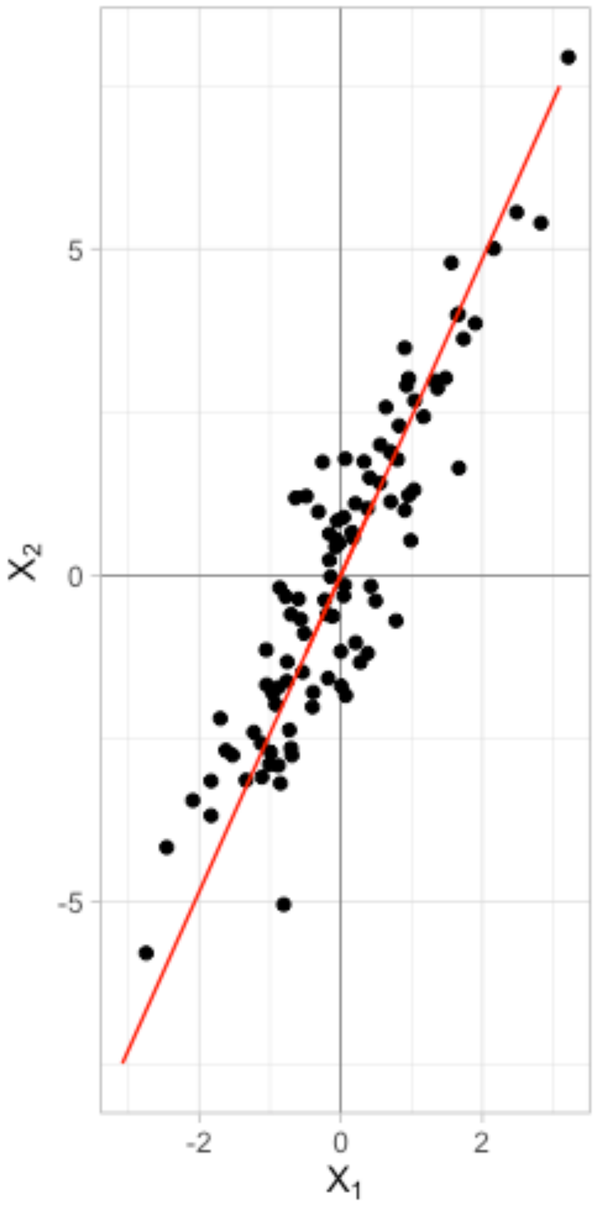

Segundo Componente

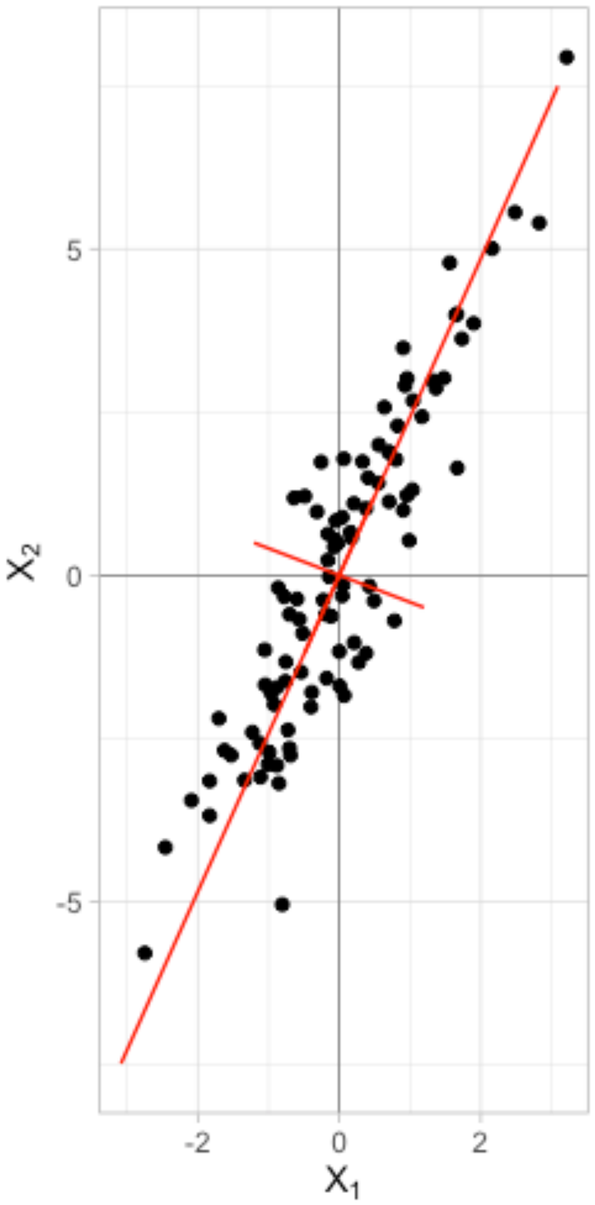

Ejemplo

- Nuevas variables

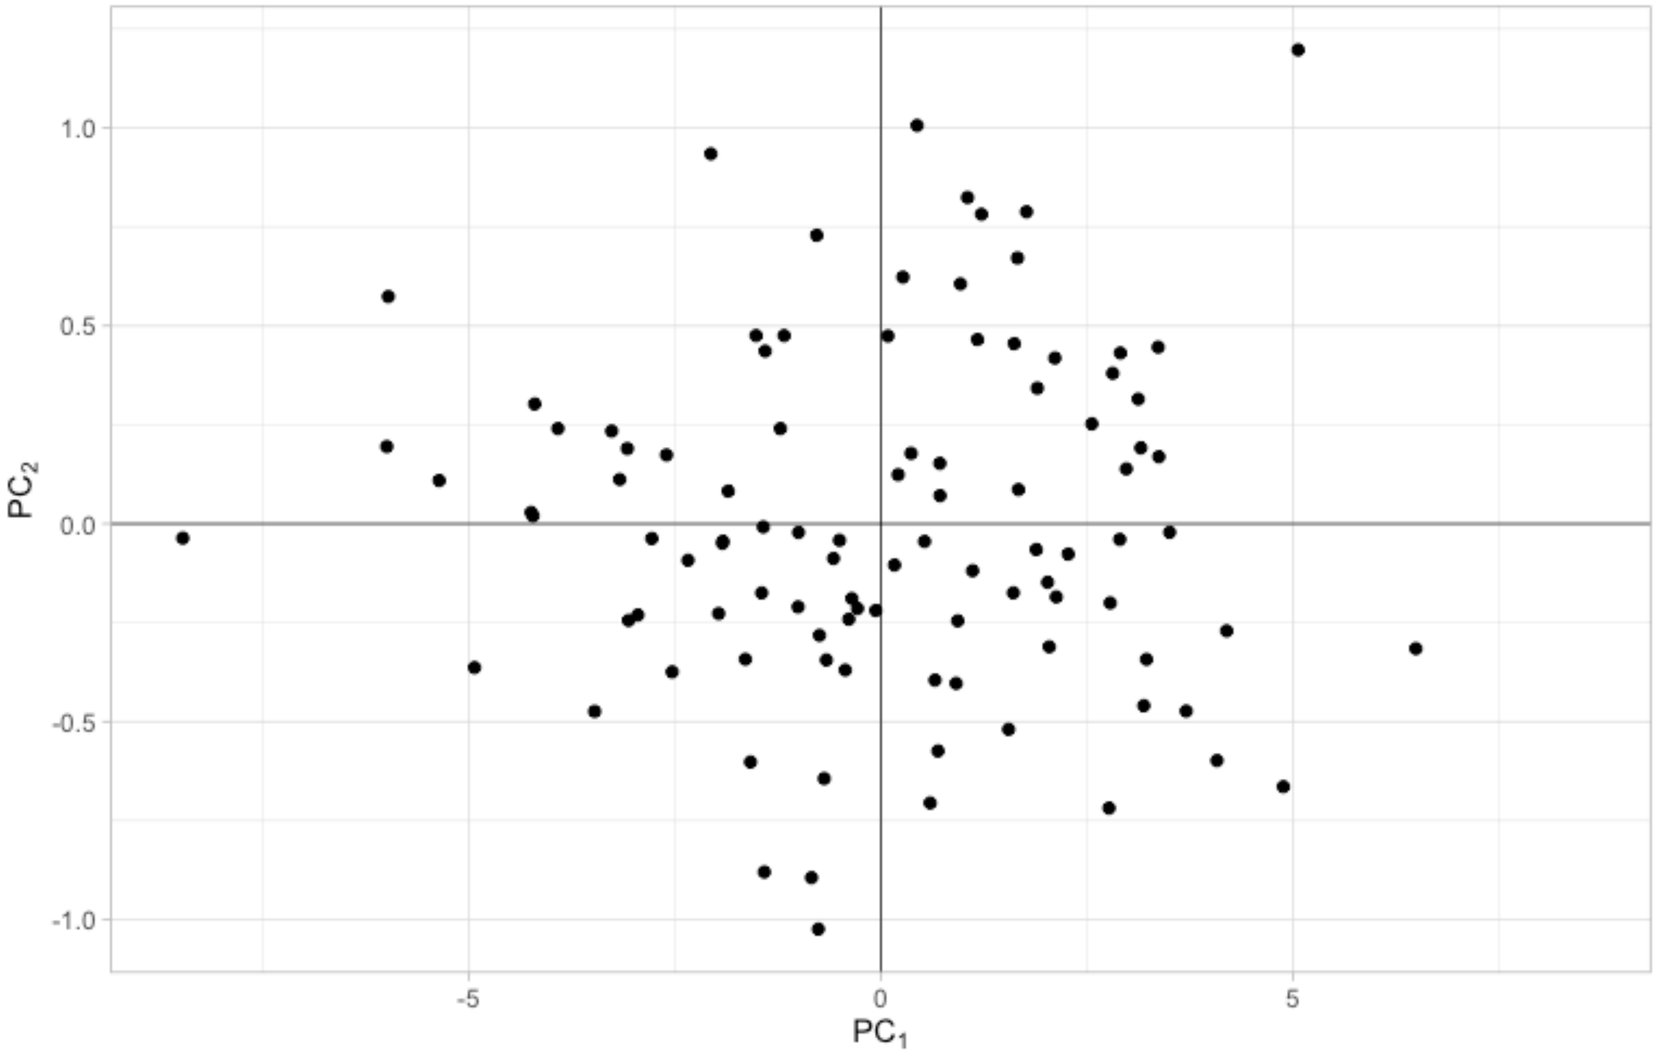

Construcción

Construcción

- Sea $\mathbf{x}_{p\times 1}$ un vector aleatorio real valuado, con Σ conocida

- Formalmente, el primer componente principal se encuentra resolviendo

$$\max_{\alpha_1} \quad \text{var}\left(\alpha_1^T \mathbf{x}\right) = \alpha_1^T \Sigma \alpha_1$$

$$\text{s.a.} \quad \alpha_1^T \alpha_1 = 1$$

- Se resuelve con los multiplicadores de Lagrange

- Dando como resultado que

λ: eigenvalor más grande

α_1: eigenvector asociado

Construcción

- El segundo componente se encuentra resolviendo:

$$\max_{\alpha_2} \quad \text{var}\left(\alpha_2^T x\right) = \alpha_2^T \Sigma \alpha_2$$

$$\text{s.a.} \quad \alpha_2^T \alpha_2 = 1$$

$$\text{cov}\left(\alpha_1^T \mathbf{x}, \alpha_2^T \mathbf{x}\right) = 0$$

- Se resuelve con los multiplicadores de Lagrange

- Dando como resultado que

  λ : segundo eigenvalor más grande

  α_2 : eigenvector asociado

- Y así sucesivamente...

Interpretación geométrica

Observación 1

Los componentes principales corresponden a una transformación ortogonal de $\mathbf{x}$, dada por $\mathbf{z} = \mathbf{A}^T\mathbf{x}$, donde $\mathbf{A}$ es la matriz de vectores propios y así var $\left(z_k\right) = \lambda_k$.

Proposición 1

Sea la familia de elipsoides dada por $\mathbf{x}^T\Sigma^{-1}\mathbf{x} = c$, entonces los componentes principales definen los ejes principales.

Interpretación geométrica

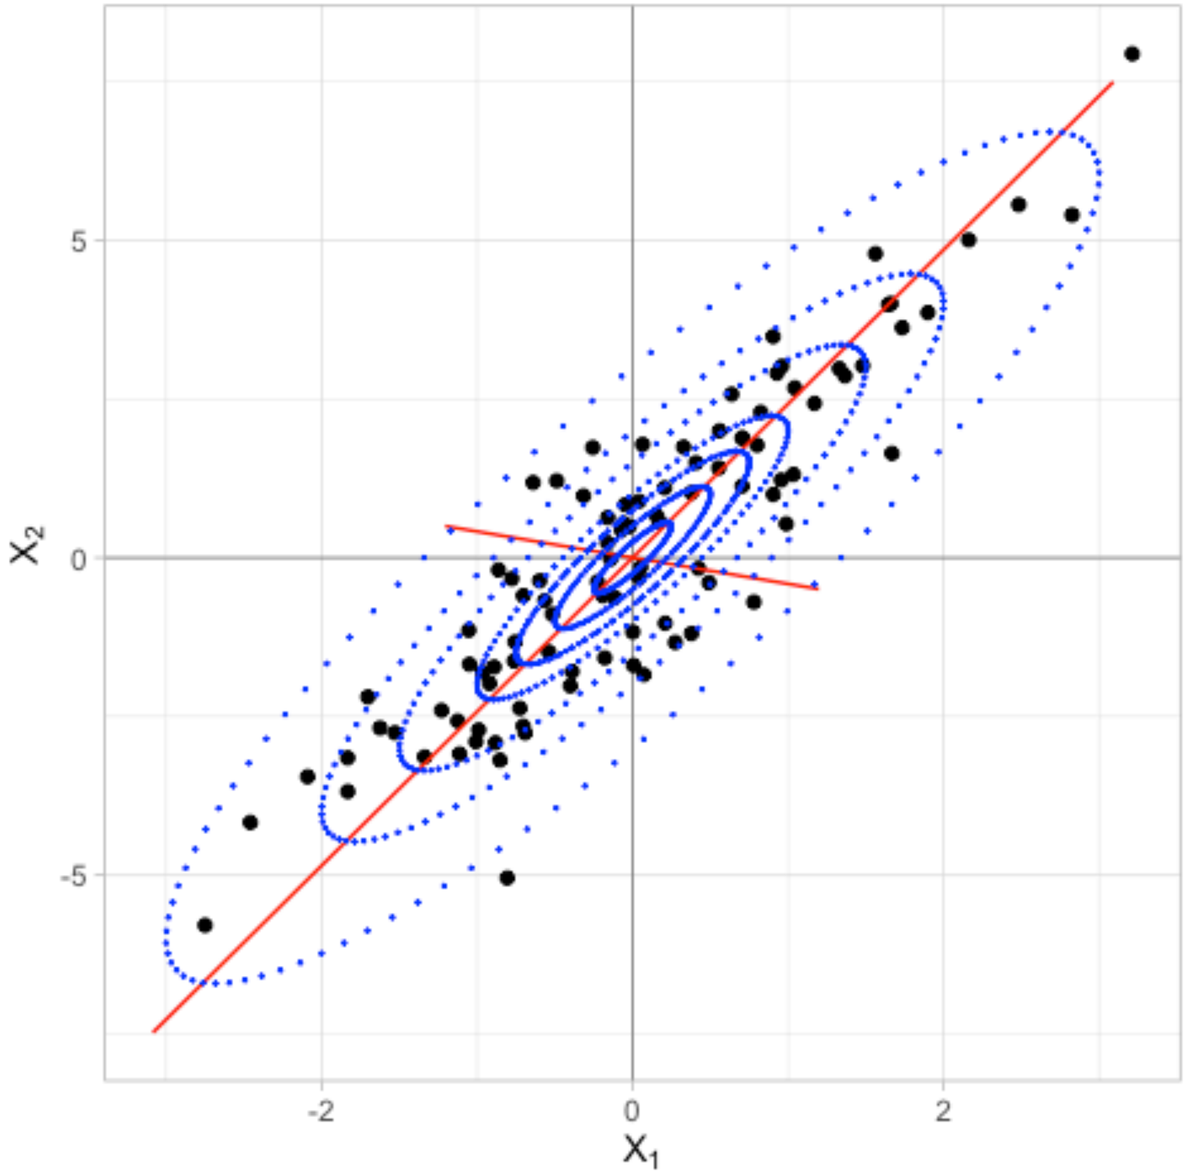

Propiedades algebraicas

Propiedad 1

Sea la transformación ortogonal $\mathbf{y} = \mathbf{B}^T\mathbf{x}$, donde $\mathbf{B}_{q\times p}$ y $\Sigma_y = \mathbf{B}^T\Sigma\mathbf{B}$ entonces,

1. $\text{tr}(\Sigma_y)$ y $|\Sigma_y|$ se maximizan cuando $\mathbf{B} = \mathbf{A}_q$ (las primeras q columnas)

2. $\text{tr}(\Sigma_y)$ se minimiza cuando $\mathbf{B} = \mathbf{A}_q^*$ (las últimas q columnas)

Propiedad 2

La descomposición espectral de Σ está dada por $\Sigma = \sum_{i=1}^{p} \lambda_i \alpha_i \alpha_i^T$

Propiedad 3

Si σ_j^2 es la varianza residual de predecir x_j en términos de $\mathbf{y}$, entonces $\sum \sigma_i^2$ se minimiza cuando $\mathbf{B} = \mathbf{A}_q$

Componentes muestrales

Componentes principales muestrales

- Sea $\mathbf{x}_1, \ldots, \mathbf{x}_n$ una muestra aleatoria (centrada) con matriz de covarianzas muestral

$$\mathbf{S} = \frac{1}{n-1}\mathbf{X}^T\mathbf{X}$$

entonces:

1. El primer componente es el vector propio $\mathbf{a}_1$ asociado al valor propio más grande de $\mathbf{S}$
2. Se tienen n nuevas variables $z_{i1} = \mathbf{a}_1^T\mathbf{x}_i$
3. Y sucesivamente para los otros componentes

Observación 2

1. A los vectores $\{\mathbf{z}_i\}_i$ se les conoce como scores
2. A los vectores propios $\{\mathbf{a}_i\}_i$ se les conoce como loadings (o cargas)

Consideraciones prácticas

Observación 3

Computacionalmente es preferible utilizar la descomposición en valores singulares (SVD) para encontrar los componentes principales

$$\mathbf{S} = \frac{1}{n-1}\mathbf{W}^T\mathbf{W} \qquad \mathbf{W} = \mathbf{U}\mathbf{D}\mathbf{V}^T \qquad \mathbf{S} = \mathbf{V}\Lambda\mathbf{V}^T.$$

Esto debido a que:

1. Numéricamente más estable.
2. Permite considerar el caso $p > n$.
3. Puede ser más rápido.

Consideraciones prácticas

Proposición 2

Sea $\mathbf{Z} = \mathbf{HXV}$ la matriz de cargas, i.e., $\mathbf{z}_i = \mathbf{V}^T(\mathbf{x}_i - \bar{\mathbf{x}})$ entonces se cumple:

1. La media muestral es el vector de ceros
2. La matriz de covarianzas es Λ
3. $\mathbf{v_1}^T\mathbf{S}\mathbf{v_1} > \mathbf{v_2}^T\mathbf{S}\mathbf{v_2} > \cdots > \mathbf{v_p}^T\mathbf{S}\mathbf{v_p}$ y si $\text{ran}(S) = q < p$ se tiene que $\mathbf{v_s}^T\mathbf{S}\mathbf{v_s} = 0$ para $s = q + 1, \ldots, p$
4. $\sum_{i=1}^{p} \mathbf{v_i}^T\mathbf{S}\mathbf{v_i} = \sum_{i=1}^{p} \lambda_i = \text{tr}(S)$
5. $\prod_{i=1}^{p} \mathbf{v_i}^T\mathbf{S}\mathbf{v_i} = \prod_{i=1}^{p} \lambda_i = |S|$

Consideraciones prácticas

Observación 4

Dependiendo de la naturaleza de los datos muchas veces es preferible definir a los componentes principales con variables estandarizadas. Esto permite que:

1. Todas las propiedades sigan siendo válidas
2. Se pueden mezclar variables en diferentes escalas
3. Los componentes no estén dominados por una posible variable de mayor varianza

Ejemplo: Calificaciones

- 88 calificaciones de 5 exámenes a libro abierto o cerrado

Alumno	Lineal (C)	Estadística (C)	Probabilidad(A)	Finanzas (A)	Cálculo (A)
1	97	92	77	72	96
2	83	88	90	75	96
3	95	83	81	71	96
4	75	82	73	75	83
5	83	73	75	75	78
.	.	.	.	.	.
.	.	.	.	.	.
87	25	36	25	25	35
88	20	50	31	14	29

- En R usamos prcomp() con $\widehat{\Sigma} = \mathbf{S}$

Ejemplo: Calificaciones

- Los valores propios (varianzas de los componentes) resultantes son:

$$\lambda_1 = 689.6583 > \lambda_2 = 200.9016 > \lambda_3 = 103.5280 > \lambda_4 = 83.3404 > \lambda_5 = 32.2476$$

- Los vectores de cargas:

Lineal (C)	-0.502	-0.759	0.289	-0.284	-0.080
Estadística (C)	-0.371	-0.188	-0.417	0.785	-0.186
Probabilidad (A)	-0.345	0.077	-0.144	-0.002	0.923
Finanzas (A)	-0.450	0.299	-0.591	-0.523	-0.287
Cálculo (A)	-0.535	0.541	0.609	0.164	-0.149

Ejemplo: Calificaciones

- El primer componente es un “promedio”

$-0.502 \cdot$ Lineal $- 0.371 \cdot$ Estadística $- 0.345 \cdot$ Proba. $- 0.450 \cdot$ Finanzas $- 0.535 \cdot$ Cálculo

- El segundo componente es una comparación entre libro abierto y cerrado

$-0.759 \cdot$ Lineal $- 0.188 \cdot$ Estadística $+ 0.077 \cdot$ Proba. $+ 0.299 \cdot$ Finanzas $+ 0.541 \cdot$ Cálculo

- El tercer componente es una comparación entre matemáticas “puras y aplicadas”

$0.289 \cdot$ Lineal $- 0.417 \cdot$ Estadística $- 0.144 \cdot$ Proba. $- 0.591 \cdot$ Finanzas $+ 0.609 \cdot$ Cálculo

- El cuarto componente (¿?)

$-0.284 \cdot$ Lineal $+ 0.785 \cdot$ Estadística $- 0.002 \cdot$ Proba. $- 0.523 \cdot$ Finanzas $+ 0.164 \cdot$ Cálculo

- El quinto componente (¿?)

$-0.080 \cdot$ Lineal $- 0.186 \cdot$ Estadística $+ 0.923 \cdot$ Proba. $- 0.287 \cdot$ Finanzas $- 0.149 \cdot$ Cálculo

Otras consideraciones

- La interpretación de los componentes requiere conocimiento del problema
  - Algunos componentes pueden interpretarse como un promedio ponderado
  - Algunos componentes pueden discriminar entre grupos de variables
  - Esto no siempre se cumple, a veces no es posible encontrarles significado
- **¿Cuántos componentes elegir?**

Número de componentes

- Seleccionar los componentes que expliquen un cierto porcentaje de la variación (por ejemplo, 70%, 80%, 90%, etc.)

- Usar la regla de codo

- Otros (e.g. pruebas de hipótesis)

- **Regla de Kaiser.** Retener los componentes con varianza mayor a cierto valor (e.g. >.7) (para PCA con matriz de correlación)

Ejemplo: Calificaciones

- La variación explicada por los componentes

  61.91% 18.21% 9.35% 7.63% 2.90%

- Nos quedamos con los primeros dos para tener arriba del 80% de la variación total (80.12%)

- Nos quedamos con los primeros tres para tener casi 90% de la variación total (89.47%)

Ejemplo: Calificaciones

- Regla de codo: graficar las varianzas (en **R** función screeplot)

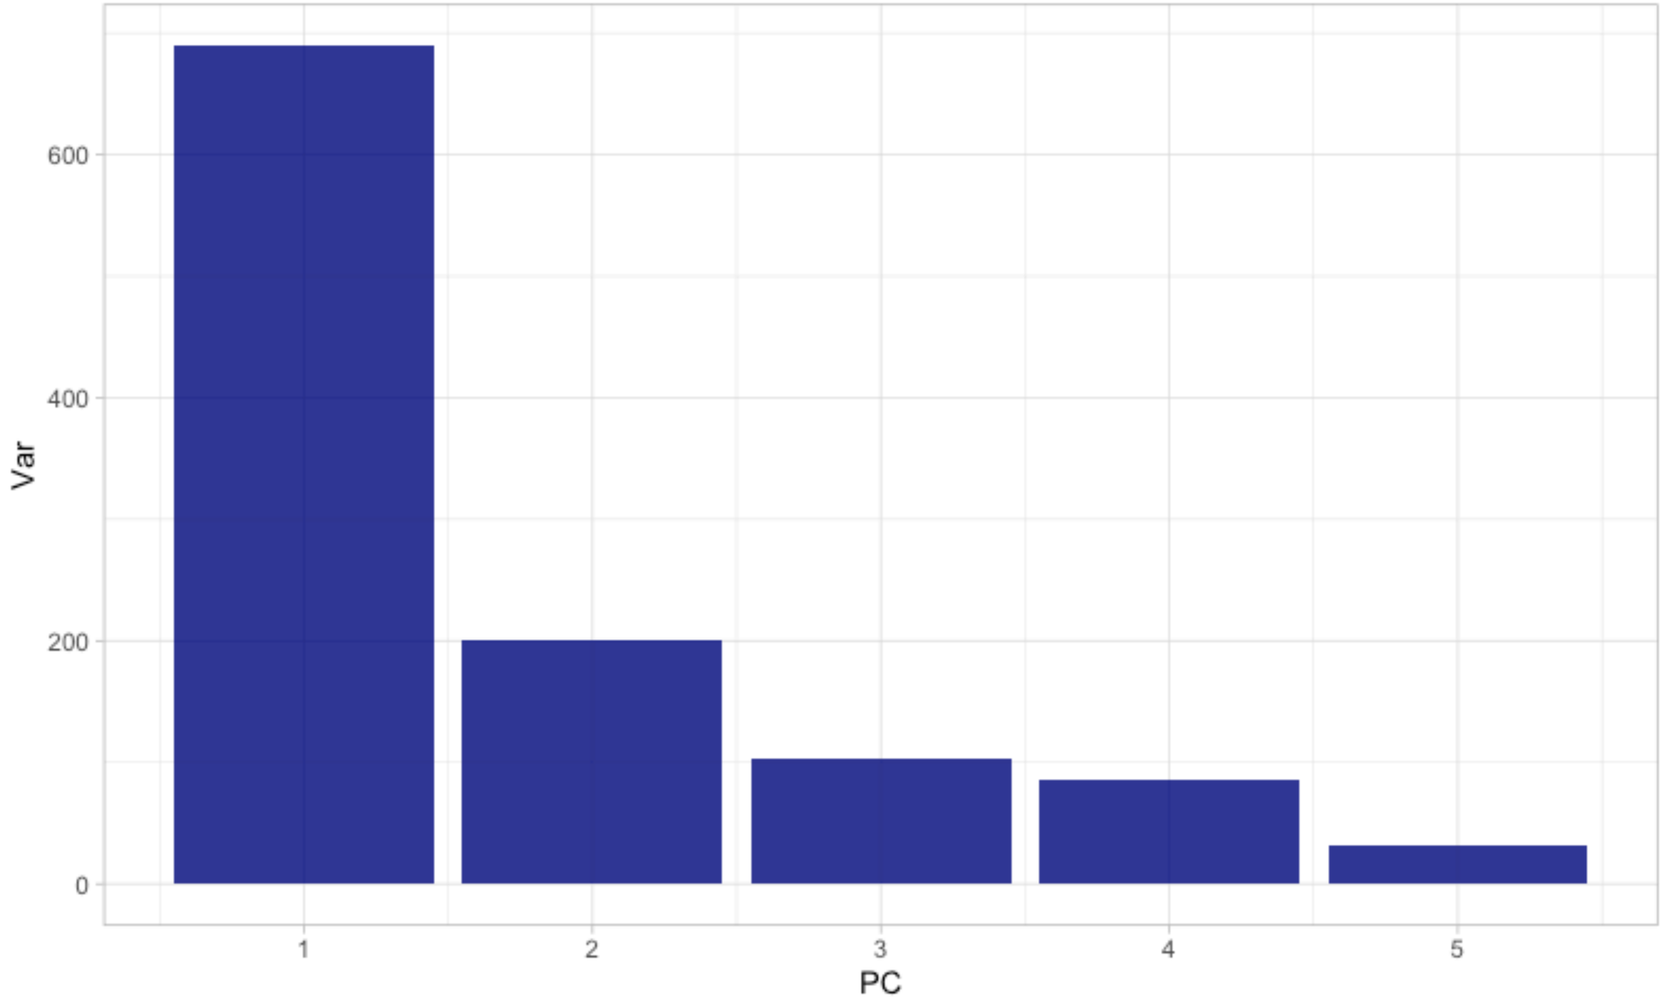

Ejemplo: Calificaciones

- Los valores propios resultantes de hacer PCA con la matriz de correlación

$$\lambda_1 = 3.1862 > \lambda_2 = 0.7287 > \lambda_3 = 0.4473 > \lambda_4 = 0.3917 > \lambda_5 = 0.2461$$

- Los vectores de cargas:

Lineal (C)	-0.397	-0.664	0.612	-0.091	-0.131
Estadística (C)	-0.432	-0.420	-0.740	0.234	-0.179
Probabilidad (A)	-0.502	0.129	-0.021	-0.116	0.846
Finanzas (A)	-0.456	0.389	-0.064	-0.674	-0.425
Cálculo (A)	-0.439	0.461	0.268	0.684	-0.230

Ejemplo: Calificaciones

- Si son dos componentes se pueden graficar (librería factoextra en R)

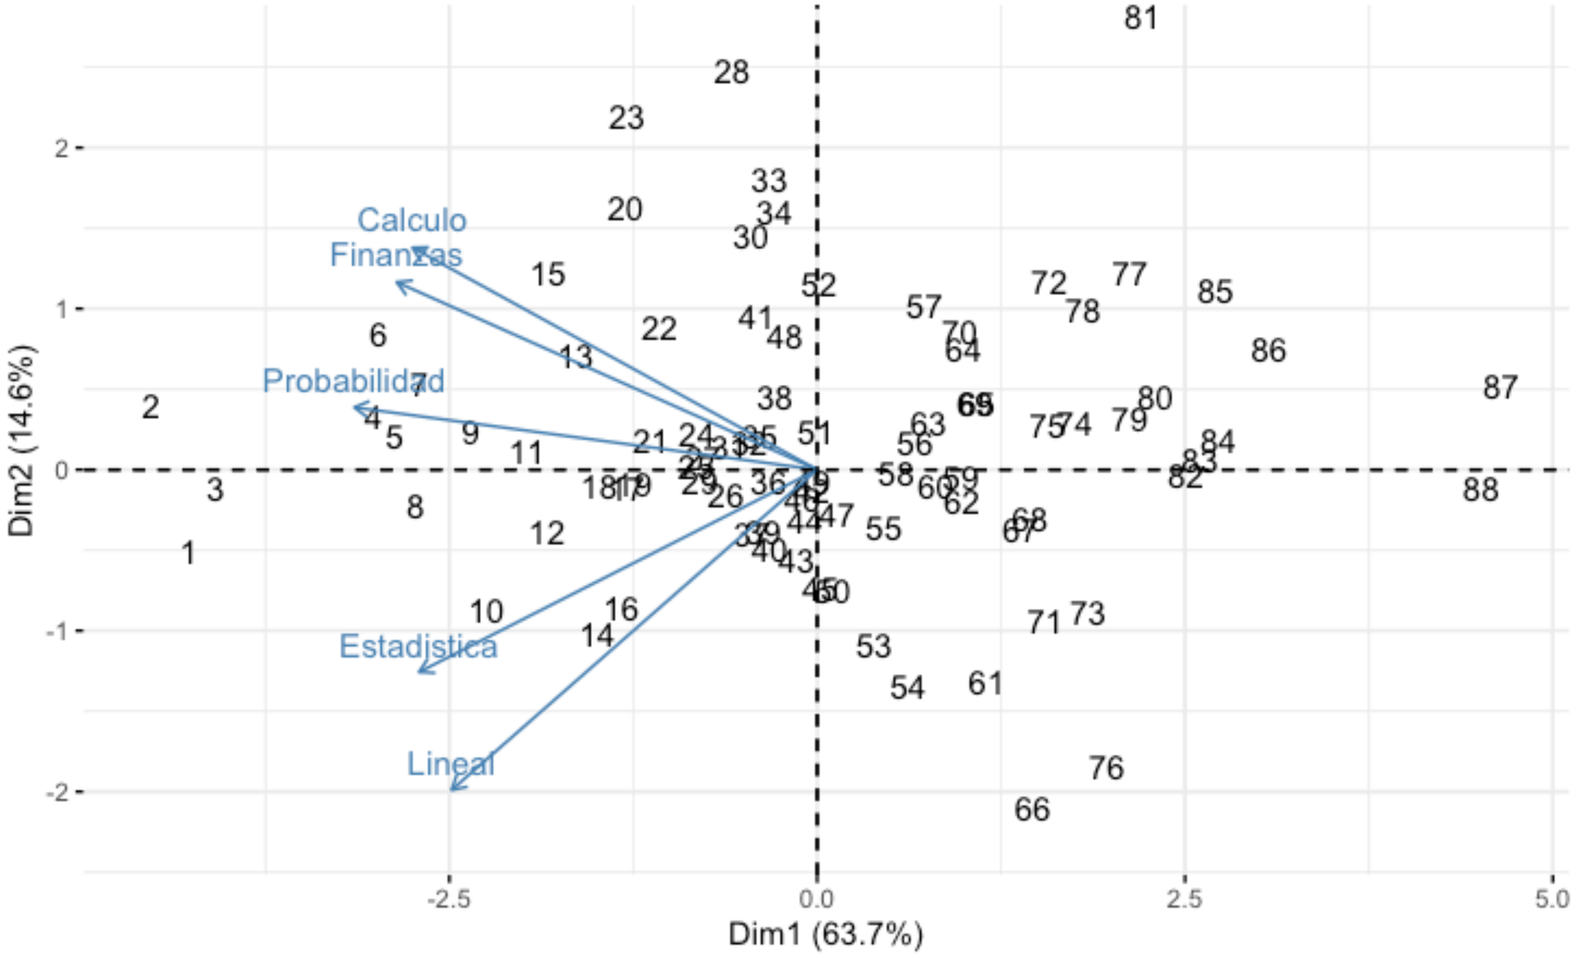

Ejemplo: Calificaciones

- Con el PC1, se pueden identificar los mejores y peores promedios

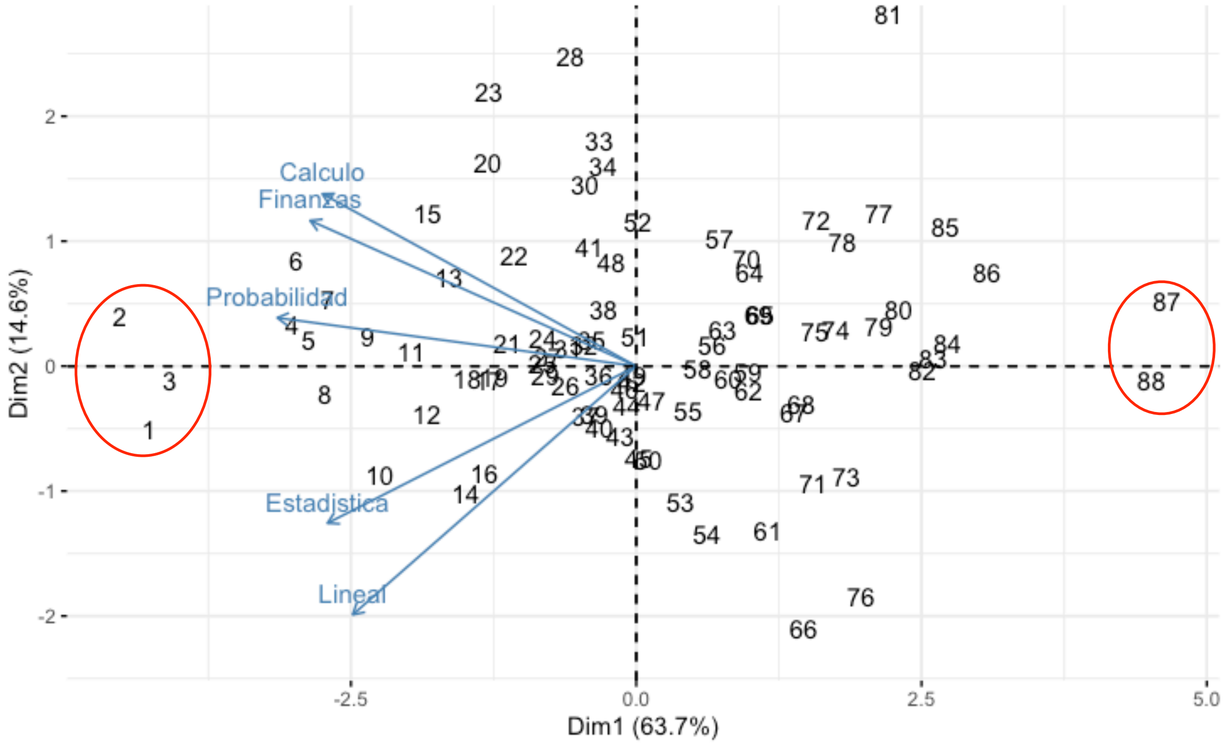

Alumno	Lineal	Est.	Proba.	Finanzas	Cálculo
1	97	92	77	72	96
2	83	88	90	75	96
3	95	83	81	71	96

Alumno	Lineal	Est.	Proba.	Finanzas	Cálculo
87	25	36	25	25	35
88	20	50	31	14	29

Ejemplo: Calificaciones

- Con el PC2, se pueden identificar las mejores y peores calificaciones en examen abierto y cerrado

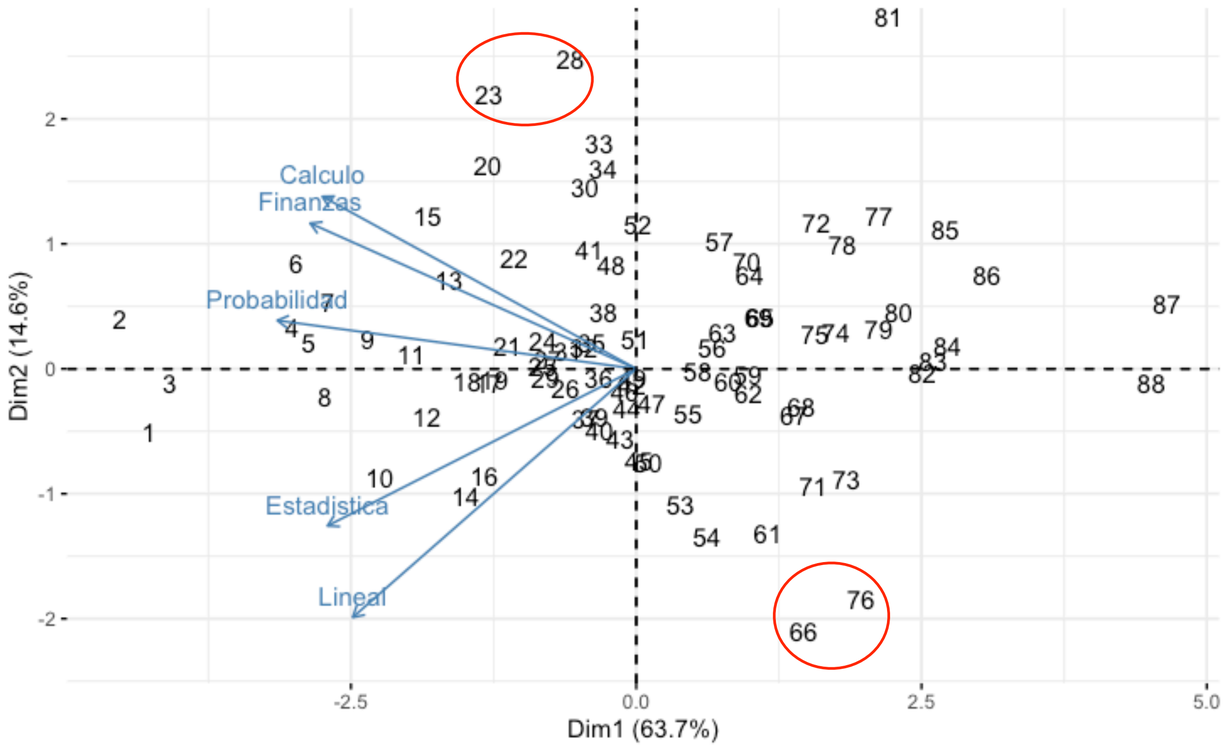

Alumno	Lineal	Est.	Proba.	Finanzas	Cálculo
66	79	63	47	27	34
76	69	60	48	28	24

Alumno	Lineal	Est.	Proba.	Finanzas	Cálculo
23	38	54	60	62	96
28	32	68	72	68	82

Ejemplo: Pizzas

- 300 observaciones de 7 valores nutricionales en 10 marcas de pizza diferentes

1. **Mois:** Cantidad de agua por cada 100g
2. **Prot**: Cantidad de proteína por cada 100g
3. **Fat**: Cantidad de grasa por cada 100g
4. **Ash**: Cantidad de ceniza por cada 100g
5. **Sodium**: Cantidad de sodio por cada 100g
6. **Carb**: Cantidad de carbohidratos por cada 100g
7. **Cal**: Cantidad de calorías por cada 100g

- PCA con matriz de covarianzas, prcomp(...,scale=F)

Ejemplo: Pizzas

- La raíz cuadrada de los valores propios (desviación estándar) resultantes

$$\lambda_1 = 20.53 > \lambda_2 = 10.09 > \lambda_3 = 4.10 > \lambda_4 = 0.42 > \lambda_5 = 0.09 > \lambda_6 = 0.03 > \lambda_7 = 0.01$$

- Los vectores de cargas:

Moisture	0.2769	-0.7470	0.3520	0.1958	0.0594	-0.4409	0.0698
Protein	0.2669	0.0557	-0.8097	0.2557	0.0837	-0.4434	0.0299
Fat	0.2789	0.6578	0.4679	0.2598	0.0357	-0.4486	-0.0198
Ash	0.0554	0.0406	-0.0222	-0.8714	-0.1666	-0.4502	0.0700
Sodium	0.0111	0.0238	0.0262	-0.2014	0.9783	0.0304	0.0025
Carbs	-0.8780	-0.0068	0.0124	0.1645	0.0574	-0.4444	0.0299
Calories	0.0006	0.0612	0.0100	0.0406	0.0014	0.0804	0.9939

Ejemplo: Pizzas

- Problemas por la escala/unidades/varianza de las variables

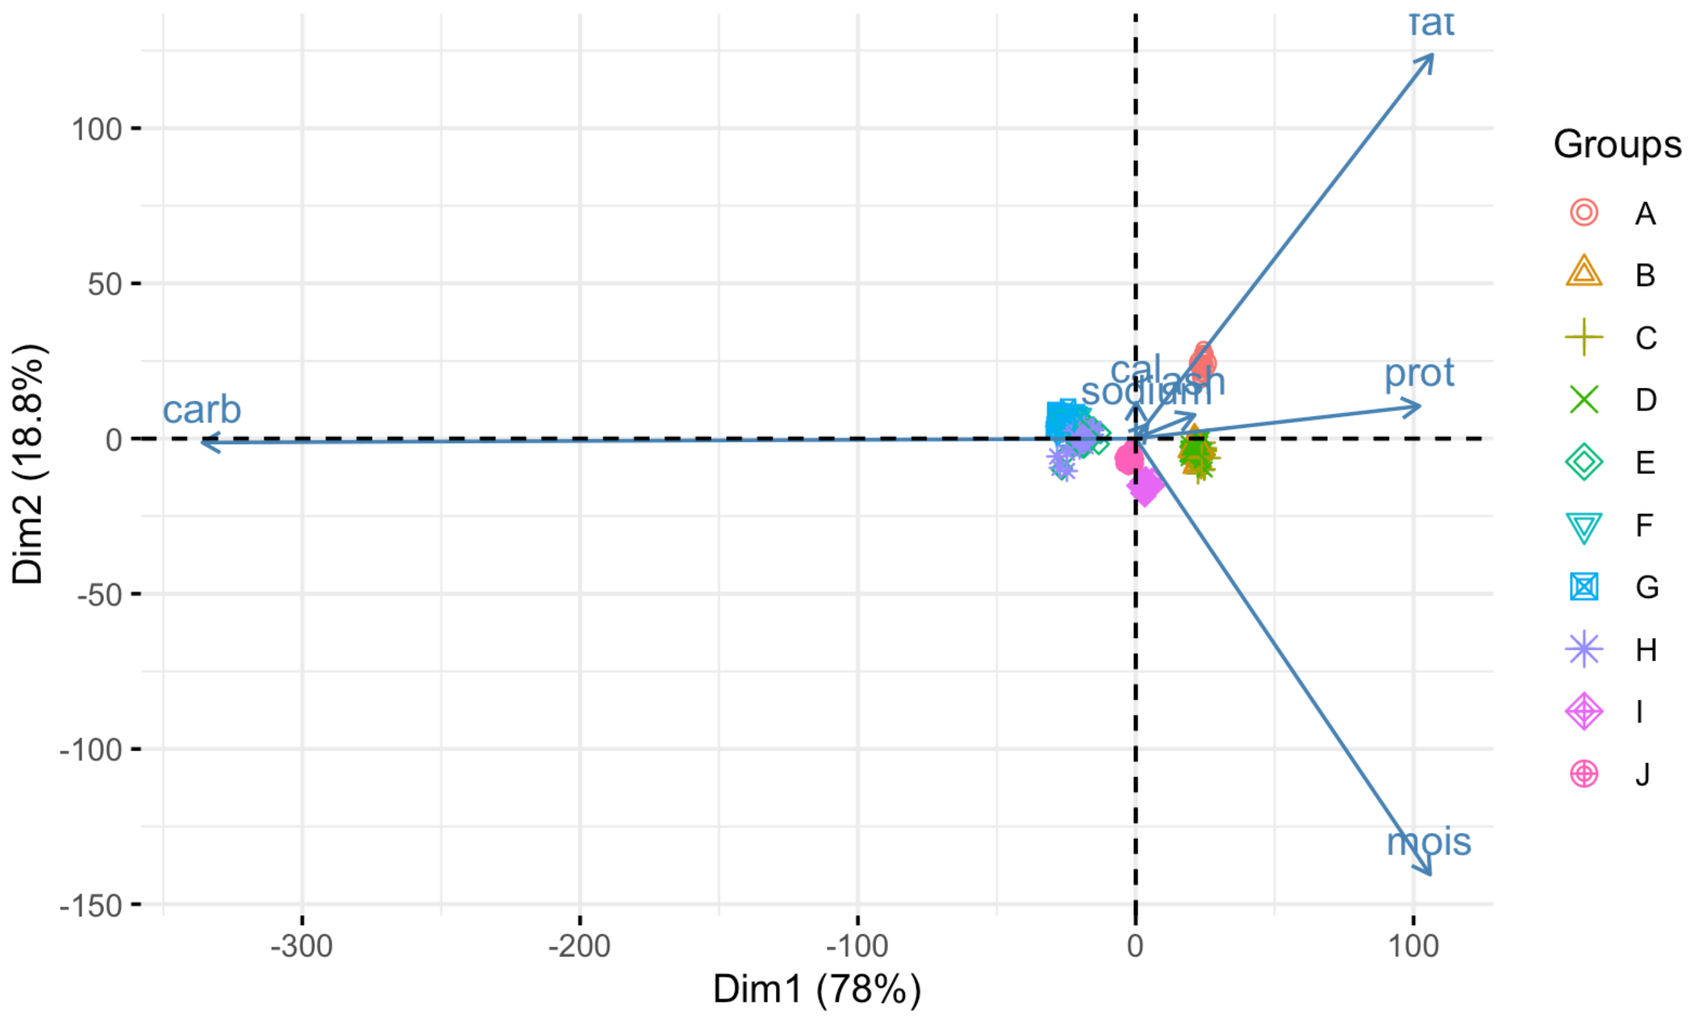

Ejemplo: Pizzas

- PCA con matriz de correlación

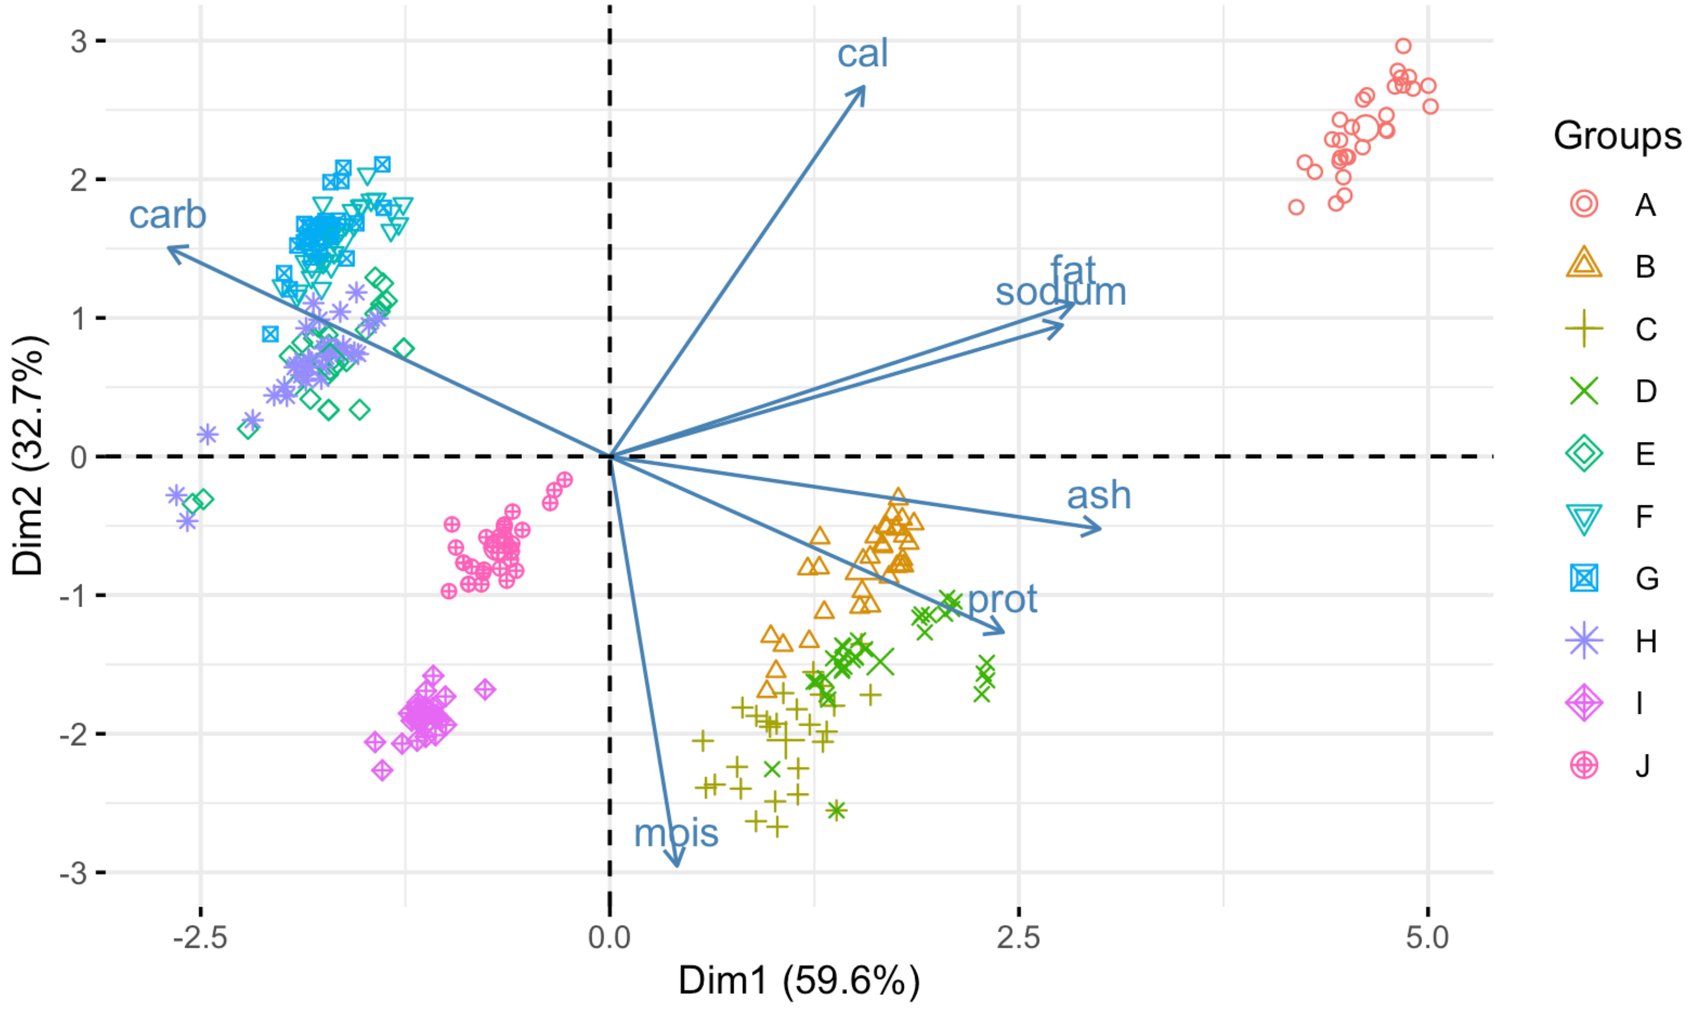

Ejemplo: Pizzas

- El primer componente es

$$0.064 \cdot \text{mois} + 0.378 \cdot \text{prot} + 0.446 \cdot \text{fat} + 0.471 \cdot \text{ash}$$
$$+0.435 \cdot \text{sodium} - 0.424 \cdot \text{carb} + 0.244 \cdot \text{cal}$$

- El segundo componente es

$$-0.628 \cdot \text{mois} - 0.269 \cdot \text{prot} + 0.234 \cdot \text{fat} - 0.110 \cdot \text{ash}$$
$$+0.201 \cdot \text{sodium} + 0.320 \cdot \text{carb} + 0.567 \cdot \text{cal}$$

- Ya no hay interpretación directa ni sencilla

PCA y más allá

Aplicaciones y temas relacionados

- Selección de variables (problema NP-difícil)
- PCA + otros modelos/técnicas multivariadas (e.g. SVM, análisis de discriminantes, regresión, etc.)
- Detección de outliers y observaciones influyentes (analizando los primeros y los últimos componentes)
- Rotación de componente principales (para una mejor interpretación como en análisis de factores)
- Otro tipo de datos (e.g. series de tiempo, datos no independientes, discretos, etc.)

Regresión por componentes principales

Regresión múltiple

- Suponer que se tiene un modelo de regresión lineal múltiple

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_p x_p + \epsilon$$

- Si no hay relación lineal entre las variables $x_1, \ldots, x_p$ el proceso de inferencia es sencillo

- Para un conjunto de n observaciones $\{y_i, x_{i1}, \ldots, x_{ip}\}_{i=1}^n$ el EMV de β es

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

- $\hat{\beta}$ es el mejor estimador lineal insesgado (BLUE)

Multicolinealidad

- Se dice que hay un problema de **multicolinealidad** si las variables son (aproximadamente) linealmente dependientes

- Este problema genera que $(\mathbf{X}^T\mathbf{X})$ sea casi singular por lo que
  - $\text{Var}(\hat{\beta}_j) \to \infty$
  - $\text{Cov}(\beta_i, \beta_j) \to \pm\infty$

- Como infla las varianzas y covarianzas, las soluciones no son estables

- Se puede diagnosticar con los factores de inflación de varianza

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$