

Análisis Multivariado: Tarea 1

Análisis Descriptivo de Datos Multivariados

Fecha de entrega: 28 de febrero

1. (1 punto) Para un punto \mathbf{x} en \mathbb{R}^p , con $p > 1$, considerar para $t \in [-\pi, \pi]$ el mapeo $f : \mathbb{R}^p \rightarrow \mathbb{R}$, definido como:

$$f_{\mathbf{x}}(t) = \begin{cases} \frac{x_1}{\sqrt{2}} + x_2 \sin(t) + x_3 \cos(t) + x_4 \sin(2t) + x_5 \cos(2t) + \cdots + x_p \sin\left(\frac{p}{2}t\right) & \text{si } p \text{ es par} \\ \frac{x_1}{\sqrt{2}} + x_2 \sin(t) + x_3 \cos(t) + x_4 \sin(2t) + x_5 \cos(2t) + \cdots + x_p \cos\left(\frac{(p-1)}{2}t\right) & \text{si } p \text{ es impar.} \end{cases}$$

Mostrar lo siguiente:

- i. La transformación preserva medias, esto es, para una colección de puntos $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^p$,

$$f_{\bar{\mathbf{x}}}(t) = \frac{1}{n} \sum_{i=1}^n f_{\mathbf{x}_i}(t).$$

- ii. Para dos puntos \mathbf{x}, \mathbf{y} en \mathbb{R}^p , se cumple que,

$$\|f_{\mathbf{x}}(t) - f_{\mathbf{y}}(t)\|_{L_2} = \int_{-\pi}^{\pi} [f_{\mathbf{x}}(t) - f_{\mathbf{y}}(t)]^2 dt = \pi \|\mathbf{x} - \mathbf{y}\|^2.$$

¿Cómo se relaciona esta propiedad con la identificación de clusters y outliers?

- iii. Asumiendo no correlación y varianza constante, σ^2 , demuestra que para p impar,

$$\text{Var}(f_{\mathbf{x}}(t)) = \sigma^2 \left(\frac{p}{2} \right),$$

y para p par, i.e. $p = 2r$, se cumple que,

$$\sigma^2 \left(r - \frac{1}{2} \right) \leq \text{Var}(f_{\mathbf{x}}(t)) \leq \sigma^2 \left(r + \frac{1}{2} \right),$$

¿Qué puedes concluir sobre la varianza con respecto a p ? ¿Qué tan adecuados son los supuestos para datos multivariados?

2. (1 punto) Mostrar que si \mathbf{H}_n es la matriz de centrado definida como,

$$\mathbf{H}_n = \mathbf{I}_{n \times n} - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^T,$$

entonces,

- i. \mathbf{H}_n es simétrica.
- ii. \mathbf{H}_n es idempotente.
- iii. Para una matriz de datos $\mathbf{X}_{n \times p}$, la media muestral de $\mathbf{W} = \mathbf{H}_n \mathbf{X}$ es el vector $\mathbf{0}_p$.
- iv. La matriz de varianza y covarianza muestral de \mathbf{X} , se puede escribir como,

$$\mathbf{S} = \frac{1}{n-1} (\mathbf{X}^T \mathbf{H}_n \mathbf{X}).$$

3. (1 punto) Sea \mathbf{B} una matriz cuadrada, tal que $\mathbf{B} = \mathbf{A}^T \mathbf{A}$, donde $\mathbf{A}_{n \times p}$, entonces:

- i. \mathbf{B} es simétrica.
- ii. \mathbf{B} es semidefinida positiva.

Utilizando este resultado justifica y concluye que la matriz de covarianzas muestral y la matriz de correlaciones muestral son semidefinidas positivas.

4. (1 punto) Mostrar que si \mathbf{x} es un vector p -variado donde, $\Sigma = \text{Var}(\mathbf{x})$, entonces $\text{Det}(\Sigma) \geq 0$.
5. (1 punto) Sean \mathbf{x} y \mathbf{y} dos vectores aleatorios independientes.

- i. Demostrar que para constantes reales α y β se tiene que,

$$\text{Var}(\alpha \mathbf{x} + \beta \mathbf{y}) = \alpha^2 \text{Var}(\mathbf{x}) + \beta^2 \text{Var}(\mathbf{y}).$$

- ii. Encontrar una fórmula para el caso no independiente y expresarla en términos de $\text{Var}(\mathbf{x})$, $\text{Var}(\mathbf{y})$ y $\text{Cov}(\mathbf{x}, \mathbf{y})$.

6. (1 punto) Sea $\mathbf{X}_{n \times p}$ una matriz de datos. Considera la transformación,

$$\mathbf{Y} = \mathbf{X} \mathbf{A}^T + \mathbf{1}_n \mathbf{b}^T,$$

donde $\mathbf{A}_{q \times p}$ y $\mathbf{b}_{q \times 1}$ son constantes. Mostrar que

$$\mathbf{S}_Y = \mathbf{A} \mathbf{S}_X \mathbf{A}^T.$$

7. (1 punto) Para una matriz de datos, \mathbf{X} , considera las siguientes dos transformaciones,

i. $\mathbf{Y} = \mathbf{H}_n \mathbf{X} \mathbf{D}^{-1}$

ii. $\mathbf{Z} = \mathbf{H}_n \mathbf{X} \mathbf{S}^{-\frac{1}{2}}$,

donde \mathbf{S} es la matriz de varianza y covarianza muestral de \mathbf{X} y $\mathbf{D} = \text{diag}(s_1, \dots, s_p)$. Obtener la media muestra y la matriz de covarianzas de \mathbf{Y} y de \mathbf{Z} . ¿En qué difieren estas dos transformaciones?

8. (1 punto) Para un vector aleatorio \mathbf{x} , tal que $\mathbb{E}(\mathbf{x}) = \mu$ y $\text{Var}(\mathbf{x}) = \Sigma$, definimos a las medidas de asimetría y curtosis respectivamente como:

$$\begin{aligned}\beta_{1,p} &= \mathbb{E} \left([(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{y} - \mu)]^3 \right) \\ \beta_{2,p} &= \mathbb{E} \left([(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu)]^2 \right),\end{aligned}$$

donde \mathbf{x} y \mathbf{y} son independientes e idénticamente distribuidos. Mostrar que estas medidas son invariantes ante transformaciones lineales.

9. (1 punto) El archivo *wine.txt* contiene 13 variables numéricas derivadas de un análisis químico en vinos de Italia de tres viñedos diferentes. Realizar un análisis descriptivo multivariado de los datos.

10. (1 punto) El archivo *Diabetes.txt* contiene 5 mediciones relacionadas con la diabetes de 145 adultos. Realiza un análisis descriptivo de estos datos. ¿Puedes identificar clusters, outliers y/o variables importantes?