

# Análisis Multivariado

## Tarea 5: Análisis de conglomerados y análisis discriminante

Fecha de entrega: 29 de mayo

*Instrucciones.* La tarea se puede realizar en equipos de máximo 3 integrantes. Se entregará física (o digital) a la hora de la clase y no habrá prórroga. Las actividades de DataCamp son opcionales y se podrán terminar hasta el final de la fecha de entrega y contarán como un punto extra sobre la tarea.

1. (1 punto) El método flexible de Lance y Williams establece que podemos definir la distancia de un tercer cluster con dos cluster recién agrupados como

$$d(C_3, C_1 \cup C_2) = \alpha_1 d(C_3, C_1) + \alpha_2 d(C_3, C_2) + \beta d(C_1, C_2) + \gamma |d(C_3, C_1) - d(C_3, C_2)|.$$

Muestra que para los siguientes valores recuperamos las siguientes ligas.

| Liga      | $\alpha_i$                    | $\beta$                        | $\gamma$       |
|-----------|-------------------------------|--------------------------------|----------------|
| Simple    | $\frac{1}{2}$                 | 0                              | $-\frac{1}{2}$ |
| Compuesta | $\frac{1}{2}$                 | 0                              | $\frac{1}{2}$  |
| Centroide | $\frac{n_i}{n_1+n_2}$         | $-\frac{n_1 n_2}{(n_1+n_2)^2}$ | 0              |
| Ward      | $\frac{n_i+n_3}{n_1+n_2+n_3}$ | $-\frac{n_3}{n_1+n_2+n_3}$     | 0              |
| Mediana   | $\frac{1}{2}$                 | $-\frac{1}{4}$                 | 0              |

2. (1 punto) Considerando a  $\mathbf{T}$  la matriz de variación total dada por

$$\mathbf{T} = \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^T = \mathbf{W} + \mathbf{B} = \sum_{i=1}^k \sum_{j=1}^{n_i} (\mathbf{x}_{ij} - \bar{\mathbf{x}}_{i.})(\mathbf{x}_{ij} - \bar{\mathbf{x}}_{i.})^T + \sum_{i=1}^k n_i (\bar{\mathbf{x}}_{i.} - \bar{\mathbf{x}}_{..})(\bar{\mathbf{x}}_{i.} - \bar{\mathbf{x}}_{..})^T$$

donde  $\mathbf{W}$  es la matriz de variación dentro de los clusters (*within-cluster variation*) y  $\mathbf{B}$  es la matriz de variación entre clusters (*between-cluster variation*). Mostrar que para  $k = 2$

- i.  $B$  es una matriz simétrica de rango 1.
- ii. Usando el hecho de que para una matriz  $\mathbf{A}$  simétrica de rango 1 se cumple que

$$|\mathbf{I} - \mathbf{A}| = 1 - \text{tr}(\mathbf{A})$$

mostrar que los siguientes métodos para dividir  $n$  objetos  $p$  dimensionales son equivalentes

(a) Minimizar  $|\mathbf{W}|$

(b) Maximizar  $\text{tr}(\mathbf{B}\mathbf{W}^{-1})$

(c) Minimizar  $\text{tr}(\mathbf{W}\mathbf{T}^{-1})$

(*Hint*: Mostrar  $(a) \Leftrightarrow (c)$  y después  $(b) \Leftrightarrow (c)$ ).

3. (3 puntos) El archivo *NCI.txt* contiene 6830 variables de 64 células cancerígenas de distintos tipos de cáncer. Realizar lo siguiente:

- a) Mediante un análisis de conglomerados (aglomerativo, divisivo y/o fuzzy) estudiar el posible agrupamiento de las células cancerígenas. ¿Qué valor de  $k$  parece más razonable?
- b) Utilizar el algoritmo  $k$ -means con el valor de  $k$  elegido en el inciso anterior y realiza un análisis comparando ambos métodos, el valor de  $k$  elegido y los clusters creados.

4. (1 punto) En un problema de discriminación de dos grupos, asumir que

$$f_i(x) = \binom{n}{x} \theta_i^x (1 - \theta_i)^{n-x}$$

donde  $\theta_1$  y  $\theta_2$  son conocidas. Si  $\pi_1$  y  $\pi_2$  son las probabilidades a priori muestre que se obtiene una función discriminante lineal como regla óptima. Da la probabilidad de clasificación errónea  $P(1|2)$  asumiendo que  $\theta_1 > \theta_2$ .

5. (1 punto) Considerando el análisis de discriminante lineal para dos poblaciones normales, mostrar que si

$$\Delta^2 = (\mu_1 - \mu_2)^T \Sigma^{-1} (\mu_1 - \mu_2),$$

entonces

i.  $\mathbb{E}(D(\mathbf{x}) \mid \mathbf{x} \in G_i) = \frac{1}{2}(-1)^{i+1} \Delta^2$

ii.  $\text{Var}(D(\mathbf{x}) \mid \mathbf{x} \in G_i) = \Delta^2$

- iii. Obtener las probabilidades de clasificación errónea,  $P(2|1)$  y  $P(1|2)$ . *Hint*: ¿Cómo se distribuye  $D(\mathbf{x}) \mid \mathbf{x} \in G_i$ ?

6. (3 puntos) La base de datos *SP500.txt* contiene el porcentaje de retornos desde inicios del 2001 a finales de 2005. Para cada fecha se tiene el porcentaje de retornos record para cada uno de los 5 días previos, el volumen de transacciones del día previo, el porcentaje de retorno del día actual y un indicador binario de si el mercado iba hacia arriba o hacia abajo en esa fecha. Realizar lo siguiente
- i. Analiza la correlación de las variables.
  - ii. Separa los datos en una muestra para entrenar el modelo (del año 2001-2004) y una muestra para probar el modelo (año 2005).
  - iii. El objetivo es predecir el comportamiento del mercado en el año 2005. Por lo que se pide:
    - a. Realizar un análisis de discriminante lineal utilizando las variables Lag1 y Lag2. Utilizando la función *partimat()* de la librería *klaR* de *R* o programando tu propia función, dibuja el hiper-plano que separa las regiones y predice a través de la función *predict()* el tipo de mercado para el año 2005. Obtén la matriz de confusión y analiza los resultados.
    - b. Repetir el inciso anterior pero esta vez utilizando un discriminante cuadrático. ¿Qué método es mejor para estas dos variables?
    - c. ¿Puedes encontrar un mejor análisis discriminante a los utilizados en el ejercicio anterior?

## Actividades de DataCamp

1. Support Vector Machines in R
2. Hyperparameter Tuning in R