

Distribución Normal Multivariada

José A. Perusquía Cortés



Análisis Multivariado Semestre 2023-2



Distribución Normal Univariada


Distribución Normal Univariada

- Decimos que $X \sim N(\mu, \sigma^2)$ si tiene función de densidad

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2\sigma^2}(x - \mu)^2 \right]$$

- Donde
 - $\mathbb{E}(X) = \mu \in \mathbb{R}$ (parámetro de localización)
 - $Var(X) = \sigma^2 \in \mathbb{R}^+$ (parámetro de escala)

Distribución Normal Univariada



Distribución Normal Multivariada

Distribución Normal Multivariada

- Decimos que $\mathbf{x} \sim N_p(\mu, \Sigma)$ (no singular) si tiene función de densidad

$$f(\mathbf{x}) = \frac{1}{|2\pi\Sigma|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu) \right]$$

- Donde
 - $\mathbb{E}(\mathbf{x}) = \mu$
 - $Var(\mathbf{x}) = \Sigma > 0$ (positiva definida)

Distribución Normal Multivariada

- Para variables normales multivariadas en **R** podemos usar la librería **mvtnorm**
 - **dmvnorm()** : Evaluar la densidad.
 - **pmvnorm()** : Evaluar la distribución.
 - **qmvnorm()** : Obtener los cuantiles.
 - **rmvnorm()** : Obtener una muestra.


Distribución Normal Multivariada

- Por ejemplo, para dibujar la densidad

$$\mu = \begin{pmatrix} 3 \\ 3 \end{pmatrix} \quad \Sigma = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$$


- Creamos un grid `expand.grid()`
- Evaluamos la densidad en el grid con `dmvnorm(grid, mu, sigma)`
- Convertimos a una matriz el resultado anterior
- Graficamos con `persp()`

Distribución Normal Multivariada



Distribución Normal Multivariada

- Para datos bivariados también se puede crear un scatterplot en 3D con librería `scatterplot3d`



Distribución Normal Multivariada

- Si $\text{ran}(\Sigma) = k < p$ podemos definir la densidad (singular) como

$$f(\mathbf{x}) = \frac{(2\pi)^{-\frac{k}{2}}}{(\lambda_1 \cdots \lambda_k)^{\frac{1}{2}}} \exp \left[-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^- (\mathbf{x} - \mu) \right]$$

- Donde

- \mathbf{x} vive en el hiperplano $\mathbf{N}'(\mathbf{x} - \mu)$ donde \mathbf{N} es una matriz de tamaño $p \times (p - k)$ tal que $\mathbf{N}^T \Sigma = \mathbf{0}$, $\mathbf{N}^T \mathbf{N} = \mathbf{I}_{p-k}$
- Σ^- es la inversa generalizada y $\lambda_1, \dots, \lambda_k$ son los eigenvalores diferentes de cero.

Distribución Normal Multivariada

- **Definición.**

Decimos que \mathbf{x} tiene una distribución normal p-variada si y solo si $\mathbf{a}^T \mathbf{x}$ tiene una distribución normal univariada para todos los vectores p-variados (no triviales) \mathbf{a}

Distribución Normal Multivariada

- **Definición.**

Decimos que \mathbf{x} tiene una distribución normal p-variada si y solo si $\mathbf{a}^T \mathbf{x}$ tiene una distribución normal univariada para todos los vectores p-variados (no triviales) \mathbf{a}

- **Proposición I**

Sea \mathbf{x} un vector normal p-variado y definamos a $\mathbf{y} = \mathbf{A}\mathbf{x} + \mathbf{b}$ donde \mathbf{A} es una matriz de dimensión $q \times p$. Entonces \mathbf{y} tiene una distribución normal q-variada tal que

$$\mathbb{E}(\mathbf{y}) = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}$$

$$\text{Var}(\mathbf{y}) = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^T$$

- Corolario I

Sea $\mathbf{x} \sim N_p(\mathbf{0}, \mathbf{I}_p)$ y definamos a $\mathbf{y} = \Sigma^{\frac{1}{2}}\mathbf{x} + \mu$ entonces $\mathbf{y} \sim N_p(\mu, \Sigma)$

- Corolario 1

Sea $\mathbf{x} \sim N_p(\mathbf{0}, \mathbf{I}_p)$ y definamos a $\mathbf{y} = \Sigma^{\frac{1}{2}}\mathbf{x} + \mu$ entonces $\mathbf{y} \sim N_p(\mu, \Sigma)$

- Corolario 2

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ ($\Sigma > 0$) y definamos a $\mathbf{y} = \Sigma^{-\frac{1}{2}}(\mathbf{x} - \mu)$ donde $\Sigma^{-\frac{1}{2}}$ es la matrix raíz cuadrada de Σ^{-1} . Entonces

y_1, y_2, \dots, y_p son variables aleatorias iid $N(0,1)$.

- Corolario 1

Sea $\mathbf{x} \sim N_p(\mathbf{0}, \mathbf{I}_p)$ y definamos a $\mathbf{y} = \Sigma^{\frac{1}{2}}\mathbf{x} + \mu$ entonces $\mathbf{y} \sim N_p(\mu, \Sigma)$

- Corolario 2

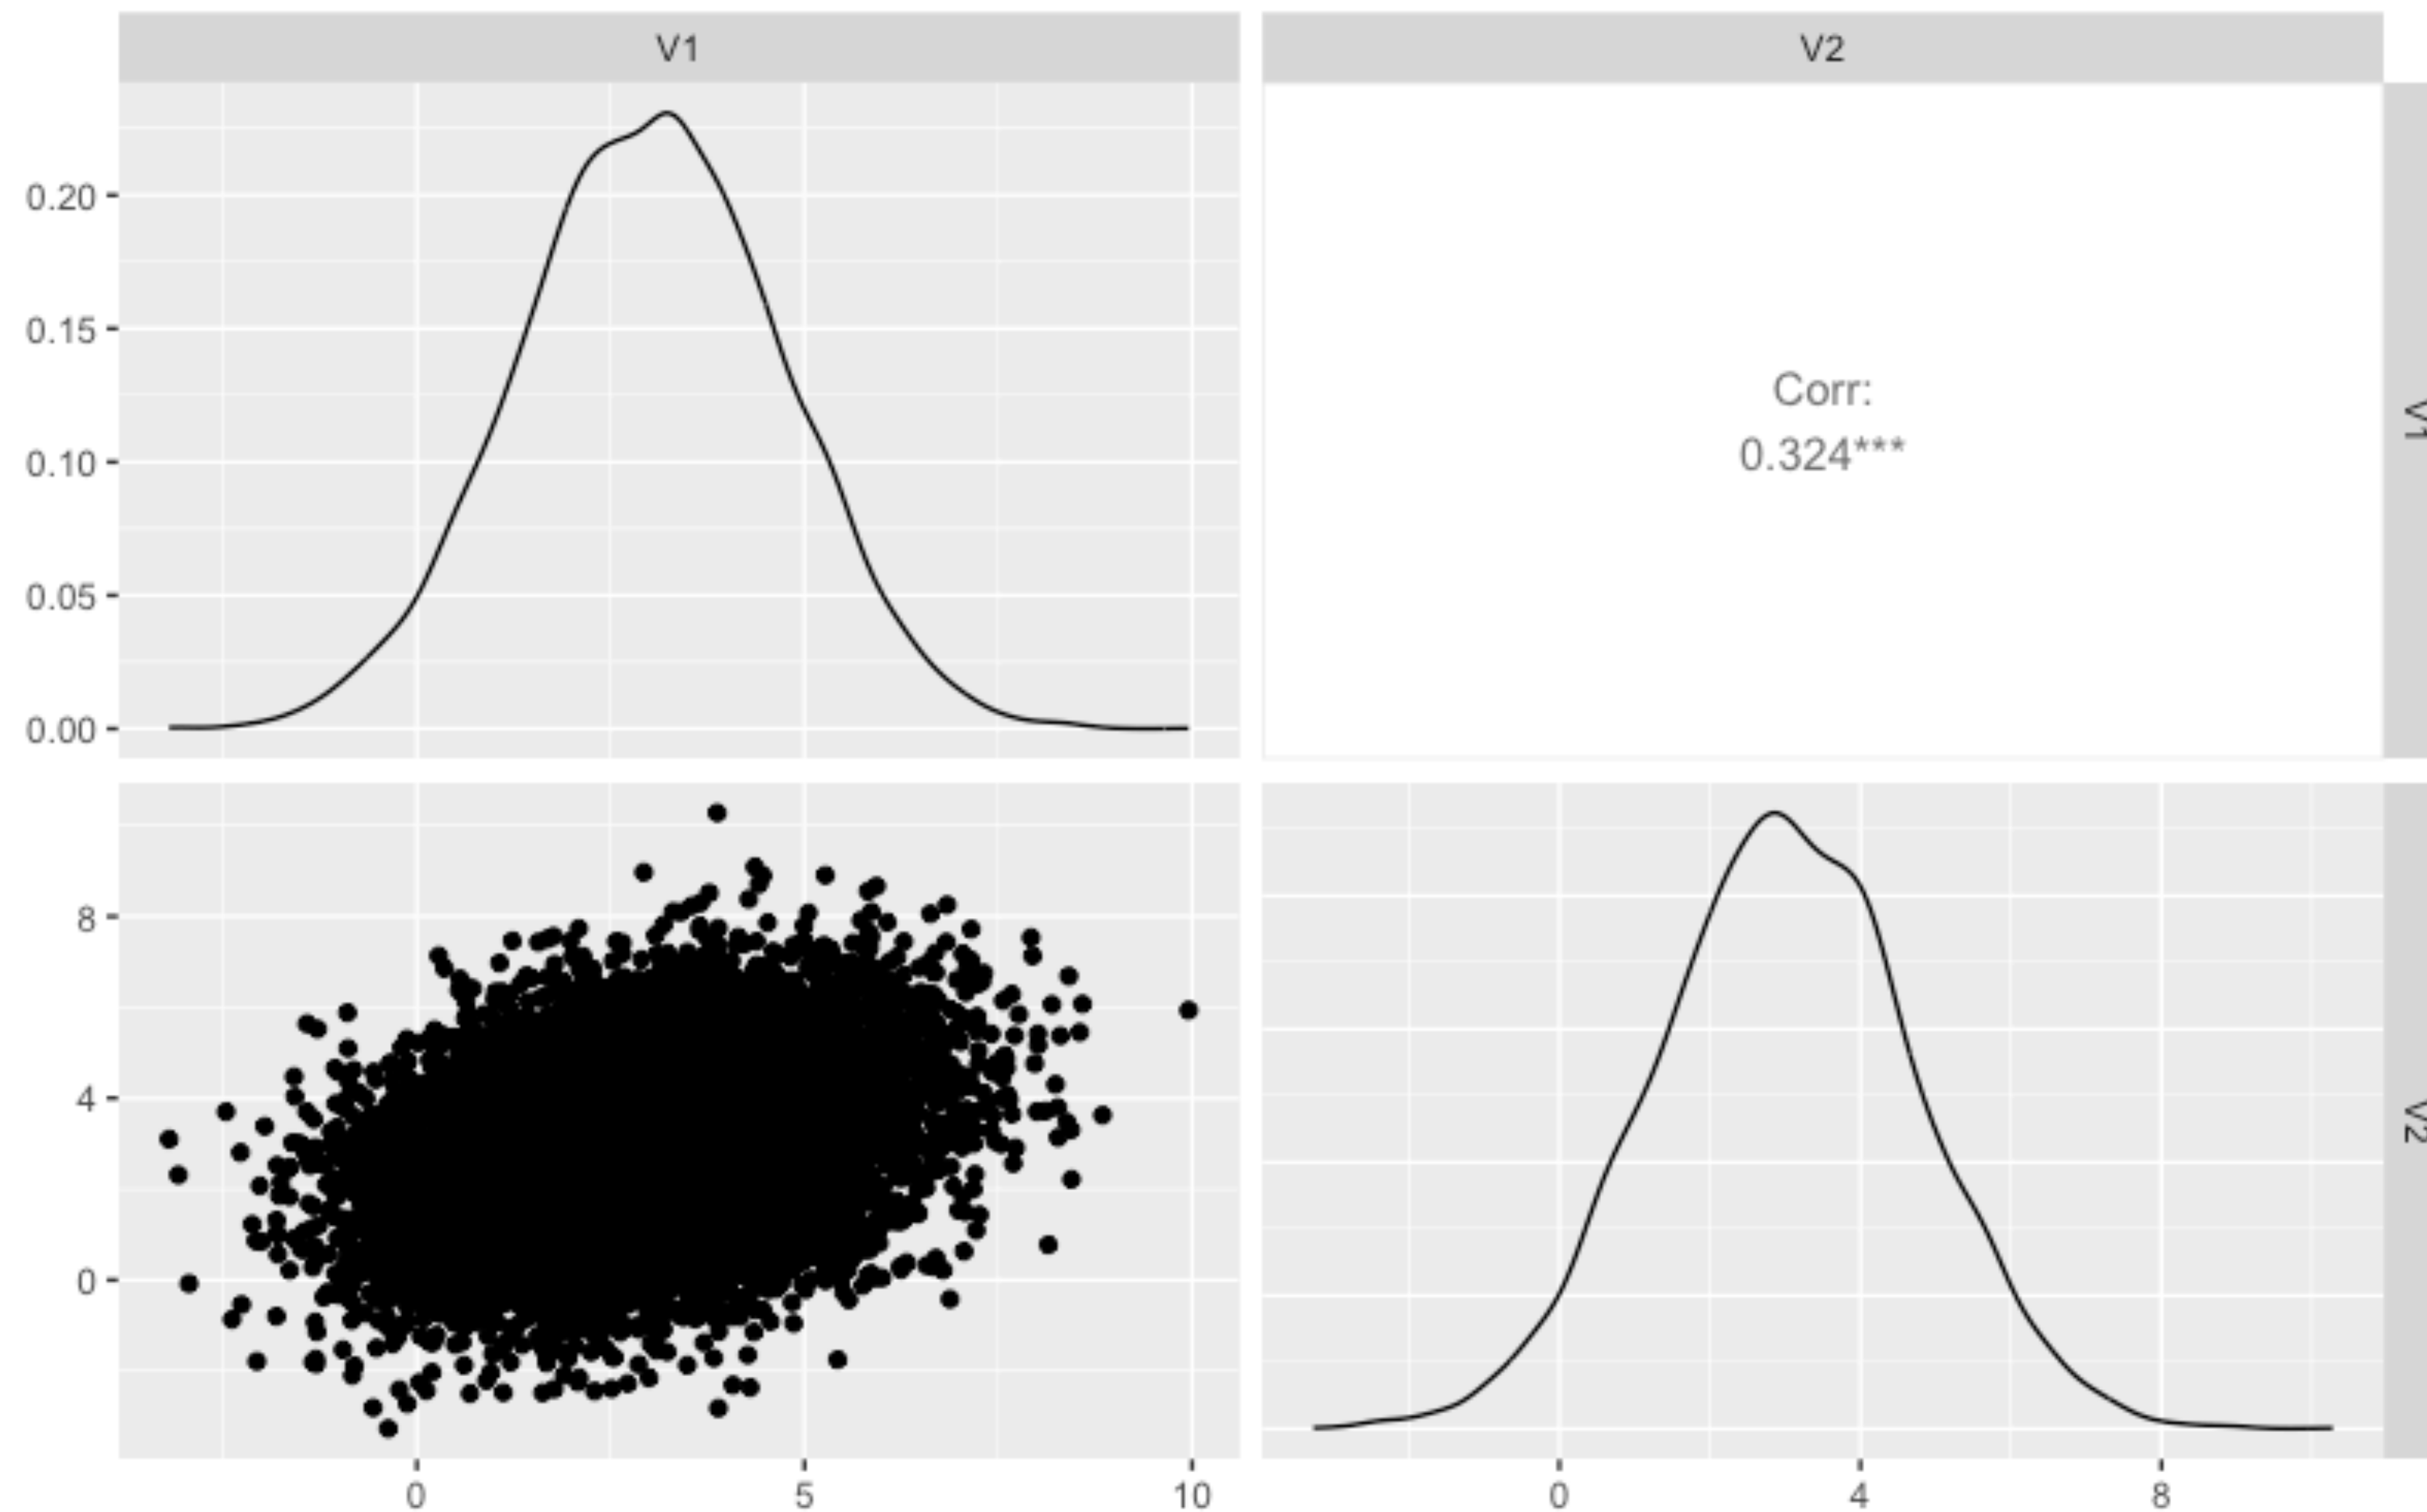
Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ ($\Sigma > 0$) y definamos a $\mathbf{y} = \Sigma^{-\frac{1}{2}}(\mathbf{x} - \mu)$ donde $\Sigma^{-\frac{1}{2}}$ es la matrix raíz cuadrada de Σ^{-1} . Entonces y_1, y_2, \dots, y_p son variables aleatorias iid $N(0,1)$.

- En **R** la librería `expm` proporciona la función requerida para obtener $\Sigma^{-\frac{1}{2}}$ con `sqrtm()`

$$\mathbf{x} \sim N_p(\mu, \Sigma)$$

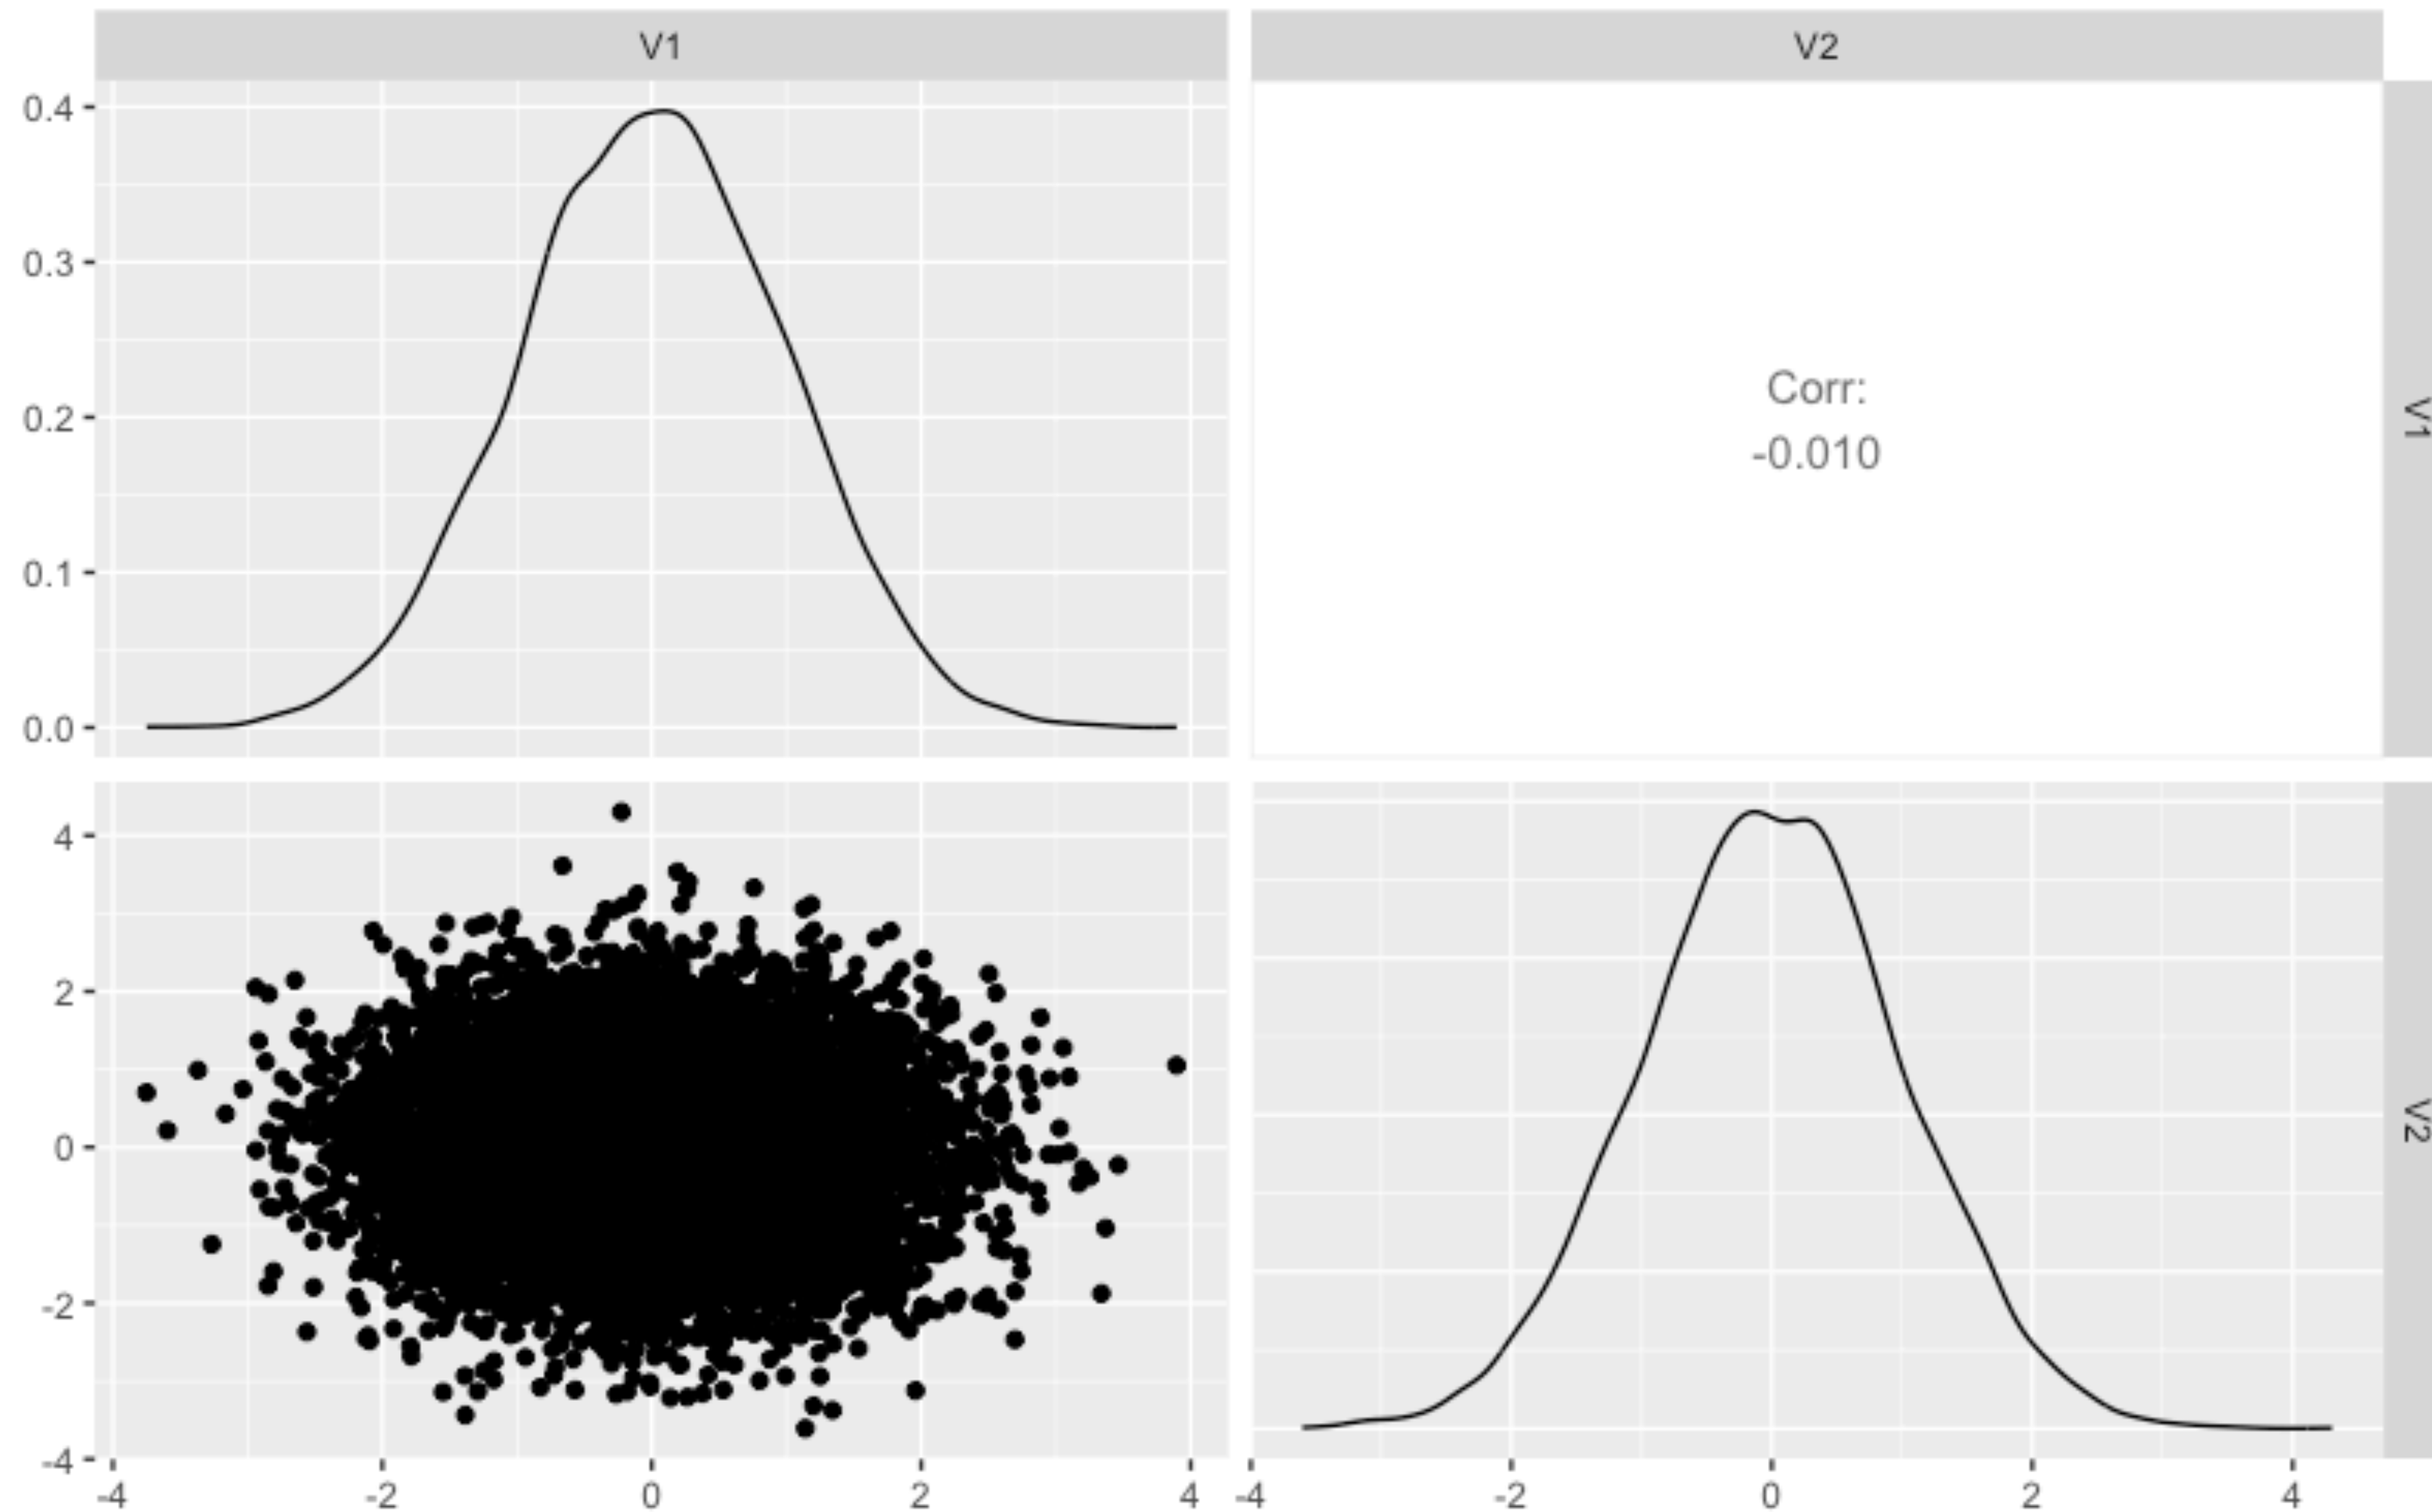
$$\mu = \begin{pmatrix} 3 \\ 3 \end{pmatrix} \quad \Sigma = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$$

Distribución Normal Multivariada



Distribución Normal Multivariada

$$\mathbf{y} = \Sigma^{-\frac{1}{2}}(\mathbf{x} - \mu)$$



- Observación

La distribución normal multivariada tiene densidad constante en elipses (elipsoides)

$$(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = k$$


- Observación

La distribución normal multivariada tiene densidad constante en elipses (elipsoides)

$$(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) = k$$

- En **R** podemos graficar las curvas mediante la función **contour()**
 - Generar vectores x , y donde evaluar la densidad (e.g. **$x=\text{seq}(0,6,\text{length.out}=40)$** , **$y=\text{seq}(0,6,\text{length.out}=40)$**)
 - Evaluar la densidad en estos puntos con **$z=\text{dmvnorm}()$**
 - Usar la función **$\text{contour}(x,y,z)$**


Distribución Normal Multivariada



Distribución Normal Multivariada

- Otra alternativa es usar la librería **plotly** para una gráfica más interactiva
 - Generar vectores x , y donde evaluar la densidad (e.g. `x=seq(0,6,length.out=40)` , `y =seq(0,6,length.out=40)`)
 - Evaluar la densidad en estos puntos con `z=dmvnorm()`
 - Usar la función `plot_ly(x,y,z,type = "contour")`

Distribución Normal Multivariada



- **Proposición 2**

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ entonces $U = (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \sim \chi_p^2$.

- **Proposición 2**

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ entonces $U = (\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \sim \chi_p^2$.

- **Observación**

Podemos fácilmente evaluar la probabilidad de que \mathbf{x} este en un elipsoide, i.e.

$$\mathbb{P}[(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) < k]$$

- Proposición 3 (Otras propiedades)

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ y sea

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \end{pmatrix} \quad \mu = \begin{pmatrix} \mu^{(1)} \\ \mu^{(2)} \end{pmatrix} \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

Entonces

- Cualquier subconjunto de \mathbf{x} se distribuye normal multivariado. En particular $\mathbf{x}^{(1)} \sim N_p(\mu^{(1)}, \Sigma_{11})$.

- Proposición 3 (Otras propiedades)

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ y sea

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \end{pmatrix} \quad \mu = \begin{pmatrix} \mu^{(1)} \\ \mu^{(2)} \end{pmatrix} \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

Entonces

1. Cualquier subconjunto de \mathbf{x} se distribuye normal multivariado. En particular $\mathbf{x}^{(1)} \sim N_p(\mu^{(1)}, \Sigma_{11})$.
2. $\mathbf{x}^{(1)}$ y $\mathbf{x}^{(2)}$ son independientes si y solo si $\text{Cov}(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}) = \mathbf{O}$.

- Proposición 3 (Otras propiedades)

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ y sea

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \end{pmatrix} \quad \mu = \begin{pmatrix} \mu^{(1)} \\ \mu^{(2)} \end{pmatrix} \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

Entonces

1. Cualquier subconjunto de \mathbf{x} se distribuye normal multivariado. En particular $\mathbf{x}^{(1)} \sim N_p(\mu^{(1)}, \Sigma_{11})$.
2. $\mathbf{x}^{(1)}$ y $\mathbf{x}^{(2)}$ son independientes si y solo si $\text{Cov}(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}) = \mathbf{O}$.
3. $\mathbf{x}^T \Sigma^{-1} \mathbf{x} \sim \chi_p^2(\mu^T \Sigma^{-1} \mu)$ (Tarea)

- Proposición 3 (Otras propiedades)

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ y sea

$$\mathbf{x} = \begin{pmatrix} \mathbf{x}^{(1)} \\ \mathbf{x}^{(2)} \end{pmatrix} \quad \mu = \begin{pmatrix} \mu^{(1)} \\ \mu^{(2)} \end{pmatrix} \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

Entonces

1. Cualquier subconjunto de \mathbf{x} se distribuye normal multivariado. En particular $\mathbf{x}^{(1)} \sim N_p(\mu^{(1)}, \Sigma_{11})$.
2. $\mathbf{x}^{(1)}$ y $\mathbf{x}^{(2)}$ son independientes si y solo si $\text{Cov}(\mathbf{x}^{(1)}, \mathbf{x}^{(2)}) = \mathbf{O}$.
3. $\mathbf{x}^T \Sigma^{-1} \mathbf{x} \sim \chi_p^2(\mu^T \Sigma^{-1} \mu)$ (Tarea)
4. $\mathbf{x}^{(2)} | \mathbf{x}^{(1)} \sim N_{p-k}(\mu^{(2)} + \Sigma_{21} \Sigma_{11}^{-1} [\mathbf{x}^{(1)} - \mu^{(1)}], \Sigma_{22} - \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12})$

- Teorema (Teorema Central del Límite)

Sean $\mathbf{x}_1, \mathbf{x}_2, \dots \in \mathbb{R}^p$ vectores aleatorios independientes e idénticamente distribuidos con media μ y matriz (finita) de varianza Σ . Entonces se tiene que

$$\sqrt{n}(\bar{\mathbf{x}} - \mu) \rightarrow N_p(\mathbf{0}_p, \Sigma)$$

- Definición

Sea \mathbf{x} un vector p-variado. Entonces la función característica está definida para $\mathbf{t} \in \mathbb{R}^p$ como

$$\phi(\mathbf{t}) = \mathbb{E}[\exp(it^T \mathbf{x})] = \int \exp(it^T \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- Definición

Sea \mathbf{x} un vector p-variado. Entonces la función característica está definida para $\mathbf{t} \in \mathbb{R}^p$ como

$$\phi(\mathbf{t}) = \mathbb{E}[\exp(it^T \mathbf{x})] = \int \exp(it^T \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- Propiedades (algunas)

- $\phi(\mathbf{t})$ siempre existe, $\phi(\mathbf{0}) = 1$ y $|\phi(\mathbf{t})| \leq 1$.

- Definición

Sea \mathbf{x} un vector p-variado. Entonces la función característica está definida para $\mathbf{t} \in \mathbb{R}^p$ como

$$\phi(\mathbf{t}) = \mathbb{E}[\exp(it^T \mathbf{x})] = \int \exp(it^T \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- Propiedades (algunas)

- $\phi(\mathbf{t})$ siempre existe, $\phi(\mathbf{0}) = 1$ y $|\phi(\mathbf{t})| \leq 1$.
- (Teorema de unicidad) $F(\mathbf{x}) = F(\mathbf{y}) \Leftrightarrow \phi_{\mathbf{x}}(\mathbf{t}) = \phi_{\mathbf{y}}(\mathbf{t})$

- Definición

Sea \mathbf{x} un vector p -variado. Entonces la función característica está definida para $\mathbf{t} \in \mathbb{R}^p$ como

$$\phi(\mathbf{t}) = \mathbb{E}[\exp(it^T \mathbf{x})] = \int \exp(it^T \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- Propiedades (algunas)

- $\phi(\mathbf{t})$ siempre existe, $\phi(\mathbf{0}) = 1$ y $|\phi(\mathbf{t})| \leq 1$.

- (Teorema de unicidad) $F(\mathbf{x}) = F(\mathbf{y}) \Leftrightarrow \phi_{\mathbf{x}}(\mathbf{t}) = \phi_{\mathbf{y}}(\mathbf{t})$

- (Teorema de inversión) Si $\phi(\mathbf{t})$ es absolutamente integrable entonces $f(\mathbf{x}) = \frac{1}{(2\pi)^p} \int_{\mathbb{R}} \exp[-it^T \mathbf{x}] \phi(\mathbf{t}) d\mathbf{t}$

- Definición

Sea \mathbf{x} un vector p-variado. Entonces la función característica está definida para $\mathbf{t} \in \mathbb{R}^p$ como

$$\phi(\mathbf{t}) = \mathbb{E}[\exp(it^T \mathbf{x})] = \int \exp(it^T \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- Propiedades (algunas)

- $\phi(\mathbf{t})$ siempre existe, $\phi(\mathbf{0}) = 1$ y $|\phi(\mathbf{t})| \leq 1$.

- (Teorema de unicidad) $F(\mathbf{x}) = F(\mathbf{y}) \Leftrightarrow \phi_{\mathbf{x}}(\mathbf{t}) = \phi_{\mathbf{y}}(\mathbf{t})$

- (Teorema de inversión) Si $\phi(\mathbf{t})$ es absolutamente integrable entonces $f(\mathbf{x}) = \frac{1}{(2\pi)^p} \int_{\mathbb{R}} \exp[-it^T \mathbf{x}] \phi(\mathbf{t}) d\mathbf{t}$

- $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$ son independientes si y solo si $\phi_{\mathbf{x}}(\mathbf{t}) = \phi_{\mathbf{x}^{(1)}}(\mathbf{t}^{(1)}) \phi_{\mathbf{x}^{(2)}}(\mathbf{t}^{(2)})$

- Definición

Sea \mathbf{x} un vector p -variado. Entonces la función característica está definida para $\mathbf{t} \in \mathbb{R}^p$ como

$$\phi(\mathbf{t}) = \mathbb{E}[\exp(it^T \mathbf{x})] = \int \exp(it^T \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- Propiedades (algunas)

- $\phi(\mathbf{t})$ siempre existe, $\phi(\mathbf{0}) = 1$ y $|\phi(\mathbf{t})| \leq 1$.

- (Teorema de unicidad) $F(\mathbf{x}) = F(\mathbf{y}) \Leftrightarrow \phi_{\mathbf{x}}(\mathbf{t}) = \phi_{\mathbf{y}}(\mathbf{t})$

- (Teorema de inversión) Si $\phi(\mathbf{t})$ es absolutamente integrable entonces $f(\mathbf{x}) = \frac{1}{(2\pi)^p} \int_{\mathbb{R}} \exp[-it^T \mathbf{x}] \phi(\mathbf{t}) d\mathbf{t}$

- $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}$ son independientes si y solo si $\phi_{\mathbf{x}}(\mathbf{t}) = \phi_{\mathbf{x}^{(1)}}(\mathbf{t}^{(1)}) \phi_{\mathbf{x}^{(2)}}(\mathbf{t}^{(2)})$

- $\phi_{\mathbf{x}^{(1)}}(\mathbf{t}^{(1)}) = \phi_{\mathbf{x}}(\mathbf{t}^{(1)}, \mathbf{0})$

- Teorema (Crámer-Wold)

La distribución de un vector aleatorio p -variado \mathbf{x} está completamente determinado por el conjunto de todas las distribuciones de combinaciones lineales $\mathbf{t}^T \mathbf{x}$, con $\mathbf{t} \in \mathbb{R}^p$

- Proposición 4

Sea $\mathbf{x} \sim N_p(\mu, \Sigma)$ entonces

$$\phi(\mathbf{t}) = \exp \left(i \mathbf{t}^T \mu - \frac{1}{2} \mathbf{t}^T \Sigma \mathbf{t} \right)$$

- **Proposición 5 (Asimetría y Curtosis)**

Sea $\mathbf{x} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ entonces los coeficientes de asimetría y curtosis están dados respectivamente por

$$\beta_{1,p} = 0$$

$$\beta_{2,p} = p(p + 2)$$

Distribución Normal Multivariada

- Checar normalidad

Distribución Normal Multivariada

- **Checar normalidad**

- Todas las distribuciones univariadas son normales

- * qqplot

- * histogramas

- * Pruebas de normalidad (e.g. Anderson-Darling, Shapiro-Wilk, Lilliefors, etc.)

Distribución Normal Multivariada

- **Checar normalidad**

- Todas las distribuciones univariadas son normales
 - * qqplot
 - * histogramas
 - * Pruebas de normalidad (e.g. Anderson-Darling, Shapiro-Wilk, Lilliefors, etc.)
- Prueba basada en los coeficientes de asimetría y curtosis (Prueba de Mardia)

- **Checar normalidad**

- Todas las distribuciones univariadas son normales

- * qqplot

- * histogramas

- * Pruebas de normalidad (e.g. Anderson-Darling, Shapiro-Wilk, Lilliefors, etc.)

- Prueba basada en los coeficientes de asimetría y curtosis (Prueba de Mardia)

- $(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \sim \chi_p^2$

- * qqplot

- **Checar normalidad**

- Todas las distribuciones univariadas son normales
 - * qqplot
 - * histogramas
 - * Pruebas de normalidad (e.g. Anderson-Darling, Shapiro-Wilk, Lilliefors, etc.)
- Prueba basada en los coeficientes de asimetría y curtosis (Prueba de Mardia)
- $(\mathbf{x} - \mu)^T \Sigma^{-1} (\mathbf{x} - \mu) \sim \chi_p^2$
 - * qqplot
- Otras pruebas de normalidad multivariadas


Distribución Normal Multivariada

- En **R** la librería **mvn** provee todas las herramientas esto

```
mvn(multnorm.sample,mvnTest="mardia",multivariatePlot = "qq")
```

```
$multivariateNormality
      Test      Statistic      p value Result
1 Mardia Skewness 3.47421629178296 0.481809628750315 YES
2 Mardia Kurtosis 0.29380065853414 0.768910231846389 YES
3      MVN          <NA>          <NA>      YES

$univariateNormality
      Test Variable Statistic p value Normality
1 Anderson-Darling Column1    0.3285    0.5161    YES
2 Anderson-Darling Column2    0.2388    0.7793    YES
```



Distribución Normal Multivariada



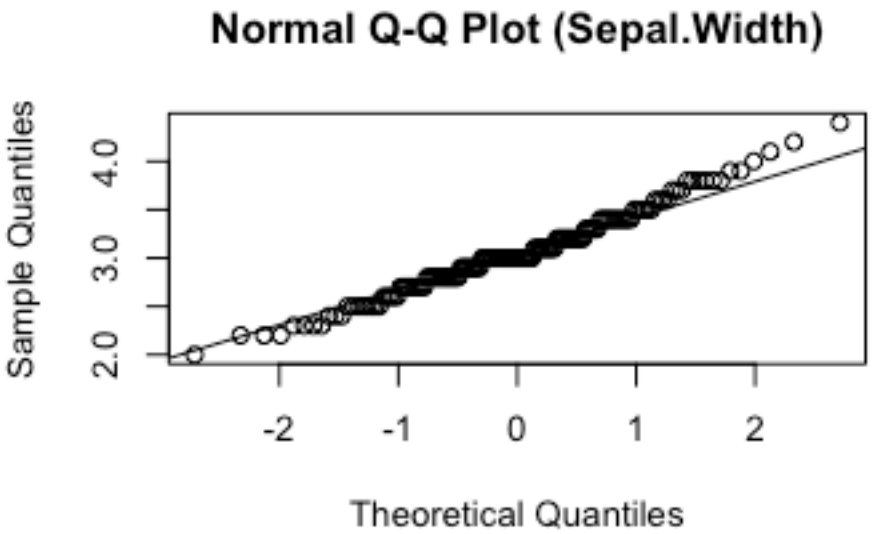

```
mvn(iris[,-5],mvnTest="mardia",univariatePlot = "qqplot")
```

```
$multivariateNormality
```

	Test	Statistic	p value	Result
1	Mardia Skewness	67.4305087780629	4.75799820400705e-07	NO
2	Mardia Kurtosis	-0.230112114480775	0.818004651478188	YES
3	MVN	<NA>	<NA>	NO


```
$univariateNormality
```

	Test	Variable	Statistic	p value	Normality
1	Anderson-Darling	Sepal.Length	0.8892	0.0225	NO
2	Anderson-Darling	Sepal.Width	0.9080	0.0202	NO
3	Anderson-Darling	Petal.Length	7.6785	<0.001	NO
4	Anderson-Darling	Petal.Width	5.1057	<0.001	NO



Distribuciones Asociadas a la Normal Multivariada

Distribución Wishart

- Definición

Sea $\mathbf{M}_{p \times p}$ una matriz simétrica de variables aleatorias tal que $\mathbb{P}(\mathbf{M} > 0) = 1$ y $\Sigma_{p \times p}$ una matriz definida positiva. Si $n \in \mathbb{N}$ tal que $n \geq p$, entonces $\mathbf{M}_{p \times p}$ tiene una distribución Wishart ($\mathbf{M} \sim W_p(n, \Sigma)$) no singular con n grados de libertad si la función de densidad de los $\frac{p(p+1)}{2}$ distintos elementos de $\mathbf{M}_{p \times p}$ está dada por

$$f(m_{11}, m_{12}, \dots, m_{pp}) = c^{-1} |\mathbf{M}|^{(n-p-1)/2} \text{etr} \left(-\frac{\Sigma^{-1} \mathbf{M}}{2} \right)$$

- Donde

- etr es el operador \exp^{trace}

- $c = 2^{\frac{np}{2}} |\Sigma|^{\frac{n}{2}} \Gamma_p \left(\frac{n}{2} \right)$ y $\Gamma_p(\cdot)$ la función gamma multivariada.

- Definición 2

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n$ vectors aleatorios iid distribuidos como $N_p(\mathbf{0}, \Sigma)$ entonces $\mathbf{M}_{p \times p} = \mathbf{X}^T \mathbf{X}$ tiene una distribución Wishart con n grados de libertad.

- Definición 2

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n$ vectors aleatorios iid distribuidos como $N_p(\mathbf{0}, \Sigma)$ entonces $\mathbf{M}_{p \times p} = \mathbf{X}^T \mathbf{X}$ tiene una distribución Wishart con n grados de libertad.

- Observación

Si $\Sigma > 0$ y $n \geq p$ entonces se puede probar que $\mathbb{P}(\mathbf{M} > 0) = 1$. De lo contrario se tiene que $\mathbf{M} \geq 0$, por lo que la densidad no existe y se dice que \mathbf{M} tiene una distribución singular.

- Teorema

Sea $\mathbf{M} \sim W_p(n, \Sigma)$ entonces, si $\mathbf{C}_{q \times p}$ tal que $\text{ran}(\mathbf{C}) = q$ se tiene que $\mathbf{CMCT} \sim W_p(n, \mathbf{C}\Sigma\mathbf{C}^T)$.

- Teorema

Sea $\mathbf{M} \sim W_p(n, \Sigma)$ entonces, si $\mathbf{C}_{q \times p}$ tal que $\text{ran}(\mathbf{C}) = q$ se tiene que $\mathbf{CMCT}^T \sim W_p(n, \mathbf{C}\Sigma\mathbf{C}^T)$.

- Corolario I

Si $\mathbf{M} \sim W_p(n, \Sigma)$ y \mathbf{a} es un vector de constantes, entonces $\mathbf{a}^T\mathbf{M}\mathbf{a} \sim \sigma_{\mathbf{a}}^2\chi_n^2$ donde $\sigma_{\mathbf{a}}^2 = \mathbf{a}^T\Sigma\mathbf{a}$.

- Teorema

Sea $\mathbf{M} \sim W_p(n, \Sigma)$ entonces, si $\mathbf{C}_{q \times p}$ tal que $\text{ran}(\mathbf{C}) = q$ se tiene que $\mathbf{CMCT}^T \sim W_p(n, \mathbf{C}\Sigma\mathbf{C}^T)$.

- Corolario 1

Si $\mathbf{M} \sim W_p(n, \Sigma)$ y \mathbf{a} es un vector de constantes, entonces $\mathbf{a}^T \mathbf{M} \mathbf{a} \sim \sigma_{\mathbf{a}}^2 \chi_n^2$ donde $\sigma_{\mathbf{a}}^2 = \mathbf{a}^T \Sigma \mathbf{a}$.

- Corolario 2

Si $\mathbf{M} \sim W_p(n, \Sigma)$ entonces $m_{i,i} \sim \Sigma_{i,i} \chi_n^2$

- (Algunas) Propiedades

Sea $\mathbf{M} \sim W_p(n, \Sigma)$ entonces

1. $\mathbb{E}(\mathbf{M}) = n\Sigma$

• (Algunas) Propiedades

Sea $\mathbf{M} \sim W_p(n, \Sigma)$ entonces

1. $E(\mathbf{M}) = n\Sigma$

2. (Aditividad) Si $\mathbf{M}_i \sim W_p(n_i, \Sigma)$ independientes entonces, $\sum_{i=1}^m \mathbf{M}_i \sim W_p\left(\sum_{i=1}^m n_i, \Sigma\right)$

• (Algunas) Propiedades

Sea $\mathbf{M} \sim W_p(n, \Sigma)$ entonces

1. $E(\mathbf{M}) = n\Sigma$

2. (Aditividad) Si $\mathbf{M}_i \sim W_p(n_i, \Sigma)$ independientes entonces, $\sum_{i=1}^m \mathbf{M}_i \sim W_p\left(\sum_{i=1}^m n_i, \Sigma\right)$

3. Si partimos a \mathbf{M} y a Σ como

$$\mathbf{M} = \begin{pmatrix} \mathbf{M}_{11} & \mathbf{M}_{12} \\ \mathbf{M}_{21} & \mathbf{M}_{22} \end{pmatrix} \quad \Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{pmatrix}$$

entonces $\mathbf{M}_{11} \sim W_k(n, \Sigma_{11})$ y $\mathbf{M}_{22} \sim W_{p-k}(n, \Sigma_{22})$. Más aún si $\Sigma_{12} = 0$, entonces son independientes.

- Teorema (Otras formas cuadráticas)

Sea $\mathbf{M} \sim W_p(n, \Sigma)$, entonces

l. Si $\text{ran}(\mathbf{A}_{q \times p}) = q$ entonces $(\mathbf{A}\mathbf{M}^{-1}\mathbf{A}^T)^{-1} \sim W_q\left(n - p + q, (\mathbf{A}\Sigma^{-1}\mathbf{A}^T)^{-1}\right)$ (Tarea)

• Teorema (Otras formas cuadráticas)

Sea $\mathbf{M} \sim W_p(n, \Sigma)$, entonces

1. Si $\text{ran}(\mathbf{A}_{q \times p}) = q$ entonces $(\mathbf{A}\mathbf{M}^{-1}\mathbf{A}^T)^{-1} \sim W_q\left(n - p + q, (\mathbf{A}\Sigma^{-1}\mathbf{A}^T)^{-1}\right)$ (Tarea)

2. Si $\mathbf{y}_{p \times 1}$ independiente de \mathbf{M} tal que $\mathbb{P}(\mathbf{y} = 0) = 0$ entonces $\frac{\mathbf{y}^T \mathbf{M} \mathbf{y}}{\mathbf{y}^T \Sigma \mathbf{y}} \sim \chi_n^2$ y $\frac{\mathbf{y}^T \Sigma^{-1} \mathbf{y}}{\mathbf{y}^T \mathbf{M}^{-1} \mathbf{y}} \sim \chi_{n-p+1}^2$ (Tarea)

• Teorema (Otras formas cuadráticas)

Sea $\mathbf{M} \sim W_p(n, \Sigma)$, entonces

1. Si $\text{ran}(\mathbf{A}_{q \times p}) = q$ entonces $(\mathbf{A}\mathbf{M}^{-1}\mathbf{A}^T)^{-1} \sim W_q\left(n - p + q, (\mathbf{A}\Sigma^{-1}\mathbf{A}^T)^{-1}\right)$ (Tarea)

2. Si $\mathbf{y}_{p \times 1}$ independiente de \mathbf{M} tal que $\mathbb{P}(\mathbf{y} = \mathbf{0}) = 0$ entonces $\frac{\mathbf{y}^T \mathbf{M} \mathbf{y}}{\mathbf{y}^T \Sigma \mathbf{y}} \sim \chi_n^2$ y $\frac{\mathbf{y}^T \Sigma^{-1} \mathbf{y}}{\mathbf{y}^T \mathbf{M}^{-1} \mathbf{y}} \sim \chi_{n-p+1}^2$ (Tarea)

3. Si $\mathbf{x}_1, \dots, \mathbf{x}_n$ son vectores aleatorios iid $N_p(\mathbf{0}, \Sigma)$ con $\mathbf{z} = \mathbf{X}\mathbf{a}$, $\mathbf{A}_{n \times n}, \mathbf{B}_{n \times n}$ matrices simétricas de rango r, s respectivamente y $\mathbf{b}_{n \times 1}$ un vector de constantes entonces

- $\mathbf{X}^T \mathbf{A} \mathbf{X} \sim W_p(r, \Sigma)$ si y solo si $\mathbf{y}^T \mathbf{A} \mathbf{y} \sim \sigma_a^2 \chi_r^2$

- $\mathbf{X}^T \mathbf{A} \mathbf{X} \sim W_p(r, \Sigma)$ y $\mathbf{X}^T \mathbf{B} \mathbf{X} \sim W_p(s, \Sigma)$ si y solo si $\mathbf{y}^T \mathbf{A} \mathbf{y} \sim \sigma_a^2 \chi_r^2$ y $\mathbf{y}^T \mathbf{B} \mathbf{y} \sim \sigma_a^2 \chi_s^2$ son independientes

- $\mathbf{X}^T \mathbf{b} \sim N_p$ y $\mathbf{X}^T \mathbf{A} \mathbf{X} \sim W_p(r, \Sigma)$ si y solo si $\mathbf{y}^T \mathbf{b} \sim N_1$ y $\mathbf{y}^T \mathbf{A} \mathbf{y} \sim \sigma_a^2 \chi_r^2$ son independientes

- Definición (Distribución Wishart No Centrada)

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n$ vectores aleatorios independientes y distribuidos como $N_p(\mu_i, \Sigma)$ entonces $\mathbf{M}_{p \times p} = \mathbf{X}^T \mathbf{X}$ tiene una distribución Wishart no centrada, $\mathbf{M} \sim W_p(n, \Sigma, \Delta)$, con n grados de libertad y matriz de no centralidad Δ definida como

$$\Delta = \sum_{i=1}^n (\Sigma^{-\frac{1}{2}} \mu_i)(\Sigma^{-\frac{1}{2}} \mu_i)^T = \Sigma^{-\frac{1}{2}} \Lambda^T \Lambda \Sigma^{-\frac{1}{2}}$$

- Donde

- $\Lambda = (\mu_1, \mu_2, \dots, \mu_n)^T$


Distribución Wishart

- En **R** existe el comando **rWishart(n,df,Sigma)** que permite simular matrices aleatorias Wishart
- Para entender su aleatoriedad podemos graficar las elipses generadas $\mathbf{a}^T \mathbf{M}_i \mathbf{a} = c$

$$n = 4$$

$$df = 2$$

$$\Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$



Distribución T^2 de Hotelling

- Teorema (Distribución Centrada)

Sean $\mathbf{x} \sim N_p(\mu, \Sigma)$ y $\mathbf{M} \sim W_p(n, \Sigma)$ independientes y no singulares

$$T^2 = n(\mathbf{x} - \mu)^T \mathbf{M}^{-1} (\mathbf{x} - \mu) \sim \frac{np}{n - p + 1} F_{p, n-p+1} = T_{p,n}^2$$

- Teorema (Distribución Centrada)

Sean $\mathbf{x} \sim N_p(\mu, \Sigma)$ y $\mathbf{M} \sim W_p(n, \Sigma)$ independientes y no singulares

$$T^2 = n(\mathbf{x} - \mu)^T \mathbf{M}^{-1} (\mathbf{x} - \mu) \sim \frac{np}{n - p + 1} F_{p, n-p+1} = T_{p,n}^2$$

- Corolario (Distribución No Centrada)

Sean $\mathbf{x} \sim N_p(\mu, \Sigma)$ y $\mathbf{M} \sim W_p(n, \Sigma)$ independientes y no singulares y denotemos por $\delta = \mu^T \Sigma^{-1} \mu$ (parámetro de no centralidad)

$$T^2 = n\mathbf{x}^T \mathbf{M}^{-1} \mathbf{x} \sim \frac{np}{n - p + 1} F_{p, n-p+1, \delta} = T_{p,n,\delta}^2$$

Estimación

- Función de verosimilitud

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$

$$L(\mu, \Sigma) = |2\pi\Sigma|^{-\frac{n}{2}} \exp \left[-\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right]$$

- Función de verosimilitud

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$

$$L(\mu, \Sigma) = |2\pi\Sigma|^{-\frac{n}{2}} \exp \left[-\frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu) \right]$$

- Función de log-verosimilitud

$$\log(L(\mu, \Sigma)) = -\frac{n}{2} \log(|2\pi\Sigma|) - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \mu)^T \Sigma^{-1} (\mathbf{x}_i - \mu)$$

- Proposición (EMV)

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$ con $n \geq p + 1$ entonces los estimadores máximo verosímiles están dados por

$$\hat{\mu} = \bar{x} \quad \hat{\Sigma} = \mathbf{S}$$

• Proposición (EMV)

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$ con $n \geq p + 1$ entonces los estimadores máximo verosímiles están dados por

$$\hat{\mu} = \bar{x} \quad \hat{\Sigma} = \mathbf{S}$$

• Teorema

Sean $\hat{\mu} = \bar{x}$ y $\hat{\Sigma} = \mathbf{S}$ los estimadores máximo verosímiles de $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$, entonces

$$-\hat{\mu} = \bar{x} \sim N_p(\mu, n^{-1}\Sigma)$$

$$-\hat{\Sigma} = \mathbf{S} \sim W_p(n - 1, \Sigma)$$

- $\hat{\mu} = \bar{x}$ y $\hat{\Sigma} = \mathbf{S}$ son independientes

• Teorema de Cochran

Suponer que \mathbf{P} una matriz de proyección con $\text{ran}(\mathbf{P}) = r$ y asumir que $\mathbf{X}_{n \times p}$ es una matriz con renglones $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mathbf{0}, \Sigma)$ con $\text{ran}(\Sigma) = p$ entonces notar que

$$\mathbf{X}^T \mathbf{X} = \mathbf{X}^T \mathbf{P} \mathbf{X} + \mathbf{X}^T (\mathbf{I}_n - \mathbf{P}) \mathbf{X}.$$

Entonces se tiene que

$\mathbf{X}^T \mathbf{P} \mathbf{X} \sim W_p(r, \Sigma)$ es independiente de $\mathbf{X}^T (\mathbf{I}_n - \mathbf{P}) \mathbf{X} \sim W_p(n - r, \Sigma)$

Pruebas de hipótesis para μ

Pruebas para μ

- Σ conocida

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$ queremos hacer el siguiente contraste

$$H_0 : \mu = \mu_0 \quad vs \quad H_a : \mu \neq \mu_0$$

Pruebas para μ

- Σ conocida

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$ queremos hacer el siguiente contraste

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu \neq \mu_0$$

- Usamos el estadístico de prueba

$$\xi^2 = n(\bar{\mathbf{X}} - \mu_0)^T \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0)$$

Pruebas para μ

- Σ conocida

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$ queremos hacer el siguiente contraste

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu \neq \mu_0$$

- Usamos el estadístico de prueba

$$\xi^2 = n(\bar{\mathbf{X}} - \mu_0)^T \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0)$$

- Bajo H_0

$$\xi^2 \sim \chi_p^2$$

Pruebas para μ

- Σ conocida

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$ queremos hacer el siguiente contraste

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_a : \mu \neq \mu_0$$

- Usamos el estadístico de prueba

$$\xi^2 = n(\bar{\mathbf{X}} - \mu_0)^T \Sigma^{-1} (\bar{\mathbf{X}} - \mu_0)$$

- Bajo H_0

$$\xi^2 \sim \chi_p^2$$

- Región de confianza $100(1 - \alpha) \%$ son las elipsoides

$$\{\mathbf{x} : \xi^2 \leq \chi_{p,1-\alpha}^2\}$$


- Ejemplo (Σ conocida)

$$\mathbf{x}_1, \dots, \mathbf{x}_{203} \sim N_2(\mu, \Sigma) \quad \mu = \begin{pmatrix} 64.1 \\ 64.7 \end{pmatrix} \quad \Sigma = \begin{pmatrix} 191 & 155.6 \\ 155.6 & 313.5 \end{pmatrix}$$

- Queremos contrastar

$$H_0 : \mu = 60 \quad vs \quad H_a : \mu \neq 60$$

Pruebas para μ




Pruebas para μ

- El estadístico de prueba

$$\xi^2 = 5.971581 < 5.991465 = \chi^2_{2,.95}$$

- No rechazamos H_0

Pruebas para μ



Pruebas para μ

- Σ desconocida (una muestra)

Utilizamos \mathbf{S} para construir el estadístico de prueba

$$\gamma^2 = \frac{n-p}{p} (\bar{\mathbf{x}} - \mu_0)^T \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0)$$

Pruebas para μ

- Σ desconocida (una muestra)

Utilizamos \mathbf{S} para construir el estadístico de prueba

$$\gamma^2 = \frac{n-p}{p} (\bar{\mathbf{x}} - \mu_0)^T \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0)$$

- Bajo H_0

$$\gamma^2 \sim F_{p, n-p}$$

Pruebas para μ

- Σ desconocida (una muestra)

Utilizamos \mathbf{S} para construir el estadístico de prueba

$$\gamma^2 = \frac{n-p}{p} (\bar{\mathbf{x}} - \mu_0)^T \mathbf{S}^{-1} (\bar{\mathbf{x}} - \mu_0)$$

- Bajo H_0

$$\gamma^2 \sim F_{p,n-p}$$

- Región de confianza $100(1 - \alpha) \%$ son las elipsoides

$$\{\mathbf{x} : \gamma^2 \leq F_{p,n-p,1-\alpha}\}$$

Pruebas para μ


- Ejemplo (Σ desconocida)

- El estadístico de prueba

$$\gamma^2 = 3.851315 > 3.013826 = F_{2,201,.95}$$

- Rechazamos H_0

Pruebas para μ



Pruebas para μ

- Σ desconocida (dos muestras)

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n$ y $\mathbf{y}_1, \dots, \mathbf{y}_m$

Pruebas para μ

- Σ desconocida (dos muestras)

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n$ y $\mathbf{y}_1, \dots, \mathbf{y}_m$

- **Caso I:** $m = n$ y existe una conexión entre ellas tenemos el caso pareado y nos fijamos en

$$\mathbf{z}_i = \mathbf{x}_i - \mathbf{y}_i \sim N_p(\mu, \Sigma)$$

Pruebas para μ

- Σ desconocida (dos muestras)

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n$ y $\mathbf{y}_1, \dots, \mathbf{y}_m$

- **Caso I:** $m = n$ y existe una conexión entre ellas tenemos el caso pareado y nos fijamos en

$$\mathbf{z}_i = \mathbf{x}_i - \mathbf{y}_i \sim N_p(\mu, \Sigma)$$

- Podemos probar fácilmente

$$H_0 : \mu = 0 \quad \text{vs} \quad H_a : \mu \neq 0$$

Pruebas para μ

- **Caso 2:** no existe una conexión entre ellas tenemos el caso no pareado

- **Caso 2:** no existe una conexión entre ellas tenemos el caso no pareado

- **Proposición**

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma_1)$ y $\mathbf{y}_1, \dots, \mathbf{y}_m \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma_2)$ si $\mu_1 = \mu_2$ y $\Sigma_1 = \Sigma_2$ entonces

$$\frac{nm}{n+m}(\bar{\mathbf{y}} - \bar{\mathbf{x}})^T \mathbf{S}_u^{-1}(\bar{\mathbf{y}} - \bar{\mathbf{x}}) \sim T^2(p, n+m-2)$$

Donde

$$\mathbf{S}_u = \frac{n\mathbf{S}_1 + m\mathbf{S}_2}{n+m-2}$$

- **Caso 2:** no existe una conexión entre ellas tenemos el caso no pareado

- **Proposición**

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma_1)$ y $\mathbf{y}_1, \dots, \mathbf{y}_m \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma_2)$ si $\mu_1 = \mu_2$ y $\Sigma_1 = \Sigma_2$ entonces

$$\frac{nm}{n+m}(\bar{\mathbf{y}} - \bar{\mathbf{x}})^T \mathbf{S}_u^{-1}(\bar{\mathbf{y}} - \bar{\mathbf{x}}) \sim T^2(p, n+m-2)$$

Donde

$$\mathbf{S}_u = \frac{n\mathbf{S}_1 + m\mathbf{S}_2}{n+m-2}$$

Utilizamos el estadístico de prueba

$$\delta^2 = \frac{(n+m-p-1)nm}{(n+m-2)(n+m)}(\hat{\mathbf{y}} - \hat{\mathbf{x}})^T \mathbf{S}_u^{-1}(\hat{\mathbf{y}} - \hat{\mathbf{x}}) \sim F_{p, n+m-p-1}$$

Pruebas de hipótesis para Σ

Pruebas para Σ

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu, \Sigma)$ con $n \geq p + 1$ se pueden hacer las siguiente pruebas para Σ

- Independencia por bloques

$$\Sigma = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} & \cdots & \Sigma_{1q} \\ \Sigma_{21} & \Sigma_{22} & \cdots & \Sigma_{2q} \\ \vdots & \vdots & & \vdots \\ \Sigma_{q1} & \Sigma_{q2} & \cdots & \Sigma_{qq} \end{pmatrix}$$

$$H_0 : \Sigma_{rs} = \mathbf{0}$$

- Esfericidad
 - **Caso 1:** $\Sigma = \sigma^2 \mathbf{I}$ con σ^2 desconocida (esta prueba incluye a $\Sigma = \sigma^2 \Sigma_0$)
 - **Caso 2:** $\Sigma = \mathbf{I}$ (esta prueba incluye a $\Sigma = \Sigma_0$)

- Esfericidad
 - Caso 1: $\Sigma = \sigma^2 \mathbf{I}$ con σ^2 desconocida (esta prueba incluye a $\Sigma = \sigma^2 \Sigma_0$)
 - Caso 2: $\Sigma = \mathbf{I}$ (esta prueba incluye a $\Sigma = \Sigma_0$)
- Igualdad en los bloques diagonales, i.e., $\Sigma_{11} = \Sigma_{22} = \dots = \Sigma_{qq}$

- Esfericidad
 - Caso 1: $\Sigma = \sigma^2 \mathbf{I}$ con σ^2 desconocida (esta prueba incluye a $\Sigma = \sigma^2 \Sigma_0$)
 - Caso 2: $\Sigma = \mathbf{I}$ (esta prueba incluye a $\Sigma = \Sigma_0$)
- Igualdad en los bloques diagonales, i.e., $\Sigma_{11} = \Sigma_{22} = \dots = \Sigma_{qq}$
- Igualdad de varianzas y correlaciones

$$\Sigma = \begin{pmatrix} 1 & \rho & \dots & \rho \\ \rho & 1 & \dots & \rho \\ \vdots & \vdots & & \vdots \\ \rho & \rho & \dots & 1 \end{pmatrix}$$

Pruebas para Σ

- Comparar dos poblaciones normales

Sean $\mathbf{x}_1, \dots, \mathbf{x}_n \stackrel{\text{iid}}{\sim} N_p(\mu_1, \Sigma_1)$ y $\mathbf{y}_1, \dots, \mathbf{y}_m \stackrel{\text{iid}}{\sim} N_p(\mu_2, \Sigma_2)$

$$H_0 : \Sigma_1 = \Sigma_2$$

- El estadístico de prueba

$$\frac{(n+m)^{\frac{(n+m)p}{2}}}{n^{\frac{np}{2}} m^{\frac{mp}{2}}} \frac{|\mathbf{S}_1|^{\frac{n}{2}} |\mathbf{S}_2|^{\frac{m}{2}}}{|\mathbf{S}_1 + \mathbf{S}_2|^{\frac{n+m}{2}}}$$