

# Análisis Discriminante (DA)

José A. Perusquía Cortés

Análisis Multivariado Semestre 2023-2



- Sabiendo que un objeto viene de uno de  $k$  grupos distintos se busca:
  - asignar el objeto utilizando  $p$  características y que

- Sabiendo que un objeto viene de uno de  $k$  grupos distintos se busca:
  - asignar el objeto utilizando  $p$  características y que
  - la regla de asignación sea óptima en algún sentido

- Sabiendo que un objeto viene de uno de  $k$  grupos distintos se busca:
  - asignar el objeto utilizando  $p$  características y que
  - la regla de asignación sea óptima en algún sentido
- Cuatro casos a considerar:
  - La distribución es conocida (prácticamente imposible en la realidad)

- Sabiendo que un objeto viene de uno de  $k$  grupos distintos se busca:
  - asignar el objeto utilizando  $p$  características y que
  - la regla de asignación sea óptima en algún sentido
- Cuatro casos a considerar:
  - La distribución es conocida (prácticamente imposible en la realidad)
  - La distribución es conocida salvo algunos parámetros

- Sabiendo que un objeto viene de uno de  $k$  grupos distintos se busca:
  - asignar el objeto utilizando  $p$  características y que
  - la regla de asignación sea óptima en algún sentido
- Cuatro casos a considerar:
  - La distribución es conocida (prácticamente imposible en la realidad)
  - La distribución es conocida salvo algunos parámetros
  - La distribución es parcialmente conocida

- Sabiendo que un objeto viene de uno de  $k$  grupos distintos se busca:
  - asignar el objeto utilizando  $p$  características y que
  - la regla de asignación sea óptima en algún sentido
- Cuatro casos a considerar:
  - La distribución es conocida (prácticamente imposible en la realidad)
  - La distribución es conocida salvo algunos parámetros
  - La distribución es parcialmente conocida
  - La distribución es desconocida

Distribución conocida



- Suponemos:
  - 2 grupos con proporciones  $\pi_1$  y  $\pi_2 = 1 - \pi_1$  y densidades  $f_1$  y  $f_2$
  - Asignamos al grupo  $G_i$  si  $\mathbf{x} \in R_i$  con  $R_1 \cup R_2 = R$

- Suponemos:
  - 2 grupos con proporciones  $\pi_1$  y  $\pi_2 = 1 - \pi_1$  y densidades  $f_1$  y  $f_2$
  - Asignamos al grupo  $G_i$  si  $\mathbf{x} \in R_i$  con  $R_1 \cup R_2 = R$
  
- Se puede cometer el error de:
  - Asignar a  $\mathbf{x}$  a  $G_2$  cuando  $\mathbf{x} \in G_1$  o viceversa

▸ Suponemos:

- 2 grupos con proporciones  $\pi_1$  y  $\pi_2 = 1 - \pi_1$  y densidades  $f_1$  y  $f_2$
- Asignamos al grupo  $G_i$  si  $\mathbf{x} \in R_i$  con  $R_1 \cup R_2 = R$

▸ Se puede cometer el error de:

- Asignar a  $\mathbf{x}$  a  $G_2$  cuando  $\mathbf{x} \in G_1$  o viceversa
- Las probabilidades de error se definen como

$$P(2 | 1) = \int_{R_2} f_1(\mathbf{x}) d\mathbf{x} \quad P(1 | 2) = \int_{R_1} f_2(\mathbf{x}) d\mathbf{x}$$

▸ Suponemos:

- 2 grupos con proporciones  $\pi_1$  y  $\pi_2 = 1 - \pi_1$  y densidades  $f_1$  y  $f_2$
- Asignamos al grupo  $G_i$  si  $\mathbf{x} \in R_i$  con  $R_1 \cup R_2 = R$

▸ Se puede cometer el error de:

- Asignar a  $\mathbf{x}$  a  $G_2$  cuando  $\mathbf{x} \in G_1$  o viceversa
- Las probabilidades de error se definen como

$$P(2 | 1) = \int_{R_2} f_1(\mathbf{x}) d\mathbf{x} \quad P(1 | 2) = \int_{R_1} f_2(\mathbf{x}) d\mathbf{x}$$

- La probabilidad de mis-clasificación es:

$$p = P(1 | 2)\pi_2 + P(2 | 1)\pi_1$$

**Lemma 1**

La integral  $\int_{R_1} g(\mathbf{x}) d\mathbf{x}$  se minimiza con respecto a  $R_1$  cuando  $R_1 = R_{01} = \{\mathbf{x} : g(\mathbf{x}) < 0\}$

**Lemma 1**

La integral  $\int_{R_1} g(\mathbf{x}) d\mathbf{x}$  se minimiza con respecto a  $R_1$  cuando  $R_1 = R_{01} = \{\mathbf{x} : g(\mathbf{x}) < 0\}$

**Observaciones**

- La región  $R_{01}$  no es única

**Lemma 1**

La integral  $\int_{R_1} g(\mathbf{x}) d\mathbf{x}$  se minimiza con respecto a  $R_1$  cuando  $R_1 = R_{01} = \{\mathbf{x} : g(\mathbf{x}) < 0\}$

**Observaciones**

- La región  $R_{01}$  no es única
- Los puntos frontera  $B = \{\mathbf{x} : g(\mathbf{x}) = 0\}$  se pueden asignar arbitrariamente a  $R_{01}$  o a  $R_{02}$

# Criterios de asignación

**a. Minimizar la probabilidad total de mis-clasificación**



## a. Minimizar la probabilidad total de mis-clasificación

- La probabilidad total de error es

$$p = P(1 | 2)\pi_2 + p(2 | 1)\pi_1 = \pi_1 + \int_{R_1} [\pi_2 f_2(\mathbf{x}) - \pi_1 f_1(\mathbf{x})] d(\mathbf{x})$$

## a. Minimizar la probabilidad total de mis-clasificación

- La probabilidad total de error es

$$p = P(1 | 2)\pi_2 + p(2 | 1)\pi_1 = \pi_1 + \int_{R_1} [\pi_2 f_2(\mathbf{x}) - \pi_1 f_1(\mathbf{x})] d(\mathbf{x})$$

- Se minimiza en  $R_{01} = \{\mathbf{x} : \pi_2 f_2(\mathbf{x}) - \pi_1 f_1(\mathbf{x}) < 0\}$

## a. Minimizar la probabilidad total de mis-clasificación

- La probabilidad total de error es

$$p = P(1 | 2)\pi_2 + p(2 | 1)\pi_1 = \pi_1 + \int_{R_1} [\pi_2 f_2(\mathbf{x}) - \pi_1 f_1(\mathbf{x})] d(\mathbf{x})$$

- Se minimiza en  $R_{01} = \{\mathbf{x} : \pi_2 f_2(\mathbf{x}) - \pi_1 f_1(\mathbf{x}) < 0\}$

- Asignar a  $G_1$  si

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > \frac{\pi_2}{\pi_1}$$

## **b. Maximizar la función de verosimilitud**

## **b. Maximizar la función de verosimilitud**

- Si  $\pi_1$  es desconocida

## b. Maximizar la función de verosimilitud

- Si  $\pi_1$  es desconocida
- Asignar a  $G_1$  si

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > 1$$

## b. Maximizar la función de verosimilitud

- Si  $\pi_1$  es desconocida
- Asignar a  $G_1$  si

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > 1$$

- Caso particular de a. con

$$\pi_1 = \pi_2 = \frac{1}{2}$$

## c. Minimizar el costo de mis-clasificación



## c. Minimizar el costo de mis-clasificación

- Si  $C(1 | 2), C(2 | 1)$  los costos de clasificar mal los miembros de  $G_1, G_2$

## c. Minimizar el costo de mis-clasificación

- Si  $C(1|2), C(2|1)$  los costos de clasificar mal los miembros de  $G_1, G_2$
- El costo total esperado es:

$$C_T = C(2|1)P(2|1)\pi_1 + C(1|2)P(1|2)\pi_2$$

## c. Minimizar el costo de mis-clasificación

- Si  $C(1 | 2), C(2 | 1)$  los costos de clasificar mal los miembros de  $G_1, G_2$
- El costo total esperado es:

$$C_T = C(2 | 1)P(2 | 1)\pi_1 + C(1 | 2)P(1 | 2)\pi_2$$

- $C_T$  se minimiza cuando  $C(1 | 2)\pi_2 f_2(\mathbf{x}) < C(2 | 1)\pi_1 f_1(\mathbf{x})$

## c. Minimizar el costo de mis-clasificación

- Si  $C(1 | 2), C(2 | 1)$  los costos de clasificar mal los miembros de  $G_1, G_2$
- El costo total esperado es:

$$C_T = C(2 | 1)P(2 | 1)\pi_1 + C(1 | 2)P(1 | 2)\pi_2$$

- $C_T$  se minimiza cuando  $C(1 | 2)\pi_2 f_2(\mathbf{x}) < C(2 | 1)\pi_1 f_1(\mathbf{x})$
- Asignamos a  $G_1$  si

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > \frac{\pi_2 C(1 | 2)}{\pi_1 C(2 | 1)}$$

**d. Maximizar la probabilidad posterior**

## d. Maximizar la probabilidad posterior

- La probabilidad posterior de  $G_i$  dado  $\mathbf{x} = \mathbf{x}_0$

$$q_i(\mathbf{x}_0) = \frac{f_i(\mathbf{x}_0)\pi_i}{f_1(\mathbf{x}_0)\pi_1 + f_2(\mathbf{x}_0)\pi_2}$$

## d. Maximizar la probabilidad posterior

- La probabilidad posterior de  $G_i$  dado  $\mathbf{x} = \mathbf{x}_0$

$$q_i(\mathbf{x}_0) = \frac{f_i(\mathbf{x}_0)\pi_i}{f_1(\mathbf{x}_0)\pi_1 + f_2(\mathbf{x}_0)\pi_2}$$

- Asignamos a  $G_1$  si

$$q_1(\mathbf{x}) > q_2(\mathbf{x})$$

## e. Minimax



## e. Minimax

- Si  $\pi_1 < \pi_2$  asignar un objeto para minimizar la máxima probabilidad individual de misclasificación

## e. Minimax

- Si  $\pi_1 < \pi_2$  asignar un objeto para minimizar la máxima probabilidad individual de misclasificación
- Para  $\alpha \in [0,1]$  se tiene que  $\max\{P(1|2), P(2|1)\} \geq (1 - \alpha)P(2|1) + \alpha P(1|2)$

## e. Minimax

- Si  $\pi_1 < \pi_2$  asignar un objeto para minimizar la máxima probabilidad individual de misclasificación
- Para  $\alpha \in [0,1]$  se tiene que  $\max\{P(1|2), P(2|1)\} \geq (1 - \alpha)P(2|1) + \alpha P(1|2)$
- Se minimiza cuando

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > \frac{\alpha}{1 - \alpha} = c$$

## e. Minimax

- Si  $\pi_1 < \pi_2$  asignar un objeto para minimizar la máxima probabilidad individual de misclasificación
- Para  $\alpha \in [0,1]$  se tiene que  $\max\{P(1|2), P(2|1)\} \geq (1 - \alpha)P(2|1) + \alpha P(1|2)$
- Se minimiza cuando

$$\frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} > \frac{\alpha}{1 - \alpha} = c$$

- A  $c$  se puede elegir de tal forma que en  $R_{01}$  se cumpla  $P_0(1|2) = P_0(2|1)$

## Ejemplo 1

Sea  $f_i = N_p(\mu_i, \Sigma)$

## Ejemplo 1

Sea  $f_i = N_p(\mu_i, \Sigma)$

– Asignamos a  $G_1$  si

$$D(\mathbf{x}) = (\mu_1 - \mu_2)^T \Sigma^{-1} \left[ \mathbf{x} - \frac{1}{2}(\mu_1 + \mu_2) \right] > \log \left( \frac{\pi_1}{\pi_2} \right)$$

## Ejemplo 1

Sea  $f_i = N_p(\mu_i, \Sigma)$

– Asignamos a  $G_1$  si

$$D(\mathbf{x}) = (\mu_1 - \mu_2)^T \Sigma^{-1} \left[ \mathbf{x} - \frac{1}{2}(\mu_1 + \mu_2) \right] > \log \left( \frac{\pi_1}{\pi_2} \right)$$

– Las probabilidades de mis-clasificación son:

$$P(2 | 1) = \Phi \left( \frac{\log \left[ \frac{\pi_2}{\pi_1} \right] - \frac{1}{2} \Delta^2}{\Delta} \right) \quad P(1 | 2) = \Phi \left( \frac{\log \left[ \frac{\pi_1}{\pi_2} \right] - \frac{1}{2} \Delta^2}{\Delta} \right)$$

## Ejemplo 1

Sea  $f_i = N_p(\mu_i, \Sigma)$

– Asignamos a  $G_1$  si

$$D(\mathbf{x}) = (\mu_1 - \mu_2)^T \Sigma^{-1} \left[ \mathbf{x} - \frac{1}{2}(\mu_1 + \mu_2) \right] > \log \left( \frac{\pi_1}{\pi_2} \right)$$

– Las probabilidades de mis-clasificación son:


$$P(2 | 1) = \Phi \left( \frac{\log \left[ \frac{\pi_2}{\pi_1} \right] - \frac{1}{2} \Delta^2}{\Delta} \right) \quad P(1 | 2) = \Phi \left( \frac{\log \left[ \frac{\pi_1}{\pi_2} \right] - \frac{1}{2} \Delta^2}{\Delta} \right)$$

– El caso  $\pi_1 = \pi_2$  fue estudiado por Fisher (1936)



– En R en la librería MASS existe función `lda()`



# Ejemplo 1



# Ejemplo 1



## Ejemplo 2

Sea  $f_i = N_p(\mu_i, \Sigma_i)$

– Asignamos a  $G_1$  si

$$Q(\mathbf{x}) = c_0 - \frac{1}{2} \left[ \mathbf{x}^T (\Sigma_1^{-1} - \Sigma_2^{-1}) \mathbf{x} - 2\mathbf{x}^T (\Sigma_1^{-1} \mu_1 - \Sigma_2^{-1} \mu_2) \right] > \log \left( \frac{\pi_2}{\pi_1} \right)$$

## Ejemplo 2

Sea  $f_i = N_p(\mu_i, \Sigma_i)$

– Asignamos a  $G_1$  si

$$Q(\mathbf{x}) = c_0 - \frac{1}{2} [\mathbf{x}^T(\Sigma_1^{-1} - \Sigma_2^{-1})\mathbf{x} - 2\mathbf{x}^T(\Sigma_1^{-1}\mu_1 - \Sigma_2^{-1}\mu_2)] > \log\left(\frac{\pi_2}{\pi_1}\right)$$

– La función ahora es cuadrática en lugar de lineal como  $D(\mathbf{x})$

## Ejemplo 2

Sea  $f_i = N_p(\mu_i, \Sigma_i)$

– Asignamos a  $G_1$  si

$$Q(\mathbf{x}) = c_0 - \frac{1}{2} [\mathbf{x}^T(\Sigma_1^{-1} - \Sigma_2^{-1})\mathbf{x} - 2\mathbf{x}^T(\Sigma_1^{-1}\mu_1 - \Sigma_2^{-1}\mu_2)] > \log\left(\frac{\pi_2}{\pi_1}\right)$$

– La función ahora es cuadrática en lugar de lineal como  $D(\mathbf{x})$

– En R en la librería MASS existe función `qda()`

Parámetros Desconocidos

- Sea  $f_i(\mathbf{x} | \theta_i)$  la densidad del grupo  $G_i$  con parámetros (desconocidos)  $\theta_i$  y una muestra de cada grupo

- Sea  $f_i(\mathbf{x} | \theta_i)$  la densidad del grupo  $G_i$  con parámetros (desconocidos)  $\theta_i$  y una muestra de cada grupo
- Obtener  $\hat{\theta}_i$  (e.g. máximos verosímiles)



- Sea  $f_i(\mathbf{x} | \theta_i)$  la densidad del grupo  $G_i$  con parámetros (desconocidos)  $\theta_i$  y una muestra de cada grupo
- Obtener  $\hat{\theta}_i$  (e.g. máximos verosímiles)
- La región óptima del grupo  $G_1$  es

$$\hat{R}_{01} = \left\{ \mathbf{x} : \frac{f_1(\mathbf{x} | \hat{\theta}_1)}{f_2(\mathbf{x} | \hat{\theta}_2)} > c \right\}$$

- Sea  $f_i(\mathbf{x} | \theta_i)$  la densidad del grupo  $G_i$  con parámetros (desconocidos)  $\theta_i$  y una muestra de cada grupo
- Obtener  $\hat{\theta}_i$  (e.g. máximos verosímiles)
- La región óptima del grupo  $G_1$  es

$$\hat{R}_{01} = \left\{ \mathbf{x} : \frac{f_1(\mathbf{x} | \hat{\theta}_1)}{f_2(\mathbf{x} | \hat{\theta}_2)} > c \right\}$$

- Para  $n \gg 1$  se tiene que  $\hat{R}_{01} \approx R_{01}$

Como en el caso de  $\theta_i$  conocidos se deben considerar los siguientes errores de clasificación

Como en el caso de  $\theta_i$  conocidos se deben considerar los siguientes errores de clasificación

– Error óptimo

$$e_{opt} = \pi_1 e_{1,opt} + \pi_2 e_{2,opt},$$

$$e_{i,opt} = \int_{R_{0j}} f_i(\mathbf{x} | \theta_i) d\mathbf{x}$$

Como en el caso de  $\theta_i$  conocidos se deben considerar los siguientes errores de clasificación

– Error óptimo

$$e_{opt} = \pi_1 e_{1,opt} + \pi_2 e_{2,opt},$$

$$e_{i,opt} = \int_{R_{0j}} f_i(\mathbf{x} | \theta_i) d\mathbf{x}$$

– Error actual

$$e_{act} = \pi_1 e_{1,act} + \pi_2 e_{2,act},$$

$$e_{i,act} = \int_{\hat{R}_{0j}} f_i(\mathbf{x} | \theta_i) d\mathbf{x}$$

Al no conocer a  $\theta_i$  hay que hacer estimaciones

Al no conocer a  $\theta_i$  hay que hacer estimaciones

– Usando  $\hat{\theta}_i$

$$\hat{e}_{i,act} = \int_{\hat{R}_{0j}} f_i(\mathbf{x} | \hat{\theta}_i) d\mathbf{x}$$

Al no conocer a  $\theta_i$  hay que hacer estimaciones

- Usando  $\hat{\theta}_i$

$$\hat{e}_{i,act} = \int_{\hat{R}_{0j}} f_i(\mathbf{x} | \hat{\theta}_i) d\mathbf{x}$$

- Errores aparentes usando los elementos mal clasificados  $m_i$

$$e_{i,app} = \frac{m_i}{n_i}$$



– Validación cruzada

$$e_{i,val} = \frac{a_i}{n_i}$$

- Validación cruzada

$$e_{i,val} = \frac{a_i}{n_i}$$

- Bootstrap usando los mal clasificados originales,  $m_i^*$ , y del remuestreo bajo la nueva regla  $m_i^{**}$

$$e_{i,boot} = \frac{m_i}{n_i} + \bar{d}_i \quad \bar{d}_i = \frac{(m_i^{**} - m_i^*)}{n_i}$$

# Discriminación Logística

- El modelo logístico asume que

$$\log \left[ \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \right] = \alpha + \beta^T \mathbf{x}$$

- El modelo logístico asume que

$$\log \left[ \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \right] = \alpha + \beta^T \mathbf{x}$$

- Asignamos a  $G_1$  si  $\alpha + \beta^T \mathbf{x} > \log(\pi_2/\pi_1)$

- El modelo logístico asume que

$$\log \left[ \frac{f_1(\mathbf{x})}{f_2(\mathbf{x})} \right] = \alpha + \beta^T \mathbf{x}$$

- Asignamos a  $G_1$  si  $\alpha + \beta^T \mathbf{x} > \log(\pi_2/\pi_1)$

- Las probabilidades posteriores son

$$q_1(\mathbf{x}) = \frac{\exp[\alpha + \log(\pi_1/\pi_2) + \beta^T \mathbf{x}]}{\exp[\alpha + \log(\pi_1/\pi_2) + \beta^T \mathbf{x}] + 1}$$

$$q_2 = 1 - q_1$$

- Estimar menos parámetros
- No necesitamos especificar las densidades de cada grupo
- Muchas familias satisfacen la relación lineal
- Particularmente útil para diagnósticos

# Distribuciones Desconocidas



- Estimar  $f(\mathbf{x})$  a partir de los datos como

$$\hat{f}(\mathbf{x}) = \frac{1}{n} \sum_{j=1}^n K(\mathbf{x} | \mathbf{x}_j, \lambda)$$

- Estimar  $f(\mathbf{x})$  a partir de los datos como

$$\hat{f}(\mathbf{x}) = \frac{1}{n} \sum_{j=1}^n K(\mathbf{x} | \mathbf{x}_j, \lambda)$$

- Donde  $K(\mathbf{y} | \mathbf{z}, \lambda)$  es un kernel o una densidad con moda  $\mathbf{z}$  y parámetro de suavidad  $\lambda$

- Estimar  $f(\mathbf{x})$  a partir de los datos como

$$\hat{f}(\mathbf{x}) = \frac{1}{n} \sum_{j=1}^n K(\mathbf{x} | \mathbf{x}_j, \lambda)$$

- Donde  $K(\mathbf{y} | \mathbf{z}, \lambda)$  es un kernel o una densidad con moda  $\mathbf{z}$  y parámetro de suavidad  $\lambda$
- Asignar a  $G_1$  si

$$\frac{\hat{f}_1(\mathbf{x})}{\hat{f}_2(\mathbf{x})} > \frac{\pi_2}{\pi_1}$$

- Para datos continuos

$$K_1(\mathbf{y} | \mathbf{z}, \lambda) = (2\pi\lambda^2)^{-\frac{p}{2}} |\mathbf{S}|^{-\frac{1}{2}} \exp \left[ \frac{1}{2\lambda^2} (\mathbf{y} - \mathbf{z})^T \mathbf{S}^{-1} (\mathbf{y} - \mathbf{z}) \right]$$

- Para datos continuos

$$K_1(\mathbf{y} | \mathbf{z}, \lambda) = (2\pi\lambda^2)^{-\frac{p}{2}} |\mathbf{S}|^{-\frac{1}{2}} \exp \left[ \frac{1}{2\lambda^2} (\mathbf{y} - \mathbf{z})^T \mathbf{S}^{-1} (\mathbf{y} - \mathbf{z}) \right]$$

- Para datos binarios se sugiere (Aitchison y Aitken, 1976)

$$K_2(\mathbf{y} | \mathbf{z}, \lambda) = \lambda^{p-D(\mathbf{y}, \mathbf{z})} (1 - \lambda)^{D(\mathbf{y}, \mathbf{z})} \quad \frac{1}{2} \leq \lambda \leq 1 \quad D(\mathbf{y}, \mathbf{z}) = ||\mathbf{y} - \mathbf{z}||^2$$

- Para datos continuos

$$K_1(\mathbf{y} | \mathbf{z}, \lambda) = (2\pi\lambda^2)^{-\frac{p}{2}} |\mathbf{S}|^{-\frac{1}{2}} \exp \left[ \frac{1}{2\lambda^2} (\mathbf{y} - \mathbf{z})^T \mathbf{S}^{-1} (\mathbf{y} - \mathbf{z}) \right]$$

- Para datos binarios se sugiere (Aitchison y Aitken, 1976)

$$K_2(\mathbf{y} | \mathbf{z}, \lambda) = \lambda^{p-D(\mathbf{y}, \mathbf{z})} (1 - \lambda)^{D(\mathbf{y}, \mathbf{z})} \quad \frac{1}{2} \leq \lambda \leq 1 \quad D(\mathbf{y}, \mathbf{z}) = ||\mathbf{y} - \mathbf{z}||^2$$

- Para mezclas de continuos y discretos

$$K_3(\mathbf{y} | \mathbf{z}, \lambda) = K_1(\mathbf{y} | \mathbf{z}, \lambda) K_2(\mathbf{y} | \mathbf{z}, \lambda)$$

# Otros métodos

- Vecino más cercano
- Particiones
- Distancias
- Rangos

Más de 2 grupos



- Suponemos:  $k$  grupos con proporciones  $\pi_i$  con densidades  $f_i$

- Suponemos:  $k$  grupos con proporciones  $\pi_i$  con densidades  $f_i$
- Queremos encontrar partición  $\mathcal{R} = \{R_1, R_2, \dots, R_k\}$  y asignar a  $G_i$  si  $\mathbf{x} \in G_i$

- Suponemos:  $k$  grupos con proporciones  $\pi_i$  con densidades  $f_i$
- Queremos encontrar partición  $\mathcal{R} = \{R_1, R_2, \dots, R_k\}$  y asignar a  $G_i$  si  $\mathbf{x} \in G_i$
- La probabilidad de asignar a  $G_j$  cuando viene de  $G_i$

$$P(j|i) = \int_{R_j} f_i(\mathbf{x}) d\mathbf{x}$$

- Suponemos:  $k$  grupos con proporciones  $\pi_i$  con densidades  $f_i$
- Queremos encontrar partición  $\mathcal{R} = \{R_1, R_2, \dots, R_k\}$  y asignar a  $G_i$  si  $\mathbf{x} \in R_i$
- La probabilidad de asignar a  $G_j$  cuando viene de  $G_i$

$$P(j|i) = \int_{R_j} f_i(\mathbf{x}) d\mathbf{x}$$

- La probabilidad de clasificar mal a un elemento de  $G_i$

$$P(i) = \sum_{j \neq i}^k P(j|i) = 1 - P(i|i)$$

- La probabilidad total de mis-clasificación

$$P(\mathcal{R}, \mathbf{f}) = \sum_{i=1}^k \pi_i P(i) = 1 - \sum_{i=1}^k \pi_i P(i | i)$$

- La probabilidad total de mis-clasificación

$$P(\mathcal{R}, \mathbf{f}) = \sum_{i=1}^k \pi P(i) = 1 - \sum_{i=1}^k \pi_i P(i | i)$$

- Usamos el enfoque bayesiano, i.e., asignar al grupo con mayor probabilidad posterior

$$q_i(\mathbf{x}) = \frac{\pi_i f_i(\mathbf{x})}{\sum_{j=1}^k \pi_j f_j(\mathbf{x})}$$

- La probabilidad total de mis-clasificación


$$P(\mathcal{R}, \mathbf{f}) = \sum_{i=1}^k \pi P(i) = 1 - \sum_{i=1}^k \pi_i P(i | i)$$

- Usamos el enfoque bayesiano, i.e., asignar al grupo con mayor probabilidad posterior

$$q_i(\mathbf{x}) = \frac{\pi_i f_i(\mathbf{x})}{\sum_{j=1}^k \pi_j f_j(\mathbf{x})}$$

- Los puntos frontera se asignan de forma arbitraria

## Ejemplo: Iris





- Los vectores de medias

$$\hat{\mu}_{set} = (3.428 \ , \ 5.006) \quad \hat{\mu}_{ver} = (2.770 \ , \ 5.936) \quad \hat{\mu}_{vir} = (2.974 \ , \ 6.588)$$

- Las matrices de varianzas y covarianzas

$$\hat{S}_{set} = \begin{pmatrix} 0.1436 & 0.0992 \\ 0.0992 & 0.1242 \end{pmatrix} \quad \hat{S}_{ver} = \begin{pmatrix} 0.0984 & 0.0851 \\ 0.0851 & 0.2664 \end{pmatrix} \quad \hat{S}_{vir} = \begin{pmatrix} 0.1040 & 0.0937 \\ 0.0937 & 0.4043 \end{pmatrix}$$

- Los vectores de medias

$$\hat{\mu}_{set} = (3.428, 5.006) \quad \hat{\mu}_{ver} = (2.770, 5.936) \quad \hat{\mu}_{vir} = (2.974, 6.588)$$

- Las matrices de varianzas y covarianzas

$$\hat{S}_{set} = \begin{pmatrix} 0.1436 & 0.0992 \\ 0.0992 & 0.1242 \end{pmatrix} \quad \hat{S}_{ver} = \begin{pmatrix} 0.0984 & 0.0851 \\ 0.0851 & 0.2664 \end{pmatrix} \quad \hat{S}_{vir} = \begin{pmatrix} 0.1040 & 0.0937 \\ 0.0937 & 0.4043 \end{pmatrix}$$


- Asumiendo que son la misma tomamos la varianza compartida

$$\hat{S}_p = \frac{49}{147} (\hat{S}_{set} + \hat{S}_{ver} + \hat{S}_{vir}) = \begin{pmatrix} 0.1153 & 0.0927 \\ 0.0927 & 0.2650 \end{pmatrix}$$

## Ejemplo: Iris

- Asignamos a setosa en lugar de versicolor si


$$D(\mathbf{x}) = (\hat{\mu}_{set} - \hat{\mu}_{ver})^T \hat{S}_p^{-1} \left[ \mathbf{x} - \frac{1}{2}(\hat{\mu}_{set} + \hat{\mu}_{ver}) \right] = 5.1528 - 7.6574x_1 + 11.8557x_2 > 0$$



## Ejemplo: Iris

- Asignamos a setosa en lugar de virginica si


$$D(\mathbf{x}) = (\hat{\mu}_{set} - \hat{\mu}_{vir})^T \hat{S}_p^{-1} \left[ \mathbf{x} - \frac{1}{2}(\hat{\mu}_{set} + \hat{\mu}_{vir}) \right] = 20.3612 - 10.2914x_1 + 12.1465x_2 > 0$$



## Ejemplo: Iris


- Asignamos a versicolor en lugar de virginica si

$$D(\mathbf{x}) = (\hat{\mu}_{ver} - \hat{\mu}_{vir})^T \hat{S}_p^{-1} \left[ \mathbf{x} - \frac{1}{2}(\hat{\mu}_{ver} + \hat{\mu}_{vir}) \right] = 15.2084 - 2.5621x_1 + 0.2908x_2 > 0$$



## Ejemplo: Iris

- Todas las regiones





- Simplificando las regiones

