




Pasajeros de avión

Datos

- Datos mensuales de enero de 1949 a diciembre de 1960



Observaciones

- No es estacionaria
- Tiene una tendencia creciente
- Tiene un componente estacional
- Varianza crece (efecto multiplicativo)

Descomposición clásica

- El modelo se puede expresar como


$$X_t = m_t + s_t + Y_t$$

donde

- m_t - es el componente de tendencia
 - s_t - es el componente estacional
 - Y_t - es un componente de ruido aleatorio estacionario
- No necesariamente aparecerán los dos componentes
 - El objetivo es estimar m_t y s_t (no se consideran aleatorios)

Datos

- Tendencia creciente y ciclos anuales



Estimación de m_t sin
componente estacional

Método 1: Suavizamientos


Suavizamiento mediante promedios móviles

$$\widehat{m}_t = (2q + 1)^{-1} \sum_{j=-q}^q X_{t-j}, \quad q + 1 \leq t \leq n - q$$


- ▶ Asumiendo observaciones $X_1, \dots, X_n$, no se puede calcular para $t \leq q$ ni para $t \geq n - q$
- ▶ Bajo ciertas condiciones puede remover la variación estacional

Promedio móvil $q = 1$

Valores ajustados




Residuales




- Sigue sin ser estacionario

Promedio móvil $q = 6$

Valores ajustados



Residuales



- Sigue sin ser estacionario

Método 1: Suavizamientos

Suavizamiento exponencial para $\alpha \in [0,1]$

$$\begin{aligned}\widehat{m}_t &= \alpha X_t + (1 - \alpha) \widehat{m}_{t-1}, & t = 2, \dots, n \\ \widehat{m}_1 &= X_1\end{aligned}$$


- Equivalentemente para $t \geq 2$

$$\widehat{m}_t = \sum_{j=0}^{t-2} \alpha(1 - \alpha)^j X_{t-j} + (1 - \alpha)^{t-1} X_1$$


- Versiones más generales para eliminar tendencia, estacionalidad, modelos aditivos y multiplicativos (en R: paquetería **forecast** y la función es **ets**)
- Eficiente para hacer predicciones a corto plazo pero no siempre es adecuado

Suavizamiento exponencial

Valores ajustados



Residuales



- Ya parece ser un ruido blanco

Método 2: Operador de diferencias

Diferencia de lag 1

$$\nabla X_t = X_t - X_{t-1} = (1 - B)X_t$$

donde $BX_t = X_{t-1}$

► Álgebra de ∇ y B


- $B^j X_t = X_{t-j}$
- $\nabla^j X_t = \nabla(\nabla^{j-1} X_t)$ con $\nabla^0 X_t = X_t$

► Por ejemplo:

$$\nabla^2 X_t = (1 - B)(1 - B)X_t = X_t - 2BX_t + B^2 X_t = X_t - 2X_{t-1} + X_{t-2}$$


Diferencia de lag 1

- No parece ser estacionario



Diferencias mejoradas

- ▶ Se puede mejorar estabilizando la varianza con logaritmo y combinando operadores



Estimación de m_t con
componente estacional s_t

Método 1: Suavizamientos

- ▶ Método 'clásico' (función **decompose** en R)
 1. Estimar m_t con un filtro de promedios móviles
 2. Construir serie sin tendencia, $d_t = X_t - m_t$
 3. Estimar la estacionalidad de d_t promediando por año en cada punto estacional
 4. Construir la serie $y_t = x_t - \widehat{m}_t - \widehat{s}_t$
- ▶ Brockwell y Davis (no hay función en R que lo haga)
 1. Estimar s_t mediante los promedios por punto estacional
 2. Construir serie sin estacionalidad, $d_t = X_t - s_t$
 3. Estimar la tendencia de d_t
 4. Construir la serie $y_t = x_t - \widehat{m}_t - \widehat{s}_t$

Método 1: Suavizamientos

Opciones más avanzadas y modernas

- Suavizamiento exponencial mediante modelos de espacio de estados
 - Función **ets** de R
 - Hyndman (2008). Forecasting with exponential smoothing: The state space approach.
- Suavizamiento Loess (Locally Estimated Scatterplot Smoothing)
 - Función **stl** de R
 - Cleveland et al. (1990). STL: A Seasonal-Trend Decomposition Procedure Based on Loess.

Método 2: Operador diferencias


- ▶ Para remover estacionalidad utilizar el operado:

$$\nabla_d X_t = (1 - B^d)X_t = X_t - X_{t-d} = m_t - m_{t-d} + Y_t - Y_{t-d}$$

- ▶ Eliminar el nuevo componente de tendencia $m_t - m_{t-d}$ con algún operador ∇^k

Diferencias mejoradas


- ▶ Aplicar logaritmo a la serie y utilizar ∇_{12} para el componente estacional y ∇ para el componente de tendencia




Análisis de residuales

ACF

- ▶ Para n suficientemente grande las autocorrelaciones muestrales $\hat{\rho}(j)$ de los residuales deben ser $\mathcal{N}(0, n^{-1})$
- ▶ Graficar el acf y checar que no haya muchos valores fuera de las bandas $(\pm 1.96/\sqrt{n})$ o un valor extremadamente grande



Suavizamiento exponencial



Operador diferencias

Prueba de Portmanteau

- ▶ Para n suficientemente grande las autocorrelaciones muestrales $\hat{\rho}(j)$ de los residuales deben ser $\mathcal{N}(0, n^{-1})$

- ▶ Bajo la hipótesis nula

$$Q = n \sum_{j=1}^h \hat{\rho}(j)^2 \sim \chi_h^2$$

- ▶ Rechazamos para valores grandes de Q
- ▶ No es muy utilizada en la práctica

Prueba de Ljung-Box

- Modificación de la prueba de Portmanteau, donde bajo la hipótesis nula

$$Q_{LB} = n(n+2) \sum_{j=1}^h \frac{\hat{\rho}(j)^2}{n-j} \sim \chi_h^2$$

- Rechazamos para valores grandes de Q_{LB}


Residuales	Q_{LB}	p-valor
Suavizamiento Exponencial	0.34999	0.5541
Operador Diferencias	15.596	7.843E-05

- Los residuales del suavizamiento ya son ruido estacionario pero los del operador de diferencias no

Modelos ARMA



Diferencias mejoradas

- ▶ Aplicar logaritmo a la serie y utilizar ∇_{12} para el componente estacional y ∇ para el componente de tendencia



Modelos ARMA

- A partir del ACF y PACF, ¿qué modelos ARMA se pueden ajustar?



Modelos ARMA

- ARMA(12,12)
- ARMA(1,1)
- AR(12)
- AR(1)
- MA(12)
- MA(1)



ARMA(1,1)

- Los parámetros estimados son

$$\phi = 0.1448$$


$$\theta = -0.5190$$

$$\sigma^2 = 0.001824$$

- AIC de -446.27



ARMA(1,1)

- Residuales



ARMA(1,1)


▸ Residuales



▸ p-value de Ljung-Box de 0.8985



ARMA(12,12)

- ¡Muchos parámetros (posiblemente innecesarios)!
- AIC de -467.34
- Residuales



ARMA(12,12)


- ACF y PACF



- p-value de Ljung-Box de 0.9907

ARMA(12,12)

- Predicción



- ¡Se tienen que revertir todas las transformaciones! (Proceso tedioso)