

Modelos de supervivencia y de series de tiempo

Tarea 2

Fecha de entrega: 5 de octubre

Instrucciones. La tarea se puede realizar en equipos de máximo 3 integrantes. Se entregará de forma física (o digital) a la hora de la clase y no habrá prórroga. El código utilizado para realizar los análisis no deberá incluirse en el reporte y se entregará en un archivo separado. El código deberá permitir reproducir los resultados numéricos y las gráficas presentadas en la tarea. Las actividades de DataCamp son individuales y podrán terminarse hasta el final de la fecha de entrega de la tarea.

1. (1 punto) Utiliza la expansión de Taylor de $\exp(-x)$ para mostrar que el estimador Kaplan-Meier es una aproximación al estimador Nelson-Aalen. ¿Qué condiciones se le debe pedir a d_j con respecto a n_j ? Asimismo, demuestra que el estimador de Nelson-Aalen siempre será mayor al de Kaplan-Meier para todo t .
2. (1 punto) Considera la base de datos *Turnover* para la cual se tiene el tiempo que pasan los empleados en sus trabajos (*stag*) antes de renunciar o ser despedidos (*event*).
 - (a) Encuentra el estimador de Kaplan-Meier para estos datos.
 - (b) Obtén las gráficas y realiza las pruebas adecuadas para verificar si existe diferencia en los tiempos de falla cuando se estratifica por el porcentaje del salario declarado antes las autoridades (*greywage*), donde *white* representa que todo el salario fue declarado y *grey* donde sólo un porcentaje del salario es declarado antes las autoridades.
 - (c) Obtén las gráficas y realiza las pruebas adecuadas para verificar si existe diferencia en los tiempos de falla cuando se estratifica por el tipo de industria (*industry*).
3. (1 punto) Considera la base de datos *Fumadores* la cual describe los tiempos (*ttr*) de recaída (*relapse*) para un grupo de personas aleatoriamente sujetas a dos tratamientos diferentes (*grp*: terapia triple (combination) o únicamente parche (patch)) y contesta lo siguiente a partir de las curvas de Kaplan-Meier y la prueba de log-rangos y Peto-Peto.
 - (a) ¿Hay diferencia en la supervivencia por tratamiento?
 - (b) ¿Hay diferencia en la supervivencia dependiendo el tipo de fumador (*levelSmoking*)?

- (c) ¿Hay diferencia en la supervivencia dependiendo de la raza (*race*)?
- (d) ¿Hay diferencia en la supervivencia dependiendo del tipo de trabajo (*employment*: tiempo completo (ft), tiempo parcial (pt) u otro esquema (other))?

4. (1.5 puntos) Considera la base de datos *Transplante médula ósea* la cual contiene las siguientes variables

- i. *grupo*: 1 - leucemia linfocítica aguda (ALL), 2 - riesgo bajo de leucemia mieloide aguda (AML) y 3 - riesgo alto de AML.
- ii. *tiempo*: tiempo a la muerte.
- iii. *status*: 1 - muerto, 0 - con vida.
- iv. *edadP*: edad del paciente.
- v. *edadD*: edad del donante.
- vi. *tiempoE*: tiempo de espera para recibir el transplante.
- vii. *FAB* (sistema de clasificación francés - americano - británico): 1 - Grado 4 o 5 AML, 0 - en otro caso.
- viii. *MTX* (metotrexato): 1 - sí, 0 - no.

Ajusta un modelo de Cox con todas las covariables y analiza la calidad del ajuste a partir de los residuales que creas convenientes.

5. (1.5 puntos) Considera la base de datos *Cáncer de laringe*, la cual contiene las siguientes variables

- i. *estado*: estado del cáncer (del 1 al 4).
- ii. *tiempo*: tiempo a la muerte en meses.
- iii. *edad*: edad al momento del diagnóstico.
- iv. *año*: año en el que se hizo el diagnóstico.
- v. *status*: 1 - muerte, 0 en otro caso.

Ajusta un modelo de Cox con todas las covariables. ¿El supuesto de relación lineal se cumple para las variables continuas? Si no es el caso, ¿puedes sugerir una forma funcional que arregle el problema?. A partir de los residuales de Cox-Snell ¿se puede pensar que el modelo es adecuado?. Finalmente, ¿qué puedes decir del supuesto de riesgos proporcionales?

6. (1.5 puntos) Considera la base *transplante de riñon*, la cual contiene las siguientes variables

- i. *id*: número de observación.
- ii. *tiempo*: tiempo a la muerte.

- iii. *status*: 1 - muerte, 0 en otro caso.
- iv. *sexo*: 1 - hombre, 2 - mujer.
- v. *raza*: 1 - blanco, 2 - negro.
- vi. *edad*: edad del paciente en años.

Ajusta un modelo de Cox utilizando una interacción de sexo y raza tomando como grupo base el ser mujer blanca y realiza un análisis de devianza ¿consideras que hay valores influyentes en la base de datos? De ser así, retíralos y vuelve a ajustar el modelo ¿cómo se compara el ajuste completo contra el ajuste sin valores influyentes?

7. (1.5 puntos) Suponga que se desea ajustar un modelo de riesgos proporcionales, esto es, el riesgo de morir al tiempo t del i -ésimo individuo es

$$h_i(t) = h_0(t) \exp(x^T \beta),$$

donde se asume que el riesgo para el grupo base está dada por

$$h_0(t) = \lambda \gamma t^{\gamma-1}.$$

- (a) Deriva la función de supervivencia del i -ésimo individuo ¿cómo se distribuye?.
- (b) Asume que sólo se tiene una covariable que toma los valores de 0 o 1 (para comparar dos grupos). Bajo el supuesto de riesgos proporcionales ¿qué debe suceder si se grafica $\log(-\log S_i(t))$ como función de $\log t$ para $i = 0, 1$?
- (c) Deriva la log-verosimilitud bajo el supuesto de que en n individuos hubo m muertes y $n - m$ censuras.
- (d) Utilizando la función *optim* de R escribe una rutina numérica que te permita calcular los estimadores de $\beta_1, \dots, \beta_p$, λ y γ para la base de *NCCTG Lung Cancer* utilizando las covariables de sexo y ECOG. Compara tus resultados con los que se obtienen de utilizar la función *flexsurvreg* de la paquetería *flexsurv*.
- (e) Obtén los residuales de Cox-Snell y los de devianza y realiza un análisis de residuales para verificar el ajuste del modelo.

Actividades de DataCamp

- 1. (0.5 puntos) Machine Learning for Marketing Analysis in R
- 2. (0.5 puntos) Manipulating Time Series data in R